

Optimización de la Planificación de la Oferta Académica mediante Modelo de Inteligencia Artificial.

Tesis de Pregrado

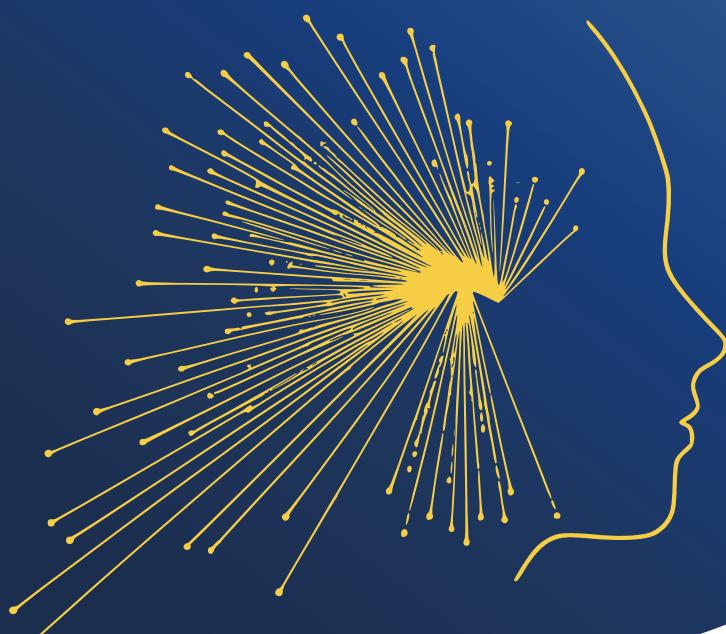
FACULTAD
DE INGENIERÍA

DEPARTAMENTO DE INGENIERÍA
EN SISTEMAS COMPUTACIONALES

Presentada por:
Joaquin David Buezo Rosa

Asesor Metodológico:
PhD. Óscar Guillermo Hernández Ramírez

Asesor Técnico:
MSc. Elías Emilio Flores Domínguez



Abril del 2026



UNAH
UNIVERSIDAD NACIONAL
AUTÓNOMA DE HONDURAS

Campus
Comayagua

Campus
Comayagua



UNAH
UNIVERSIDAD NACIONAL
AUTÓNOMA DE HONDURAS



Optimización de la Planificación de la Oferta Académica mediante Modelo de Inteligencia Artificial.

Joaquin David Buezo Rosa 

Asesor Metodológico: PhD. Óscar Guillermo Hernández
Ramírez 
PhD., Universidad Nacional Autónoma de Honduras

Asesor Técnico: MSc. Elías Emilio Flores Domínguez 
MSc., Universidad Nacional Autónoma de Honduras

Facultad de Ingeniería
Departamento de Ingeniería en Sistemas Computacionales
Licenciatura en Ingeniería en Sistemas

Tesis de Pregrado

Comayagua, Abril 2026

AUTORIDADES UNIVERSITARIAS

PHD. ODIR AARÓN FERNÁNDEZ FLORES
RECTOR

MÁSTER. JOSÉ ALEXANDER ÁVILA VALLECILLO
SECRETARIO GENERAL

DRA. LOURDES ROSARIO MURCIA CARBAJAL
VICERRECTORA ACADÉMICA

MÁSTER MILTHON MOISÉS REYES SOSA
DIRECTOR DEL CENTRO

MÁSTER JOSÉ GÁMEZ SUAZOO
SECRETARIO ACADÉMICO

PHD. EDIS FRANCISCO ROMERO MEJIA
JEFE DE DEPARTAMENTO
DE INGENIERÍA EN SISTEMAS COMPUTACIONALES

Acerca del Autor

Joaquin David Buezo Rosa



Estudiante de Ingeniería en Sistemas
Universidad Nacional Autónoma de Honduras
Campus Comayagua

ORCID: 0009-0001-4129-0329
Google Scholar: Joaquin David Buezo Rosa
LinkedIn: Joaquin David Buezo Rosa
GitHub: @joasro
Email: joaquin.buezo@unah.hn

Ingeniero en Sistemas por la Universidad Nacional Autónoma de Honduras (2026). Su formación se orientó al desarrollo de soluciones tecnológicas basadas en programación, análisis de datos e inteligencia artificial, con énfasis en la optimización de procesos académicos.

Se desarrollaron sistemas web, bases de datos y modelos predictivos aplicados a la planificación académica en UNAH-Comayagua, mediante el análisis de datos históricos de matrícula. Sus intereses de investigación se centraron en la minería de datos educativa y en la aplicación de algoritmos de aprendizaje automático para la optimización de la oferta académica.

Identificadores Académicos:

Lenguajes: C#, Python, TypeScript, JavaScript, SQL, L^AT_EX

Data Science: Pandas, NumPy, Scikit-learn, Matplotlib, Seaborn, SciPy

Frameworks y Entornos: Express.js, Firebase, Streamlit, Node.js

Bases de Datos: MySQL

Redes y Simulación: Cisco Packet Tracer (BGP, enrutamiento, diseño de redes)



Optimización de la Planificación de la Oferta Académica mediante Algoritmos de Inteligencia Artificial.

Copyright © 2026 - Joaquin David Buezo Rosa, Facultad de Ingeniería.

Esta tesis es un trabajo original, escrito exclusivamente para este fin, y todos los autores cuyos estudios y publicaciones han contribuido a ella han sido debidamente citados. Se permite la reproducción parcial con el reconocimiento del autor y la referencia al título, año académico, institución —*Universidad Nacional Autónoma de Honduras*— y fecha de defensa pública.



Un perdedor, es un ganador que lo volvio a intentar.

— Bananirou

*A mis padres,
por su amor y apoyo incondicional.*

*A mis hermanas,
por su inspiración y compañía.*

*A mi sobrino,
a quien deseo inspirar y motivar a perseguir sus sueños.*

*A mis maestros,
por compartir su conocimiento y sabiduría.*

Motivación

La motivación fundamental para el desarrollo de la presente investigación surgió de la experiencia directa vivida dentro del entorno universitario, donde se evidenció la necesidad crítica de optimizar los procesos de gestión académica. Durante los últimos años de la carrera, se observó cómo la falta de una planificación basada en datos generaba una constante incertidumbre en la población estudiantil, afectando la toma de decisiones sobre qué asignaturas cursar y provocando, en múltiples ocasiones, la imposibilidad de inscribir clases esenciales para el avance del flujo curricular.

Esta problemática se identificó no como un hecho aislado, sino como una realidad sistemática en la que el Censo Académico no cumplía su función predictiva, resultando en una oferta de horarios desconectada de la demanda real. Se experimentó la dificultad de acceder a cupos en asignaturas críticas y el impacto negativo que esto conllevó en el tiempo de graduación, lo que impulsó el interés por investigar cómo las herramientas tecnológicas modernas podrían mitigar estas ineficiencias y transformar la experiencia administrativa y educativa.

En consecuencia, se planteó el desafío de trascender la simple observación del problema para proponer una solución técnica y rigurosa. Se buscó aplicar los conocimientos adquiridos en ingeniería de sistemas e inteligencia artificial para diseñar un modelo capaz de anticipar la demanda y optimizar la distribución de recursos. El objetivo se centró en demostrar que la implementación de algoritmos predictivos podía sustituir la intuición por la precisión matemática, reduciendo así la fricción que los estudiantes enfrentan periodo tras periodo al intentar armar sus horarios.

Finalmente, este trabajo se concibió bajo el compromiso de aportar un legado funcional a la comunidad universitaria. La investigación se orientó a sentar las bases para una gestión académica más ágil y justa, donde la tecnología sirviera como un puente para garantizar que la oferta educativa respondiera verdaderamente a las necesidades de los estudiantes, promoviendo así un entorno más ordenado y propicio para el éxito profesional de las futuras generaciones.

Agradecimientos

A mi Compita, **Gemini 3 Pro**, por hacerme una parte del trabajo.

A mi Doggy, **Chat Yipiti**, por hacer la otra parte.

Resumen

Esta tesis se centra en la evaluación del flujo vehicular en las principales intersecciones de la ciudad de Comayagua que experimentan congestión. Inicialmente, se aplicó la observación directa como técnica para estimar el volumen de tráfico que circula por estas zonas críticas.

Posteriormente, se realizó un análisis de la red vial mediante la teoría de grafos, utilizando las librerías de Python OSMx y NetworkX. Buscando identificar las intersecciones (nodos) con una alta puntuación de centralidad, que son esenciales para conectar la mayoría de las rutas más cortas. Una vez definidas las calles críticas, se ejecutó una simulación de tráfico con la herramienta SUMO bajo tres escenarios: el flujo base, un incremento del 30 %, y una duplicación del flujo vehicular. Además, se comparó el desempeño del tráfico en el nodo crítico al emplear un semáforo contra la instalación de una rotonda.

Los resultados demostraron una mejora significativa en la movilidad, evidenciada por un aumento en la velocidad media, una reducción del tiempo perdido, y un incremento en las paradas por vehículo, sugiriendo una mayor fluidez. Validando la factibilidad de emplear la teoría de grafos y herramientas de simulación para proponer estrategias efectivas de descongestión vehicular y fundamentar la toma de decisiones.

Palabras Clave: Tráfico vehicular, Teoría de grafos, Simulación, Congestionamiento

Abstract

This thesis focuses on evaluating vehicular flow at the main intersections of the city of Comayagua that experience congestion. Initially, direct observation was applied as a technique to estimate the traffic volume circulating through these critical areas.

Subsequently, a road network analysis was conducted using graph theory, employing the Python libraries OSMnx and NetworkX. The objective was to identify intersections (nodes) with a high centrality score, which are essential because they connect most of the shortest routes. Once the critical streets were defined, a traffic simulation was executed using the SUMO tool under three scenarios: the baseline flow, a 30

The results demonstrated a significant improvement in mobility, evidenced by an increase in average speed, a reduction in lost time, and an increase in stops per vehicle, suggesting greater fluidity. This validates the feasibility of using graph theory and simulation tools to propose effective vehicular decongestion strategies and support decision-making.

Keywords: Vehicular Traffic, Graph Theory, Simulation, Congestion

Índice general

<i>Índice de figuras</i>	xiv
<i>Índice de tablas</i>	xvi
<i>Glosario de Acrónimos</i>	xviii
I PRESENTACIÓN	1
1. Introducción	2
1.1. Planteamiento del Problema	3
1.2. Objetivos de la investigación	4
1.2.1. Objetivo General	4
1.2.2. Objetivos Específicos	4
1.3. Preguntas de investigación	4
1.4. Justificación de la investigación	4
1.4.1. Justificación Teórica y Técnica	4
1.4.2. Justificación Práctica y Administrativa	5
1.4.3. Justificación Económica	5
1.4.4. Justificación Social	6
1.5. Alcances y limitaciones	6
II Marco Teórico / Estado del arte	7
2. Investigaciones previas relacionadas	8
2.1. Antecedentes y estado actual de la investigación	9
2.2. Estado del arte	10
3. Educación Superior y Modalidades	12
3.1. Contexto Actual y Transformación Digital en la Educación Superior	13
3.1.1. Alineación estratégica con los Objetivos de Desarrollo Sostenible (ODS)	15
3.2. Modalidades educativas y su impacto en la gestión de recursos	15

3.2.1. Educación Presencial, Virtual e Híbrida	16
3.2.2. Requerimientos físicos y tecnológicos por modalidad	17
3.3. La gestión administrativa en los centros universitarios	18
3.3.1. Impacto Económico de la Planificación Académica	19
3.3.2. Complejidad Logística de la Asignación de Horarios	20
4. Planificación Académica y Distribución de Cargas	21
4.1. El proceso de programación de la oferta académica	22
4.2. La Cadencia Académica y el flujo curricular	24
4.2.1. Importancia de la secuencia de asignaturas	25
4.2.2. Tiempos y ciclos de gestión académica	26
4.3. Problemáticas en la distribución de secciones	26
4.3.1. Subestimación de cupos y saturación	28
4.3.2. Impacto de la mala distribución en el egreso estudiantil	28
5. Inteligencia Artificial y Gestión de Datos	30
5.1. Inteligencia Artificial aplicada a la gestión administrativa	31
5.2. Minería de Datos Educativa (EDM) y Big Data	33
5.3. Ciclo de vida de los datos: Adquisición y Preparación	35
5.4. Aprendizaje Automático	36
5.4.1. Conceptos clave: Entrenamiento, Pruebas y Validación	37
5.4.2. Algoritmos de Regresión	38
5.4.3. Algoritmos de Clasificación	38
5.5. Métricas de evaluación y validación de modelos	40
5.6. Interfaz de Programación de Aplicaciones y consumo de datos	41
6. Optimización de la Oferta Académica mediante IA	43
6.1. Marco Conceptual del Sistema Propuesto	44
6.2. Censo Académico Inteligente: Integración de la Intención de Demanda Estudiantil	46
6.3. Aplicación de Aprendizaje Automático para el Ajuste de la Cadencia Académica	48
6.4. Módulo de Predicción de Cupos y Secciones	49
6.5. Estrategias de Optimización de Recursos Físicos y Horarios	51
6.6. Sistemas de Apoyo a la Toma de Decisiones para Unidades de Jefatura	53
6.7. Sinergia entre la Predicción de Datos y la Planificación Estratégica	55
7. Marco Conceptual	58
7.1. Glosario conceptual del estudio	59



8. Marco Legal	62
8.1. Marco Legal	63
8.1.1. Normativa Académica e Institucional de la UNAH	63
8.1.2. Protección de Datos Personales y Habeas Data	63
8.1.3. Estándares Éticos y Normativa Internacional de la Inteligencia Artificial	64
III Marco Metodológico	67
9. Metodología	68
9.1. Tipo de investigación	69
9.2. Diseño Metodológico	69
9.3. Involucrados en la investigación	70
9.3.1. Principales involucrados	70
9.3.2. Otros involucrados	70
9.4. Técnicas e Instrumentos de recolección de datos	71
9.5. Procedimiento	72
9.6. Herramientas tecnológicas utilizadas	74
9.7. Métodos de validación	76
9.7.1. Métricas de evaluación del modelo	76
9.7.2. Casos de uso	78
IV Implementación de la propuesta tecnológica	81
10. Implementación	82
10.1. Diseño de la Solución tecnológica	83
10.1.1. Arquitectura general del sistema	84
10.1.2. Flujo de procesos	85
10.2. Implementación	86
10.2.1. Preparación y estructuración de los datos	86
10.2.2. Desarrollo del modelo de análisis basado en teoría de grafos	86
10.2.3. Integración con la simulación de tráfico	87
10.2.4. Entorno de desarrollo y herramientas utilizadas	89
10.2.5. Validación inicial del sistema	89
10.3. Pruebas y resultado preliminares	89
10.3.1. Análisis de la red vial mediante la teoría de grafos	89
10.3.2. Pruebas de simulación en SUMO	90
10.3.3. Pruebas de carga	91



V Resultados y Análisis	93
11. Resultados y Análisis	94
11.1. Presentación de Resultados	95
11.2. Interpretación y análisis de los resultados obtenidos	105
11.2.1. Análisis de Escenarios de Demanda Creciente	106
11.2.2. Evaluación de la Propuesta de Mitigación (Rotonda vs. Semáforo) .	107
11.3. Comparación con Investigaciones Previas o Estándares	107
11.3.1. Niveles de Servicio (NdS) y Vulnerabilidad	108
11.3.2. Comparación de Soluciones: Semáforo vs. Rotonda	108
11.4. Validación de objetivos planteados	109
VI Conclusiones y Recomendaciones	111
12. Conclusiones y recomendaciones	112
12.1. Conclusiones generales	113
12.2. Aportes tecnológicos y prácticos de la investigación	114
12.3. Limitaciones encontradas durante la implementación	114
12.4. Recomendaciones	115
12.5. Trabajos Futuros	116
VII Referencias	119
<i>Bibliografía</i>	121
VIII Anexos	133
13. Anexos	134
Anexos	134

Índice de figuras

10.1. Arquitectura del Sistema de Análisis y Optimización del Tráfico Vehicular	85
10.2. Flujo de procesos del sistema de análisis y optimización del tráfico vehicular	86
10.3. Grafo inicial de la red vial de la Cuidad de Comayagua	90
10.4. Configuración del flujo vehicular en Netedit	91
10.5. Simulacion de Escenarios en sumo-gui	92
11.1. Pronóstico del Parque Vehicular en Honduras	95
11.2. Análisis Topológico y de Vulnerabilidad: Centralidad de Intermediación de la Red Vial de Comayagua	96
11.3. Simulación de Velocidad Media bajo Escenarios de Crecimiento Vehicular	97
11.4. Simulación de Pérdida de Tiempo bajo Escenarios de Crecimiento Vehicular	98
11.5. Simulación de Paradas por Vehículo bajo Escenarios de Crecimiento Vehicular	99
11.6. Impacto de la Rotonda en la Velocidad Media	100
11.7. Impacto de la Rotonda en la Pérdida de Tiempo	101
11.8. Impacto de la Rotonda en la Paradas por Vehículo	102
11.9. Datos Comparativos de la intersección Bulevar 4 Centenario y Carretera RN-57	103
11.10Datos Comparativos de la intersección Bulevar 4 Centenario y Calle 0	104
11.11Datos Comparativos de la intersección frente al Hospital Santa Teresa	105
13.1. Interfaz de SUMO NETEDIT para la edición de redes viales	134
13.2. Equipo de cómputo utilizado para la realización de las simulaciones y análisis de datos	135

Índice de tablas

11.1. Comparación del desempeño por escenarios y nivel de servicio estimado. . . . 108

Glosario de Acrónimos

API	Interfaz de Programación de Aplicaciones, Application Programming Interface. (p. 41)
BAMS	Sistemas de Automatización y Gestión de Edificios, Building Automation and Management Systems. (p. 52)
BDA	Analítica de Big Data, Big Data Analytics. (p. 33)
CART	Árboles de Clasificación y Regresión, Classification and Regression Trees. (p. 19)
COVID-19	Enfermedad por Coronavirus 2019, Coronavirus Disease 2019. (p. 31)
CPN	Redes de Prerrequisitos de Cursos, Course-Prerequisite Networks. (p. 48)
DAG	Grafo Dirigido Acíclico, Directed Acyclic Graph. (p. 48)
DEA	Análisis Envolvente de Datos, Data Envelopment Analysis. (p. 18)
DSS	Sistema de Soporte a la Decisión, Decision Support System. (p. 5)
EDM	Minería de Datos Educativos, Educational Data Mining. (p. 22)
EDW	Almacén de Datos Educativos, Educational Data Warehouse. (p. 24)
ERP	Planificación de Recursos Empresariales, Enterprise Resource Planning. (p. 41)
ETL	Extracción, Transformación y Carga; Extract, Transform, Load. (p. 35)
GA	Algoritmos Genéticos, Genetic Algorithms. (p. 52)
GDPR	Reglamento General de Protección de Datos, General Data Protection Regulation. (p. 26)
GPA	Promedio de Calificaciones, Grade Point Average. (p. 19)
GPD	Grafo Ponderado y Dirigido. (p. 114)
GSCV	Búsqueda en Cuadrícula con Validación Cruzada, Grid Search Cross-Validation. (p. 37)

HCM	Manual de Capacidad de Carreteras, Highway Capacity Manual. (<i>p. 107, 108</i>)
IA	Inteligencia Artificial. (<i>p. 14, 74</i>)
IMS	Sistema de Gestión de Información, Information Management System. (<i>p. 34</i>)
IoT	Internet de las Cosas, Internet of Things. (<i>p. 83</i>)
KM	Gestión del Conocimiento, Knowledge Management. (<i>p. 32</i>)
LIME	Explicaciones Agnósticas al Modelo Interpretables Localmente, Local Interpretable Model-agnostic Explanations. (<i>p. 54</i>)
LLM	Grandes Modelos de Lenguaje, Large Language Models. (<i>p. 14</i>)
LMS	Sistemas de Gestión del Aprendizaje, Learning Management Systems. (<i>p. 23</i>)
MAE	Error Absoluto Medio, Mean Absolute Error. (<i>p. 40</i>)
MCC	Coeficiente de Correlación de Matthews, Matthews Correlation Coefficient. (<i>p. 40</i>)
ML	Aprendizaje Automático, Machine Learning. (<i>p. 19</i>)
NdS	Niveles de Servicio, Levels of Service. (<i>p. 107, 108</i>)
NP	Tiempo Polinómico No Determinista, Non-deterministic Polynomial-time. (<i>p. 5</i>)
ODS	Objetivos de Desarrollo Sostenible. (<i>p. 3</i>)
RFE	Eliminación Recursiva de Características, Recursive Feature Elimination. (<i>p. 36</i>)
RMSE	Raíz del Error Cuadrático Medio, Root Mean Square Error. (<i>p. 28</i>)
SEM	Modelo de Ecuaciones Estructurales, Structural Equation Modeling. (<i>p. 14</i>)
SHAP	Explicaciones Aditivas de Shapley, SHapley Additive exPlanations. (<i>p. 54</i>)
SIE	Sistemas de Información Estratégica. (<i>p. 18</i>)
SLM	Modelos de Lenguaje Pequeños, Small Language Models. (<i>p. 38</i>)
SUMO	Simulation of Urban Mobility. (<i>p. 71, 73, 74, 84, 87, 88, 95</i>)
SVM	Máquinas de Soporte Vectorial, Support Vector Machines. (<i>p. 39</i>)
UCTP	Problema de Horarios de Cursos Universitarios, University Course Timetabling Problem. (<i>p. 20</i>)
XAI	Inteligencia Artificial Explicable, Explainable AI. (<i>p. 54</i>)

PRESENTACIÓN

1847

1

Introducción

Contenido del Capítulo

1.1. Planteamiento del Problema	3
1.2. Objetivos de la investigación	4
1.2.1. Objetivo General	4
1.2.2. Objetivos Específicos	4
1.3. Preguntas de investigación	4
1.4. Justificación de la investigación	4
1.4.1. Justificación Teórica y Técnica	4
1.4.2. Justificación Práctica y Administrativa	5
1.4.3. Justificación Económica	5
1.4.4. Justificación Social	6
1.5. Alcances y limitaciones	6

1.1. Planteamiento del Problema

A nivel mundial, la educación superior atraviesa una crisis de "masificación" sin precedentes. Según datos de la UNESCO^[1], la matrícula universitaria global se ha triplicado en los últimos años, tomando de referencia desde el año 2000 hasta datos más recientes en 2024, pasando de 100 millones a más de 264 millones de estudiantes, lo que ha generado una presión insostenible sobre la infraestructura y los recursos docentes de las instituciones públicas. Este crecimiento desmedido, si no se gestiona con herramientas de planificación estratégica, deriva en la saturación de aulas y la incapacidad de las universidades para ofrecer los cupos necesarios que la población estudiantil demanda.

La ineficiencia en la gestión de la oferta académica tiene consecuencias directas en el éxito estudiantil. El Banco Mundial^[2] señala que en América Latina, aproximadamente el 46 % de los estudiantes que ingresan a la educación superior logran graduarse, y de ellos, una gran mayoría tarda hasta un 40 % más del tiempo estipulado en su plan de estudios. Este fenómeno, conocido como el rezago académico, es alimentado en gran medida por la falta de disponibilidad de asignaturas críticas, lo que obliga a los estudiantes a extender su permanencia en la universidad, elevando los costos operativos para el Estado y retrasando su inserción en el mercado laboral.

En el contexto regional, la Organización de Estados Iberoamericanos (OEI) ha identificado debilidades estructurales en la gestión universitaria. Los informes de diagnóstico revelan un rezago tecnológico significativo, donde el ecosistema digital de la región presenta apenas un 50 % de desarrollo en comparación con el 80 % alcanzado en América del Norte^[3]. Esta disparidad pone de manifiesto una infraestructura insuficiente para afrontar los desafíos de la planificación moderna. A esta situación se suma una desconexión en la pertinencia académica; estudios de competitividad señalan la existencia de una "importante y creciente brecha" entre la formación ofrecida y los requerimientos reales del entorno^[4], fenómeno que deriva en la subutilización del capital humano y obstaculiza la inserción laboral de los egresados.

Por su parte, la gestión administrativa en las universidades públicas hondureñas enfrenta limitaciones técnicas que restringen su capacidad de optimización. La implementación de tecnologías de la información se ha circunscrito mayoritariamente a procesos operativos básicos, dejando de lado el uso de herramientas analíticas avanzadas para la planificación estratégica^[2]. En consecuencia, la toma de decisiones sobre la programación de secciones académicas continúa sustentándose en criterios empíricos y tradicionales, lo que conlleva a ignorar patrones subyacentes en los datos históricos institucionales. Esta carencia de mecanismos de predicción y análisis compromete la eficiencia operativa y dificulta el aseguramiento de una educación inclusiva y equitativa, metas fundamentales del Objetivos de Desarrollo Sostenible (ODS) N.º 4 de la Agenda 2030^[5].



1.2. Objetivos de la investigación

1.2.1. Objetivo General

Optimizar la planificación de la oferta académica en instituciones de educación mediante el desarrollo de un modelo de inteligencia artificial que soporte la toma de decisiones para una distribución eficiente de los recursos institucionales.

1.2.2. Objetivos Específicos

- Analizar datos históricos de cargas académicas y matrícula para identificar patrones de demanda en distintas asignaturas.
- Examinar y priorizar las variables académicas y normativas que influyen en la apertura de secciones, tales como mínimos de estudiantes y prioridades académicas.
- Diseñar un modelo predictivo que permita estimar la demanda de secciones académicas en futuros períodos.
- Evaluar el desempeño del modelo a través de un conjunto de datos de prueba a pequeña escala.

1.3. Preguntas de investigación

- ¿Qué patrones de demanda pueden identificarse a partir del análisis de datos históricos de matrícula y cargas académicas?
- ¿Cuáles son las variables académicas y normativas que influyen con mayor peso en la apertura de secciones académicas?
- ¿Cómo puede diseñarse un modelo predictivo basado en aprendizaje automático que permita estimar la demanda futura de secciones académicas?
- ¿Qué nivel de desempeño presenta el modelo predictivo al ser evaluado con datos históricos de prueba?

1.4. Justificación de la investigación

1.4.1. Justificación Teórica y Técnica

La presente investigación se justifica en la necesidad de superar las limitaciones de los modelos estadísticos tradicionales utilizados en la gestión educativa. La literatura reciente demuestra que métodos como la regresión lineal o logística son insuficientes para capturar la complejidad no lineal del comportamiento estudiantil actual [6]. Al implementar algoritmos de aprendizaje automático, específicamente Random Forest, este estudio busca llenar un vacío metodológico, validando herramientas que permiten jerarquizar la im-



portancia de variables demográficas y académicas con una precisión superior al análisis probabilístico estándar [6].

Asimismo, se aborda la programación de horarios como un problema de optimización combinatoria clasificado como Tiempo Polinómico No Determinista, Non-deterministic Polynomial-time (NP)-Hard [7]. La investigación aporta valor teórico al demostrar que la gestión de restricciones “duras” y “blandas” en la asignación de recursos no es eficiente con planificación manual, justificando el uso de metaheurísticas y modelos predictivos como la única vía para garantizar soluciones factibles en espacios de búsqueda de alta complejidad [7].

1.4.2. Justificación Práctica y Administrativa

Desde una perspectiva operativa, el proyecto responde a la desconexión crítica diagnosticada entre la infraestructura tecnológica y la toma de decisiones estratégicas en las universidades latinoamericanas [8]. A pesar de que las instituciones generan grandes volúmenes de datos, la falta de una cultura de análisis ha convertido a los sistemas de información en simples repositorios pasivos [8]. Esta propuesta ofrece una solución práctica mediante un Sistema de Soporte a la Decisión, Decision Support System (DSS) que transforma datos históricos aislados en inteligencia accionable, permitiendo a las autoridades anticipar la demanda real de cupos y evitar la gestión reactiva.

Además, esta investigación responde a los retos de la educación híbrida. Evidencia reciente del año 2025 indica que una proporción significativa de los docentes (aproximadamente un tercio) percibe que los recursos tecnológicos actuales son insuficientes para soportar adecuadamente la modalidad mixta [9]. El sistema se justifica al integrar variables de infraestructura física y digital en la planificación, asegurando que la asignación de espacios responda a los requerimientos técnicos actuales y mitigue las barreras operativas detectadas.

1.4.3. Justificación Económica

La optimización de la oferta académica tiene un impacto directo en la sostenibilidad financiera de la institución. La incapacidad para predecir con exactitud las tasas de inscripción genera costos administrativos innecesarios, derivados de la apertura de secciones con baja demanda o la saturación de otras que requieren contratación docente de emergencia [6]. Al minimizar el error de predicción, esta investigación contribuye a la eficiencia presupuestaria, permitiendo una asignación de recursos (humanos y físicos) ajustada a la demanda real, lo cual es un imperativo para la sostenibilidad en el contexto de la Cuarta Revolución Industrial [10].



1.4.4. Justificación Social

Finalmente, el impacto más significativo recae sobre el éxito estudiantil. La falta de disponibilidad de cupos en asignaturas críticas, conocidas como “cuellos de botella”, interrumpe el flujo curricular y es un factor determinante en el rezago académico [11]. Al utilizar análisis de redes para identificar estos nodos críticos y predecir el riesgo de deserción asociado a factores financieros y académicos con una precisión cercana al 89 % [12], el sistema propuesto no solo optimiza procesos, sino que favorece la continuidad educativa. Esto garantiza que los estudiantes puedan avanzar en su malla curricular sin bloqueos administrativos, reduciendo las tasas de abandono y facilitando su inserción oportuna en el mercado laboral.

1.5. Alcances y limitaciones

Esta investigación comprende el diseño y desarrollo de un prototipo funcional de plataforma digital basada en inteligencia artificial para predecir la demanda académica en UNAH-Comayagua. El sistema procesará registros de intención de matrícula y datos históricos mediante algoritmos de regresión y clasificación. El alcance incluye la creación de perfiles de usuario, un módulo de análisis predictivo y un dashboard de visualización para autoridades. Entre las limitaciones, se reconoce que la variabilidad en la calidad de los datos históricos puede afectar la precisión inicial, y que las pruebas piloto se limitarán a una muestra representativa de X estudiantes debido a restricciones temporales.

- **Viabilidad Técnica:** El proyecto se desarrollará utilizando el lenguaje de programación Python, empleando librerías especializadas como Pandas y Scikit-Learn. La gestión de datos se realizará mediante el motor de base de datos MySQL. La interfaz de usuario será implementada con el framework Streamlit y el código fuente será auditado mediante un repositorio en GitHub.
- **Viabilidad Económica y Operativa:** La investigación cuenta con la viabilidad operativa al disponer del apoyo de la Jefatura de Departamento de UNAH-Comayagua para el acceso a la información. Es económicamente viable al basarse en tecnologías de código abierto, no requiriendo inversión financiera directa por parte de la institución.



Parte II

MARCO TEÓRICO / ESTADO DEL ARTE

2

Investigaciones previas relacionadas

Contenido del Capítulo

2.1. Antecedentes y estado actual de la investigación	9
2.2. Estado del arte	10

2.1. Antecedentes y estado actual de la investigación

En la última década, la gestión académica ha transitado de modelos administrativos estáticos a enfoques dinámicos basados en datos. La literatura reciente coincide en que la sostenibilidad de las instituciones de educación superior depende ahora de integrar tecnología en la planificación operativa, más allá de su oferta pedagógica. No obstante, la adopción de estas herramientas varía según el contexto geográfico y cultural.

Al contrastar las exigencias del entorno global con la realidad operativa latinoamericana, se evidencia una brecha crítica en la gestión de recursos. Mientras que Shenkoya y Kim[10], establecieron que la transformación digital es un imperativo de supervivencia para la sostenibilidad en la Cuarta Revolución Industrial, Gallegos Macías et al[8], demostraron que, en la práctica regional, esta transición es deficiente. A pesar de que las instituciones invierten en infraestructura tecnológica, Gallegos Macías et al. diagnosticaron que los Sistemas de Información Estratégica (SIE) funcionan mayoritariamente como repositorios de datos aislados. Esta desconexión confirma que el problema no es la falta de herramientas digitales, sino la ausencia de una cultura organizacional que alinee los datos operativos con la visión estratégica de sostenibilidad propuesta por Shenkoya y Kim[10].

En el ámbito metodológico, la insuficiencia de los modelos estadísticos tradicionales fue abordada por Shao et al.[6] y Shilbayeh y Abonamah[12], quienes optaron por enfoques de aprendizaje automático más sofisticados. Mientras que Shao et al.[6] validaron el uso de Random Forest, Shilbayeh y Abonamah[12] implementaron Árboles de Regresión Potenciados (Boosted Regression Trees) para la predicción de matrículas y el algoritmo Apriori para detectar patrones de deserción. Contrario a los métodos probabilísticos simples, su modelo de regresión potenciado alcanzó una precisión del 89 % mediante validación cruzada, superando significativamente al 76 % obtenido con árboles de decisión simples. Además, mediante la minería de reglas de asociación, lograron identificar perfiles de riesgo específicos combinando variables como la edad, experiencia laboral y GPA, permitiendo a la institución diseñar intervenciones preventivas basadas en reglas comportamentales concretas.

La evolución de la investigación también ha redefinido la jerarquía de los datos relevantes para la planificación. Shao et al.[6] aplicaron métricas de importancia de variables (feature importance) utilizando Random Forest, logrando reducir la tasa de error al 0.8 %. Su análisis reveló que, si bien se integraron datos demográficos, los predictores más determinantes no fueron estos, sino variables administrativas y temporales críticas como la fecha de cumplimiento de prerequisitos y el término de ingreso. Por su parte, Shilbayeh y Abonamah[12] demostraron que un sistema robusto no depende de una sola variable financiera, sino de la interacción compleja de factores; sus reglas de asociación evidenciaron que el riesgo de deserción se concentra en perfiles específicos, como estudiantes de mayor edad con poca experiencia laboral y bajo rendimiento académico, validando la necesidad



de sistemas multidimensionales para reducir la incertidumbre en la oferta de cupos. Un avance fundamental en los antecedentes de la optimización académica es el cambio de paradigma en la visualización del plan de estudios. Tradicionalmente, la oferta se planificaba como una lista lineal de asignaturas, un enfoque que Stavrinides y Zuev[11], desafilaron al proponer el modelado mediante Redes de Prerrequisitos de Cursos (CPNs). Al aplicar la teoría de grafos, estos autores demostraron que la complejidad de la gestión no reside solo en la cantidad de alumnos, sino en la topología de la malla curricular.

La aplicación de métricas de centralidad permitió cuantificar fenómenos que antes solo se gestionaban intuitivamente. Stavrinides y Zuev[11], introdujeron el uso de la “Centralidad de Intermediación” (Betweenness Centrality) para detectar asignaturas que actúan como puentes críticos en la red de conocimiento.

Finalmente, la comprensión de la jerarquía curricular se consolidó mediante la estratificación topológica. Stavrinides y Zuev[11], establecieron que los planes de estudio poseen una estructura de niveles de dependencia que dicta el flujo natural de la demanda.

2.2. Estado del arte

En el estado actual del conocimiento, la optimización de la oferta académica supera la estadística tradicional e incorpora computación evolutiva y análisis de sistemas complejos. El estado del arte aborda problemas de asignación intratables para humanos, integrando infraestructura para modalidades híbridas y el comportamiento digital de estudiantes, que redefinen la planificación eficiente.

La resolución del Problema de Horarios Universitarios (UCTP) ha alcanzado un nivel de sofisticación que separa definitivamente la gestión manual de la automatizada. Abdipoor et al.[7], definieron este problema como NP-Hard, estableciendo que la única vía viable para su resolución es el uso de metaheurísticas híbridas.

Una dimensión emergente en el estado del arte es la validación de la educación híbrida desde la perspectiva docente. Guadalupe Beltrán et al.[9] aportaron evidencia sobre cómo la modalidad mixta ha transformado la práctica educativa, revelando que el 82 % de los docentes percibe el modelo como flexible y adaptable. Sin embargo, el estudio no señaló a la infraestructura física como la única barrera, sino que identificó que el 18 % de los docentes mantiene reservas debido principalmente a desafíos de conectividad, adaptación pedagógica y competencias digitales. Esto implica que los modelos de optimización modernos no solo deben verificar el hardware, sino priorizar la capacitación continua y el soporte técnico, dado que la percepción de insuficiencia en el apoyo institucional limita la efectividad del modelo.

Finalmente, la frontera de la predicción de demanda se ha expandido hacia el análisis de datos no estructurados externos. Li et al.[13] demostraron mediante modelos de ecuaciones estructurales que el comportamiento en redes sociales (eWOM) actúa como un indi-



cador adelantado de la inscripción, estableciendo un nuevo estándar para los sistemas de planificación modernos.

A modo de síntesis, la revisión crítica de la literatura permite constatar que la gestión de la oferta académica ha dejado de ser un problema logístico lineal para constituirse como un desafío multidimensional de ciencia de datos. La evidencia analizada demuestra que, si bien existen herramientas teóricas potentes desde los algoritmos de Random Forest validados por Shao et al.[6], hasta el análisis de grafos curriculares de Stavrinides y Zuev[11], su aplicación práctica enfrenta la necesidad de integrar variables heterogéneas que los modelos tradicionales ignoraban. Se concluye que el estado del arte actual exige el desarrollo de sistemas holísticos que no solo resuelvan la complejidad combinatoria definida por Abdipoor et al.[7], sino que incorporen simultáneamente las restricciones de infraestructura híbrida y los indicadores de demanda digital externa, cerrando así la brecha existente entre la capacidad computacional avanzada y la realidad operativa de las instituciones educativas.



3

Educación Superior y Modalidades

Contenido del Capítulo

3.1. Contexto Actual y Transformación Digital en la Educación Superior	13
3.1.1. Alineación estratégica con los Objetivos de Desarrollo Sostenible (ODS)	15
3.2. Modalidades educativas y su impacto en la gestión de recursos	15
3.2.1. Educación Presencial, Virtual e Híbrida	16
3.2.2. Requerimientos físicos y tecnológicos por modalidad	17
3.3. La gestión administrativa en los centros universitarios	18
3.3.1. Impacto Económico de la Planificación Académica	19
3.3.2. Complejidad Logística de la Asignación de Horarios	20

3.1. Contexto Actual y Transformación Digital en la Educación Superior

La educación superior contemporánea enfrenta una coyuntura crítica donde la tecnología ha dejado de ser una herramienta auxiliar para convertirse en el eje vertebrador de la operatividad institucional. En la última década, la gestión universitaria ha tenido que evolucionar forzosamente desde modelos tradicionales, caracterizados por la rigidez administrativa y la presencialidad exclusiva, hacia ecosistemas digitales dinámicos. Esta transición no responde únicamente a una tendencia de modernización, sino a una necesidad de supervivencia ante la masificación estudiantil y la exigencia de optimizar recursos limitados en un entorno globalizado que demanda inmediatez y precisión en la oferta académica.

En este escenario macro, la sostenibilidad institucional se ha vinculado indisolublemente con la capacidad de adaptación tecnológica. Shenkoya y Kim [10] analizaron el impacto de la Cuarta Revolución Industrial (4IR) en la educación, estableciendo que la fusión de tecnologías físicas, digitales y biológicas está desdibujando las fronteras tradicionales del campus. Según su investigación, la educación superior actúa como un motor crítico para el desarrollo sostenible, pero solo si logra integrar la transformación digital en sus procesos de “conocimiento abierto”. Los autores sostienen que las universidades que no alinean su gestión con estos principios de la 4IR corren el riesgo de obsolescencia, ya que la innovación tecnológica es ahora el principal conductor de la relevancia académica y social.

Sin embargo, esta integración tecnológica no ha estado exenta de fricciones estructurales. Guàrdia et al. [14] realizaron una revisión exhaustiva de tendencias, destacando que impactos inesperados, como la pandemia global, obligaron a gobiernos y universidades a re-examinar todos los componentes de los sistemas existentes. Su estudio revela que, aunque la migración a formatos en línea fue rápida, la calidad y la aceptación variaron enormemente. La investigación identificó que el desafío actual ya no es la conectividad, sino la eficiencia pedagógica y administrativa de estas tecnologías. Se detectó una necesidad urgente de pasar de la improvisación remota a una planificación estratégica que utilice la tecnología para mejorar las tasas de finalización y el aprendizaje real, superando la simple digitalización de contenidos.

La correlación entre la necesidad de reforma estructural y la sostenibilidad operativa es evidente al cruzar los hallazgos de Shenkoya y Kim [10] con la evaluación de tendencias de Guàrdia et al. [14]. Ambos estudios convergen en la premisa de que la educación superior no puede sostenerse bajo paradigmas analógicos en una era digital; mientras Guàrdia et al. [14] señalan que la falta de planificación tecnológica compromete la calidad y la retención, Shenkoya y Kim [10] advierten que esta carencia impide el desarrollo de un ecosistema de conocimiento abierto, concluyendo que la transformación digital es el único mecanismo viable para alinear la eficiencia administrativa con las demandas sociales contemporáneas.



Dentro de las herramientas tecnológicas disponibles para afrontar este reto, la Inteligencia Artificial (IA) ha emergido como el campo de mayor crecimiento y potencial disruptivo. Crompton y Burke [15] llevaron a cabo una revisión sistemática del estado del arte entre 2016 y 2022, hallando un crecimiento exponencial en la literatura científica: las publicaciones sobre IA en educación superior se duplicaron e incluso triplicaron en los años 2021 y 2022 en comparación con períodos anteriores. Un hallazgo clave de su estudio es el desplazamiento geopolítico de la innovación; mientras que históricamente Estados Unidos lideraba la investigación, China ha asumido el liderazgo en la producción de soluciones de IA educativa. Además, se evidenció que la mayor parte de esta tecnología se está aplicando en el nivel de pregrado, validando la pertinencia de enfocar los esfuerzos de optimización en este segmento demográfico masivo.

La aplicación de estas herramientas de IA ha permitido profundizar en la comprensión de las problemáticas estudiantiles con un nivel de detalle inédito. Al-Azzam y Al-Oudat [16] propusieron recientemente modelos basados en aprendizaje automático y Grandes Modelos de Lenguaje, Large Language Models (LLM) para clasificar y predecir desafíos académicos y psicológicos. Su investigación demuestra que la tecnología puede ir más allá de la gestión administrativa para identificar patrones de bienestar y rendimiento. Al utilizar algoritmos de clasificación, lograron detectar dificultades que tradicionalmente pasaban desapercibidas en la gestión manual, subrayando que la “salud” del sistema educativo depende de la capacidad de procesar datos complejos sobre el estado del estudiante, no solo sus calificaciones.

Finalmente, el perfil del estudiante moderno se ha transformado en un agente digital cuyas decisiones están fuertemente influenciadas por entornos no académicos. Li et al. [13] exploraron cómo la comunicación en redes sociales y la imagen de marca institucional determinan las intenciones de inscripción. Mediante un Modelo de Ecuaciones Estructurales, Structural Equation Modeling (SEM), comprobaron que el “Boca a Boca Electrónico” (eWOM) tiene un impacto positivo significativo sobre la percepción de la universidad. Esto implica que la planificación de la oferta académica ya no puede basarse únicamente en históricos internos; debe considerar que la demanda es volátil y sensible a la interacción digital. Los autores concluyen que la interactividad y la personalización en la comunicación son factores determinantes para captar y retener la matrícula en un mercado competitivo.

En síntesis, la convergencia de estos factores la imperativa de sostenibilidad de la 4IR, la reconfiguración post-pandemia, el auge de la IA generativa y predictiva, y la digitalización del comportamiento estudiantil configura un nuevo paradigma de gestión. La literatura analizada evidencia que las instituciones que carecen de sistemas inteligentes para procesar estas variables enfrentan una desventaja estratégica crítica. Por tanto, la optimización de la oferta académica no es un mero ejercicio logístico, sino una respuesta necesaria a un entorno donde la eficiencia administrativa y la satisfacción estudiantil dependen de la



capacidad de anticipación algorítmica.

3.1.1. Alineación estratégica con los Objetivos de Desarrollo Sostenible (ODS)

En el contexto de la educación superior contemporánea, se estableció que la modernización de los procesos de gestión administrativa debió responder a los lineamientos de la agenda global. Por consiguiente, la conceptualización del sistema de soporte a la decisión se alineó directamente con el Objetivo de Desarrollo Sostenible (ODS) 4, enfocado en garantizar una educación inclusiva, equitativa y de calidad. Se determinó que la optimización algorítmica de la oferta académica mitigó los cuellos de botella curriculares, asegurando un acceso ininterrumpido al plan de estudios para los estudiantes. Simultáneamente, el desarrollo de esta arquitectura de software impulsó el cumplimiento del ODS 9 (Industria, Innovación e Infraestructura), al transformar la infraestructura operativa tradicional de la institución mediante la adopción de inteligencia artificial y minería de datos[5].

Asimismo, la implementación de este modelo predictivo consolidó los principios de gobernanza exigidos por el ODS 16, el cual promueve la creación de instituciones eficaces, responsables y transparentes a todos los niveles. Se evidenció que la integración de algoritmos matemáticos en la planificación eliminó la arbitrariedad en la asignación de aulas, presupuestos y cargas docentes. Al fundamentar la toma de decisiones en inferencias estadísticas auditables y no en estimaciones empíricas, el sistema dotó a las autoridades académicas de una herramienta de gestión que garantizó la equidad y la justificación técnica de la oferta frente a la comunidad universitaria, redefiniendo el estándar de responsabilidad administrativa[5].

3.2. Modalidades educativas y su impacto en la gestión de recursos

La diversificación de las modalidades educativas ha transformado radicalmente la lógica de la gestión universitaria. Anteriormente, la administración de recursos se limitaba a una asignación lineal de espacios físicos; hoy, la coexistencia de modelos presenciales, virtuales e híbridos impone una matriz de gestión multidimensional. El impacto de esta transformación recae directamente sobre la eficiencia operativa: cada modalidad demanda una configuración específica de tiempo, espacio y tecnología. Ignorar estas diferencias en la planificación estratégica conduce a una subutilización de la infraestructura instalada y a una sobrecarga de los recursos digitales, creando “cuellos de botella” administrativos que frenan la calidad del servicio educativo.

En el análisis del contexto reciente, Iparraguirre Contreras et al. [17] realizaron una revisión sistemática sobre la educación superior post pandemia, identificando que la adopción de modalidades flexibles no fue acompañada de una reestructuración administrativa



equivalente. Su estudio determina que la gestión de la educación híbrida requiere “nuevas estrategias de enseñanza-aprendizaje” que impactan la logística institucional. La investigación revela que el intento de gestionar lo híbrido con las mismas reglas administrativas de lo presencial ha generado desorganización. Se concluye que el éxito del modelo no depende solo de la plataforma tecnológica, sino de la capacidad de la institución para reorganizar sus procesos de control y seguimiento académico en un entorno mixto.

Por otro lado, la gestión de recursos debe considerar las disparidades de acceso que cada modalidad exacerba. Pillajo Pila et al. [18] evaluaron el impacto del aprendizaje híbrido en América Latina, destacando que la efectividad de esta modalidad está condicionada por la infraestructura tecnológica del estudiante. Su estudio señala que, sin una gestión que asegure la equidad en el acceso a dispositivos y conectividad, la modalidad híbrida se convierte en un factor de segregación. Esto implica que la planificación de recursos universitarios no puede limitarse al campus; debe considerar si el “recurso virtual” es accesible para la demografía estudiantil, integrando variables socioeconómicas en la matriz de decisión académica.

La complejidad de gestionar múltiples modalidades se hace evidente al cruzar los hallazgos de Iparraguirre Contreras et al. [17] con los de Pillajo Pila et al. [18]. Mientras que el primer estudio [17] advierte sobre la sobrecarga administrativa derivada de la falta de procesos definidos para lo híbrido, el segundo [18] subraya que esta desorganización afecta desproporcionadamente a los estudiantes vulnerables. Ambos coinciden en que la “flexibilidad” prometida por las nuevas modalidades se convierte en inefficiencia operativa si no existe un sistema de gestión robusto. La conclusión conjunta es que la universidad moderna debe transitar de una administración estática a una gestión dinámica que sincronice los recursos físicos institucionales con las capacidades tecnológicas reales de su población estudiantil.

3.2.1. Educación Presencial, Virtual e Híbrida

La distinción operativa entre las modalidades es fundamental para la planificación. Rodríguez Caballero et al. [19] analizaron los retos específicos del modelo híbrido, diferenciándolo claramente de la educación a distancia tradicional. Según su investigación, la modalidad híbrida no es una suma simple de virtualidad y presencialidad, sino una integración que exige un nuevo perfil docente. El estudio indica que la falta de competencias digitales específicas para este entorno mixto genera inefficiencias; un docente puede ser excelente en lo presencial pero ineficaz gestionando la interacción simultánea virtual. Para la gestión de recursos, esto implica que la asignación de carga horaria debe filtrar al personal no solo por su conocimiento de la materia, sino por su certificación en la modalidad a impartir.

En la práctica, la ejecución de estas modalidades presenta fricciones operativas significativas. Guadalupe Beltrán et al. [9] aportaron evidencia empírica del año 2025 sobre la



docencia en la Universidad Estatal de Milagro. Su análisis cuantitativo reveló que, aunque el modelo es percibido como flexible por la mayoría, existe una minoría significativa (18 %) que reporta dificultades críticas relacionadas con la conectividad y la adaptación tecnológica. Este dato es crítico para la planificación académica: asignar cursos híbridos sin considerar el soporte técnico y la capacitación necesaria incrementa el riesgo de saturación y baja calidad educativa, sugiriendo que la asignación docente debe ponderar estas competencias tecnológicas.

La integración de las perspectivas de Rodríguez Caballero et al. [19] y Guadalupe Beltrán et al. [9] permite establecer una jerarquía de complejidad en la gestión de modalidades. Ambos estudios confirman que el modelo híbrido representa un desafío administrativo superior. Mientras Rodríguez Caballero et al. [19] enfatizan la brecha de formación pedagógica, Guadalupe Beltrán et al. [9] evidencian la percepción de sobrecarga administrativa y la necesidad de soporte. Para efectos de optimización de la oferta académica, esto significa que las modalidades no son variables intercambiables; cada una posee restricciones únicas de capital humano y tiempo que deben ser modeladas explícitamente.

3.2.2. Requerimientos físicos y tecnológicos por modalidad

La viabilidad de las modalidades presencial e híbrida depende intrínsecamente de las condiciones físicas del aula. Guadalupe Beltrán et al. [9] identificaron una barrera logística relevante: aproximadamente un tercio de los docentes encuestados (32 %) manifestó desacuerdo respecto a la adecuación de los recursos tecnológicos proporcionados por la universidad. Este hallazgo demuestra que la infraestructura actual, diseñada originalmente para un modelo presencial, enfrenta tensiones al soportar los requerimientos de transmisión simultánea. En términos de gestión, esto obliga a clasificar el inventario de aulas no solo por capacidad de aforo, sino por nivel de equipamiento tecnológico (Hardware readiness).

Frente a estas limitaciones físicas, el paradigma de Smart Campus ofrece una solución de gestión automatizada. Min-Allah y Alrashed [20] proponen que la administración de recursos físicos debe evolucionar hacia sistemas basados en el Internet de las Cosas (IoT). Según su análisis, un campus inteligente utiliza sensores para monitorear la ocupación y el consumo energético, permitiendo una asignación más eficiente de espacios. Para la modalidad presencial e híbrida, esto sugiere pasar de horarios estáticos a una programación que optimice el uso de laboratorios y aulas inteligentes, reduciendo el desperdicio de capacidad instalada.

Finalmente, la gestión de la modalidad virtual e híbrida impone requerimientos severos sobre la arquitectura de datos institucional. Kustitskaya et al. [21] establecen que la toma de decisiones basada en datos (Data-Driven Management) requiere bases de datos educativas diseñadas para capturar la complejidad del proceso de aprendizaje. Su investigación

advierte que los sistemas de gestión tradicionales suelen estar desconectados de las plataformas de aprendizaje, creando puntos ciegos sobre la actividad real. Para optimizar la oferta, es imperativo integrar estos flujos de información, permitiendo correlacionar la disponibilidad de infraestructura digital con la demanda real de cursos.

3.3. La gestión administrativa en los centros universitarios

La gestión administrativa en las instituciones de educación superior evolucionó desde una función meramente burocrática hacia un eje estratégico de competitividad y sostenibilidad. Anteriormente, la administración se limitaba al registro y control de expedientes; sin embargo, la masificación de la matrícula y la diversificación de modalidades impusieron la necesidad de optimizar procesos mediante la toma de decisiones basada en datos. Se identificó que la eficiencia operativa ya no depende únicamente de la capacidad financiera, sino de la agilidad para gestionar flujos de información complejos que interrelacionan la disponibilidad de infraestructura, la carga docente y la demanda estudiantil, transformando la administración universitaria en una ciencia de optimización de recursos finitos frente a necesidades.

En el análisis de la infraestructura de gestión, Gallegos Macías et al. [8] evaluaron la situación de los Sistemas de Información Estratégica (SIE) en el contexto universitario. Se determinó que, aunque las instituciones invirtieron significativamente en tecnologías de la información, su implementación enfrentó problemáticas estructurales que limitaron su impacto. Se observó que los sistemas funcionaron predominantemente como herramientas transaccionales para resolver problemas operativos diarios, careciendo de una integración real que permitiera la inteligencia de negocios. La investigación concluyó que la información generada se almacenó en silos, impidiendo a los directivos contar con datos consolidados y oportunos para la planificación a largo plazo, lo que perpetuó modelos de gestión reactivos.

Paralelamente a la problemática tecnológica, la medición del desempeño administrativo presentó desafíos metodológicos. Alvarez-Sánchez et al. [22] realizaron una revisión sistemática sobre la eficiencia en instituciones de educación superior, hallando una heterogeneidad marcada en los modelos de evaluación. Se identificó que la eficiencia administrativa se midió frecuentemente a través de métodos de frontera estocástica y Análisis Envolvente de Datos, Data Envelopment Analysis (DEA), considerando variables como el personal no académico y los gastos operativos como “inputs”. Sin embargo, el estudio reveló que la falta de estandarización en los indicadores de “output” dificultó la comparación y el benchmarking entre universidades, lo que generó una opacidad sobre qué procesos administrativos aportaron valor real a la calidad educativa y cuáles representaron un gasto burocrático ineficiente.

La correlación entre la precariedad de los sistemas de información y la baja eficiencia ad-



ministrativa se hizo evidente al contrastar los hallazgos de Gallegos Macías et al. [8] y Alvarez-Sánchez et al. [22]. Mientras el primer estudio [8] diagnosticó que la falta de cultura organizacional impidió el uso estratégico de los datos, el segundo [22] confirmó que esta carencia de datos estructurados imposibilitó la construcción de modelos de eficiencia robustos. Ambos autores coincidieron en que la gestión universitaria operó bajo una “ceguera estratégica”, donde los recursos se asignaron por inercia histórica y no por evidencia empírica. Se concluyó que la modernización administrativa requiere transitar de la simple digitalización de procesos a la implementación de sistemas inteligentes que vinculen los indicadores operativos con los objetivos de sostenibilidad financiera.

3.3.1. Impacto Económico de la Planificación Académica

Uno de los procesos críticos donde la ineficiencia administrativa impactó directamente el presupuesto fue la planificación de la matrícula. Shao et al. [6] analizaron la predicción de inscripción de cursos, estableciendo que la inexactitud en los pronósticos constituyó una fuente mayor de costos administrativos innecesarios. Se demostró que subestimar la demanda derivó en la apertura reactiva de secciones de último minuto, mientras que sobreestimarla resultó en la subutilización de espacios y personal docente. El estudio enfatizó que “pronosticar con precisión las tasas de inscripción” es la única vía para minimizar la carga burocrática tanto para estudiantes como para profesores, validando la necesidad de abandonar las estimaciones subjetivas en favor de modelos predictivos.

Para mitigar estos costos, se evaluó la eficacia de diferentes metodologías de predicción. Shao et al. [6] compararon el rendimiento de análisis de probabilidad condicional frente a algoritmos de aprendizaje automático como Random Forest y Árboles de Clasificación y Regresión, Classification and Regression Trees (CART). Se comprobó que los métodos de Aprendizaje Automático, Machine Learning (ML) superaron a las estadísticas tradicionales al capturar interacciones complejas entre variables demográficas y académicas. Específicamente, el modelo de Random Forest permitió identificar que variables como el “nivel de clase del estudiante” y su “Promedio de Calificaciones, Grade Point Average (GPA) acumulado” fueron determinantes para la inscripción, proporcionando a los administradores una herramienta de “importancia de variables” (variable importance) para refinar sus estrategias de oferta académica con base científica.

La gestión eficiente de la matrícula trascendió la mera logística de cupos para convertirse en un factor de viabilidad operativa. Alvarez-Sánchez et al. [22] señalaron en su revisión que el “personal académico” representa uno de los inputs más costosos en la función de producción universitaria. Por tanto, una planificación deficiente de la oferta académica, basada en predicciones erróneas como las descritas por Shao et al. [6], obligó a las instituciones a mantener una nómina docente ineficiente. Se concluyó que la optimización de los procesos administrativos de inscripción no solo mejoró la experiencia estudiantil, sino

que actuó como un mecanismo de control presupuestario, maximizando el retorno de la inversión en capital humano.

3.3.2. Complejidad Logística de la Asignación de Horarios

La materialización final de la gestión académica recae en la programación de horarios, una tarea que se identificó como el cuello de botella operativo más severo. Abdipoor et al. [7] definieron el Problema de Horarios de Cursos Universitarios, University Course Timetabling Problem (UCTP) como un problema de optimización combinatoria de clase NP-Hard. Se estableció que la dificultad administrativa radicó en asignar un conjunto de eventos a espacios y tiempos limitados bajo un gran número de restricciones. La investigación demostró que, a medida que aumentó el tamaño de la institución, el espacio de soluciones creció exponencialmente, haciendo humanamente imposible para los gestores encontrar una solución óptima sin incurrir en conflictos de aulas o docentes mediante métodos manuales.

La complejidad de esta gestión se vio agravada por la evolución de los requerimientos institucionales. Chen et al. [23] realizaron un estudio sobre las tendencias en el UCTP, clasificando las restricciones en “duras” y “blandas”. Se observó que la administración moderna ya no buscó solo satisfacer las restricciones duras (evitar choques de horarios), sino optimizar las blandas, como las preferencias de los profesores y la minimización de ventanas libres para los estudiantes. El estudio destacó que los enfoques administrativos tradicionales fallaron al intentar balancear estos objetivos contrapuestos, validando la necesidad de algoritmos que pudieran ponderar penalizaciones y buscar el bienestar de la comunidad universitaria más allá de la simple factibilidad operativa.

Finalmente, la revisión de la literatura técnica confirmó la obsolescencia de las herramientas de gestión convencionales para este propósito. Chen et al. [23] y Abdipoor et al. [7] coincidieron en que los métodos exactos de programación lineal resultaron computacionalmente costosos e imprácticos para instituciones de gran escala. Abdipoor et al. [7] argumentaron que las metaheurísticas (como algoritmos genéticos o de enjambre) se consolidaron como la única alternativa viable para la administración eficiente. Ambos estudios concluyeron que la gestión administrativa universitaria debe abandonar la pretensión de resolver el cronograma “a mano” o con hojas de cálculo, delegando esta complejidad combinatoria a sistemas inteligentes capaces de explorar el espacio de búsqueda de manera efectiva.



4

Planificación Académica y Distribución de Cargas

Contenido del Capítulo

4.1.	El proceso de programación de la oferta académica	22
4.2.	La Cadencia Académica y el flujo curricular	24
4.2.1.	Importancia de la secuencia de asignaturas	25
4.2.2.	Tiempos y ciclos de gestión académica	26
4.3.	Problemáticas en la distribución de secciones	26
4.3.1.	Subestimación de cupos y saturación	28
4.3.2.	Impacto de la mala distribución en el egreso estudiantil	28

4.1. El proceso de programación de la oferta académica

El proceso de programación de la oferta académica se transformó de una tarea administrativa rutinaria a un procedimiento estratégico de alta complejidad. Históricamente, la planificación se ejecutó mediante métodos manuales basados en la repetición de patrones históricos; sin embargo, la masificación de la matrícula y la diversificación curricular exigieron la adopción de modelos dinámicos. Se estableció que la programación eficiente no solo implicó asignar espacios y tiempos, sino sincronizar múltiples variables críticas disponibilidad docente, infraestructura física y demanda estudiantil en un sistema coherente que garantizara la operatividad institucional y la calidad del servicio educativo.

En el contexto de la modernización institucional, Yang [24] exploró la ruta de transformación digital en la gestión educativa universitaria. Su investigación cuantificó el impacto de digitalizar los procesos administrativos, determinando que la implementación de sistemas inteligentes redujo el tiempo dedicado a la gestión en un 30 %. Además, se observó una correlación directa entre la agilidad administrativa y la percepción de calidad; el estudio reportó un incremento del 25 % en la satisfacción estudiantil y una mejora del 20 % en las evaluaciones de calidad educativa. Estos hallazgos validaron que la optimización del proceso de programación no fue meramente una mejora técnica, sino un factor determinante para la eficiencia operativa global de la universidad.

A pesar de las ventajas de la digitalización, se identificó que la persistencia de métodos manuales constituyó la principal barrera para la eficiencia. Farinola y Assogba [25] analizaron la generación de horarios en instituciones de educación superior, señalando que la preparación manual resultó ser un proceso propenso a errores y extremadamente consumidor de tiempo. Se evidenció que los planificadores humanos, al enfrentarse a restricciones conflictivas (como la disponibilidad de aulas versus la preferencia docente), tendieron a producir soluciones subóptimas que requirieron ajustes continuos durante el periodo académico. La investigación concluyó que la automatización mediante inteligencia artificial fue necesaria para eliminar la redundancia y garantizar cronogramas libres de conflictos desde la primera iteración.

Para superar la subjetividad en la planificación, se recurrió a técnicas avanzadas de tratamiento de datos. Almaghrabi et al. [26] presentaron una sistematización del conocimiento (Systematization of Knowledge - SoK) sobre el impacto de la Minería de Datos Educativos, Educational Data Mining (EDM) en la administración organizacional. Se demostró que la aplicación de algoritmos de minería permitió transitar de una gestión basada en la intuición a una basada en evidencia. El estudio destacó que las técnicas de agrupamiento (*clustering*) y predicción facilitaron a los administradores la identificación de patrones ocultos en el comportamiento de matrícula, permitiendo ajustar la oferta académica a las necesidades reales de los estudiantes y optimizar la asignación de recursos antes del inicio del ciclo lectivo.



La operatividad del proceso de programación dependió críticamente de la interconexión entre plataformas heterogéneas. Pérez-Jorge et al. [27] evaluaron el impacto de las Interfaces de Programación de Aplicaciones (APIs) impulsadas por IA en la gestión de información educativa. Se estableció que la fragmentación de datos entre los Sistemas de Gestión del Aprendizaje, Learning Management Systems (LMS) y los sistemas administrativos (ERP) generó inconsistencias en la oferta académica. La investigación determinó que el uso de APIs inteligentes permitió un flujo de datos en tiempo real, facilitando que la programación de la oferta se alimentara automáticamente de los registros de rendimiento y prerequisitos estudiantiles, eliminando la necesidad de la captura manual de datos y reduciendo la latencia en la toma de decisiones.

La convergencia de la automatización y la integración de datos generó un impacto multi-dimensional en la institución. Al contrastar los hallazgos de Farinola y Assogba [25] con los de Yang [24], se observó que la implementación de generadores de horarios basados en IA no solo resolvió el problema logístico, sino que mejoró el clima organizacional. Mientras Farinola y Assogba [25] demostraron que la automatización eliminó los conflictos de horarios (choques de aulas o docentes), Yang [24] confirmó que esta eficiencia técnica se tradujo directamente en una mayor satisfacción de los involucrados. Ambos estudios coincidieron en que la tecnología liberó al personal administrativo de tareas repetitivas, permitiéndoles enfocarse en la gestión estratégica y la atención al estudiante.

Sin embargo, se reconoció que la automatización del proceso enfrentó un desafío matemático inherente. Retomando a Abdipoor et al. [7], se reiteró que el Problema de Horarios Universitarios (UCTP) pertenece a la clase de complejidad NP-Hard. En el contexto del proceso de programación, esto significó que buscar la “oferta académica perfecta” implicó explorar un espacio de soluciones que crecía exponencialmente con cada nueva asignatura o sección agregada. Se concluyó que los métodos de programación lineal tradicionales fueron insuficientes para manejar esta explosión combinatoria en tiempos razonables, validando la necesidad de incorporar metaheurísticas en el núcleo del motor de programación para obtener soluciones factibles en tiempos operativos viables.

La evolución del proceso de programación permitió incorporar la sostenibilidad financiera como una variable de control. Almaghrabi et al. [26] destacaron en su revisión que la minería de datos educativos facultó a las instituciones para predecir la asignación de recursos con alta precisión. Se observó que, al analizar los patrones históricos de inscripción y deserción, los algoritmos pudieron sugerir el número óptimo de secciones a abrir, evitando tanto la saturación de aulas como la subutilización de espacios. Esta capacidad predictiva transformó la programación de la oferta de un ejercicio reactivo a uno proactivo, alineando la disponibilidad académica con las restricciones presupuestarias y de infraestructura de la universidad.

Asimismo, el proceso de programación evolucionó hacia un enfoque centrado en el usu-



rio final. Pérez-Jorge et al. [27] argumentaron que la gestión de información impulsada por IA permitió personalizar la experiencia educativa. Se determinó que, mediante el análisis de las trayectorias académicas individuales accesibles a través de APIs, el sistema de programación pudo priorizar la apertura de asignaturas críticas para el egreso de cohortes específicas. Esto aseguró que la oferta académica no fuera estática, sino que se adaptara dinámicamente a las necesidades de avance curricular de los estudiantes, reduciendo los tiempos de graduación y mejorando los indicadores de eficiencia terminal.

En conclusión, la reingeniería del proceso de programación de la oferta académica se fundamentó en la integración de tres pilares tecnológicos: la minería de datos para la predicción de la demanda, las APIs para la interoperabilidad de sistemas y los algoritmos metaheurísticos para la resolución de conflictos. La evidencia analizada confirmó que la transición hacia este modelo automatizado fue indispensable para gestionar la complejidad de la educación superior moderna. Se estableció que solo mediante esta simbiosis tecnológica fue posible garantizar una oferta académica que fuera simultáneamente eficiente en costos, viable logísticamente y pertinente para las necesidades estudiantiles.

4.2. La Cadencia Académica y el flujo curricular

La cadencia académica se definió no solo como la cronología de los períodos lectivos, sino como la velocidad y fluidez con la que el estudiantado transitó a través de la malla curricular. Se identificó que el flujo curricular no fue un proceso lineal uniforme, sino un sistema dinámico propenso a interrupciones causadas por la falta de sincronización entre la oferta institucional y el avance real de los estudiantes. El análisis de esta variable fue determinante, pues se estableció que cualquier desajuste en la programación de asignaturas críticas generó un “efecto dominó”, alterando los tiempos de egreso y provocando la acumulación de matrícula en niveles inferiores, lo que saturó la capacidad operativa de la universidad. Para comprender la estructura subyacente de este flujo, se retomó el enfoque de Stavrinides y Zuev [11], quienes modelaron los planes de estudio mediante Redes de Prerrequisitos de Cursos (CPNs). Se analizó la malla curricular no como un listado, sino como un grafo dirigido acíclico donde los nodos representaron las asignaturas y los enlaces sus dependencias. La investigación determinó que la complejidad del flujo curricular residió en la “centralidad” de ciertos nodos; se demostró que ignorar la topología de la red al programar la oferta académica provocó bloqueos estructurales, impidiendo que los estudiantes avanzaran a pesar de tener cupos disponibles en materias no correlativas.

La gestión eficiente de este flujo requirió una infraestructura de datos robusta capaz de almacenar la trazabilidad histórica del estudiante. Amo et al. [28] propusieron una arquitectura de Almacén de Datos Educativos, Educational Data Warehouse (EDW) modular y basada en la nube para centralizar esta información dispersa. Se implementó un diseño que permitió la integración de datos provenientes de Sistemas de Gestión del Aprendizaje



(LMS) y sistemas administrativos, facilitando el análisis de grandes volúmenes de datos (Big Data). El estudio concluyó que contar con un repositorio unificado y seguro fue el prerequisito técnico indispensable para aplicar algoritmos de análisis sobre el progreso curricular, garantizando que la toma de decisiones se basara en la realidad histórica de los expedientes y no en proyecciones teóricas.

Complementariamente, se abordó la predicción del comportamiento estudiantil dentro de este flujo. Almalawi et al. [29] realizaron una revisión sistemática de modelos predictivos con fines educativos, identificando que el aprendizaje automático supervisado fue la técnica más eficaz para anticipar el rendimiento y la deserción. Se observó que los modelos predictivos permitieron identificar patrones de riesgo en etapas tempranas del flujo curricular, alertando a los gestores sobre qué estudiantes tenían alta probabilidad de reprobar o abandonar. Esta capacidad de anticipación fue clave para la planificación académica, pues permitió ajustar la oferta de cursos remediales o tutorías antes de que el flujo se interrumpiera definitivamente.

4.2.1. Importancia de la secuencia de asignaturas

La secuencia de asignaturas se identificó como la columna vertebral de la planificación académica, regida por una jerarquía estricta. Stavrinides y Zuev [11] introdujeron el concepto de “estratificación topológica” para clasificar las asignaturas según su nivel de profundidad y dependencia. Se determinó que violar esta secuencia natural por ejemplo, ofertar cupos en materias avanzadas sin garantizar la cobertura suficiente en sus prerequisitos generó inconsistencias académicas. El análisis de la red curricular reveló que ciertas asignaturas actuaron como “cuellos de botella” estructurales; su reprobación o falta de oferta detuvo el avance de cohortes enteras, validando la necesidad de priorizar estos cursos en la asignación de recursos.

La secuencia óptima no dependió únicamente de los prerequisitos formales, sino también de la capacidad del estudiante para gestionar su carga cognitiva. Bhosale y Hore [30] desarrollaron un motor de asignación de tiempo basado en IA que consideró la “asignación inteligente del tiempo de estudio”. Aunque su enfoque se centró en la planificación personal del alumno, su modelo demostró que el éxito académico depende de equilibrar la carga de trabajo en función de la disponibilidad real. Esto sugiere que la oferta académica no debe estructurarse solo por bloques administrativos rígidos, sino considerar heurísticas que eviten la combinación inviable de múltiples asignaturas de alta complejidad en un mismo ciclo temporal.

La interrelación entre la estructura secuencial del currículo y el riesgo de fracaso escolar fue validada al cruzar los hallazgos de Stavrinides y Zuev [11] con los de Almalawi et al. [29]. Mientras que el análisis topológico de Stavrinides y Zuev [11] permitió identificar qué asignaturas eran críticas para mantener la conectividad del grafo curricular, los mo-

delos predictivos revisados por Almalawi et al. [29] cuantificaron la probabilidad de que un estudiante fallara en dichos nodos críticos basándose en su historial. Ambos estudios coincidieron en que la gestión de la oferta académica debió focalizarse en los puntos de intersección entre la alta complejidad estructural y el alto riesgo predictivo, asegurando que la secuencia de asignaturas no se convirtiera en un filtro excluyente sino en un camino transitable.

4.2.2. Tiempos y ciclos de gestión académica

Los tiempos de dedicación académica dejaron de ser variables estáticas para adaptarse a las necesidades del estudiante moderno. Bhosale y Hore [30] propusieron un enfoque de planificación centrado en la gestión del tiempo personal, donde el sistema generó horarios de estudio y recordatorios basándose en la disponibilidad real del usuario mediante almacenamiento local y reglas heurísticas. Este enfoque evidenció que alinear las exigencias académicas con la disponibilidad temporal del estudiante redujo la ansiedad y mejoró la organización personal, contrastando con los modelos tradicionales que asumen una disponibilidad ilimitada del alumnado.

La gestión de los datos durante los ciclos académicos implicó el procesamiento masivo de información sensible. Amo et al. [28] enfatizaron la importancia de la privacidad y la seguridad en la arquitectura del almacén de datos. Se diseñó un sistema que incorporó técnicas de anonimización y encriptación para proteger la identidad estudiantil mientras se analizaban sus patrones de actividad. El estudio determinó que garantizar la integridad y confidencialidad de los datos fue fundamental para mantener la confianza institucional y cumplir con las normativas éticas (como Reglamento General de Protección de Datos, General Data Protection Regulation (GDPR)) al procesar información para la toma de decisiones.

Finalmente, la definición de la oferta requirió integrar la probabilidad de éxito en la ecuación de planificación. Retomando la revisión de Almalawi et al. [29], se destacó que los algoritmos de clasificación (como Random Forest y Naive Bayes) permitieron prever el rendimiento estudiantil con alta precisión. La integración de estas predicciones en la gestión académica facultó a la institución para anticipar la demanda de recursos de apoyo en períodos específicos, distribuyendo la carga docente y de tutorías de manera proactiva para mitigar las tasas de deserción detectadas por los modelos.

4.3. Problemáticas en la distribución de secciones

La distribución de secciones se identificó como el punto crítico donde la planificación estratégica convergió con la realidad operativa. Una vez definida la oferta académica macro, el desafío administrativo consistió en determinar la cantidad exacta de paralelos (grupos)



necesarios para cada asignatura. Se observó que este proceso fue vulnerable a sesgos históricos; la repetición inercial de la programación de años anteriores, sin considerar las variaciones estocásticas de la demanda actual, derivó frecuentemente en desequilibrios estructurales. La ineficiencia en esta etapa no solo generó conflictos logísticos, sino que comprometió la calidad educativa al forzar la apertura de cursos sobre poblados o, inversamente, diluir los recursos docentes en secciones con baja rentabilidad social.

En el intento de racionalizar esta distribución, Pauta Riera et al. [31] realizaron un estudio comparativo en la Universidad Católica de Cuenca sobre el uso de modelos de regresión para pronosticar la demanda estudiantil. Se aplicaron modelos lineales, logarítmicos y polinómicos para predecir la matrícula en carreras de ingeniería. La investigación determinó que, si bien los modelos estadísticos clásicos ofrecieron una aproximación inicial, los modelos lineales tendieron a simplificar excesivamente el comportamiento de la matrícula, presentando coeficientes de determinación (R^2) inferiores a los modelos polinómicos (0,96). Se concluyó que confiar exclusivamente en proyecciones lineales para la distribución de secciones condujo a errores de subestimación en períodos de crecimiento acelerado, resultando en una falta de cobertura para la demanda real.

La inexactitud en la predicción de la cantidad de estudiantes tuvo repercusiones directas en la eficiencia administrativa. Retomando a Shao et al. [6], se estableció que la incapacidad para pronosticar las tasas de inscripción con precisión generó costos operativos innecesarios y una carga administrativa adicional. Se evidenció que cuando la distribución de secciones se basó en estimaciones incorrectas, la administración se vio obligada a realizar ajustes reactivos de “último minuto”, como la contratación emergente de docentes o la reasignación forzada de aulas. El estudio enfatizó que minimizar el error de predicción fue fundamental para asignar los recursos apropiados asientos, espacio de laboratorio y auxiliares—antes del inicio del ciclo, evitando la improvisación logística.

Finalmente, la problemática de distribución trascendió lo administrativo para afectar la permanencia estudiantil. Shilbayeh y Abonamah [12] desarrollaron modelos predictivos para identificar patrones de deserción, demostrando que el abandono estudiantil no es un evento aleatorio, sino un fenómeno predecible vinculado a variables demográficas y financieras específicas. Su investigación reveló que ciertos perfiles estudiantiles presentan un riesgo de deserción inherente más alto, lo que implica que la distribución de secciones no debe ser uniforme. Por tanto, se determinó que la planificación de cupos debe priorizar estratégicamente a estos grupos vulnerables, asegurando que la disponibilidad de horarios no se convierta en una barrera adicional para estudiantes que ya enfrentan desafíos socioeconómicos.

4.3.1. Subestimación de cupos y saturación

La subestimación de la demanda real en la planificación de cupos derivó en el fenómeno de “saturación áulica”. Pauta Riera et al. [31] evidenciaron que la falta de herramientas predictivas robustas provocó que la infraestructura física se viera rebasada por la matrícula efectiva. En su análisis de la Unidad Académica de Ingeniería, se detectó que la discrepancia entre las plazas ofertadas (basadas en históricos estáticos) y la demanda real generó sobre población en las aulas. Esta saturación no solo contravino las normas pedagógicas de ratio estudiante/docente, sino que obligó a la institución a improvisar desdobles de grupos sin la planificación de infraestructura adecuada, comprometiendo la calidad del proceso de enseñanza-aprendizaje.

Para corregir esta subestimación, fue necesario identificar qué variables determinaban realmente la ocupación de un curso. Shao et al. [6] aplicaron métricas de “importancia de variables” (*variable importance*) derivadas de algoritmos de Random Forest, descubriendo factores que los métodos tradicionales ignoraban. Se determinó que variables como la “especialidad del estudiante” (*major*) y su “nivel de clase” (*freshman, sophomore, etc.*) tuvieron un peso predictivo superior al historial simple de inscripciones pasadas. El estudio concluyó que la subestimación de cupos ocurrió frecuentemente porque los planificadores humanos no lograron ponderar las interacciones no lineales entre estas variables demográficas y académicas, asumiendo erróneamente una demanda homogénea.

La superioridad de los enfoques avanzados para mitigar la saturación se confirmó al contrastar los resultados de Pauta Riera et al. [31] con los de Shao et al. [6]. Mientras que Pauta Riera et al. [31] lograron mejorar el ajuste de la oferta mediante modelos de regresión polinómica ($R^2 \approx 0,96$), Shao et al. [6] demostraron que los métodos de aprendizaje automático (Random Forest) redujeron aún más el Raíz del Error Cuadrático Medio, Root Mean Square Error (RMSE) al manejar datos complejos y ruidosos. Ambos estudios coincidieron en que la planificación manual o basada en promedios simples fue sistemáticamente deficiente para anticipar picos de demanda. Se estableció que la única vía para evitar la subestimación de cupos y la consecuente saturación fue la adopción de modelos matemáticos no lineales capaces de simular el comportamiento de inscripción con alta fidelidad.

4.3.2. Impacto de la mala distribución en el egreso estudiantil

La correlación entre la disponibilidad de cursos y la deserción universitaria se analizó sistemáticamente en la literatura reciente. Quimiz-Moreira et al. [32] realizaron una revisión sistemática (2012-2024) sobre los factores de deserción universitaria, clasificándolos en dimensiones individuales, académicas e institucionales. Se identificó que, dentro de los factores institucionales, la gestión ineficiente de la oferta académica jugó un rol preponderante. El estudio reveló que la incapacidad de la institución para proveer una ruta cu-



rricular fluida debido a la mala distribución de secciones o horarios conflictivos— actuó como un detonante para el abandono, especialmente en estudiantes que ya presentaban vulnerabilidad académica. Se concluyó que la predicción de la deserción debió integrar variables de gestión institucional y no culpar únicamente al rendimiento del estudiante. Más allá de los factores macro, la experiencia diaria del estudiante con los servicios universitarios resultó ser un predictor crítico. Matz et al. [33] investigaron la retención estudiantil integrando datos de nivel “meso”, que capturaron la interacción del estudiante con el entorno universitario a través de aplicaciones móviles y sistemas. Se descubrió que la falta de compromiso (*engagement*) con los servicios institucionales evidenciada por una baja frecuencia de interacción digital— fue una señal temprana de alerta. El modelo de Random Forest utilizado demostró que combinar datos demográficos con métricas de comportamiento (como el uso de la app universitaria) mejoró significativamente la predicción de la retención. Esto sugirió que una distribución de secciones que no fomente la interacción constante del estudiante con su entorno académico debilita su sentido de pertenencia y precipita su salida.

Finalmente, se estableció la necesidad de utilizar la distribución de secciones como una herramienta de intervención preventiva. Shilbayeh y Abonamah [12] propusieron un enfoque donde la identificación de estudiantes en riesgo de deserción informara la planificación académica. Al utilizar algoritmos para clasificar a los estudiantes según su probabilidad de abandono, la institución pudo priorizar la asignación de cupos en secciones críticas para estos perfiles vulnerables. Se determinó que una distribución “inteligente” no solo buscó llenar aulas, sino garantizar que los estudiantes con mayor riesgo de *attrition* tuvieran acceso garantizado a los cursos necesarios para mantener su progreso, transformando la gestión de horarios en un mecanismo activo de retención y éxito estudiantil.

5

Inteligencia Artificial y Gestión de Datos

Contenido del Capítulo

5.1.	Inteligencia Artificial aplicada a la gestión administrativa	31
5.2.	Minería de Datos Educativa (EDM) y Big Data	33
5.3.	Ciclo de vida de los datos: Adquisición y Preparación	35
5.4.	Aprendizaje Automático	36
5.4.1.	Conceptos clave: Entrenamiento, Pruebas y Validación	37
5.4.2.	Algoritmos de Regresión	38
5.4.3.	Algoritmos de Clasificación	38
5.5.	Métricas de evaluación y validación de modelos	40
5.6.	Interfaz de Programación de Aplicaciones y consumo de datos .	41

5.1. Inteligencia Artificial aplicada a la gestión administrativa

La gestión administrativa en las instituciones de educación superior experimentó una reconfiguración fundamental, transitando de modelos operativos tradicionales a ecosistemas digitales de apoyo a la decisión. Se identificó que la mera digitalización de documentos resultó insuficiente para responder a la complejidad del entorno actual; por tanto, se requirió el diseño de sistemas capaces de procesar información y proponer escenarios estratégicos. En este nuevo paradigma, la Inteligencia Artificial (IA) se posicionó no como un ente autónomo de ejecución, sino como una herramienta de consultoría avanzada (*Decision Support System*) que permitió a los gestores anticipar demandas y evaluar opciones de distribución de recursos con una precisión inalcanzable mediante métodos manuales.

El impulso hacia esta transformación tecnológica se vinculó directamente con crisis globales que expusieron la fragilidad de los sistemas analógicos. García-Morales et al. [34] examinaron la transformación de la educación superior tras la disruptión del Enfermedad por Coronavirus 2019, Coronavirus Disease 2019 (COVID-19), determinando que las instituciones se vieron forzadas a realizar una transición abrupta hacia entornos digitales. Se observó que este cambio no planificado reveló carencias críticas en la capacidad de respuesta administrativa. El estudio concluyó que la sostenibilidad universitaria dependió de transformar estos mecanismos de emergencia en estrategias digitales integrales, donde la tecnología sirvió para estructurar la información caótica y presentarla de manera coherente para la toma de decisiones humanas.

En respuesta a esta necesidad de evolución, se consolidó el modelo de gestión estratégica asistida por datos. George y Wooden [35] analizaron la adopción de la IA bajo el marco de las “Universidades Inteligentes” (*Smart Universities*). Se estableció que la integración de tecnologías avanzadas permitió remodelar los procesos administrativos, moviendo a la institución de una postura reactiva a una predictiva. Los autores argumentaron que la gestión moderna implicó el uso de algoritmos para sugerir escenarios de personalización y asignación de activos, dotando a los directivos de un “tablero de control” inteligente que facilitó la elección de la estrategia más adecuada frente a la incertidumbre del mercado educativo.

La aplicación práctica de estas tecnologías demostró beneficios tangibles en la operatividad diaria como herramienta de asistencia. Cisneros Zumba et al. [36] evaluaron el uso de la IA en la gestión académica y administrativa para el fortalecimiento institucional. Se determinó que la implementación de asistentes algorítmicos optimizó tiempos y recursos, al encargarse del procesamiento masivo de datos y presentar resultados depurados. La investigación destacó que estas herramientas liberaron al capital humano de tareas repetitivas, permitiendo a los administradores enfocar su criterio en la evaluación cualitativa de los reportes generados y en la gobernanza transparente de la institución.

La incorporación técnica de la IA en la estructura organizacional se canalizó a través de los

Sistemas de Soporte a la Decisión (DSS). Shwedeh [37] investigó la integración de la IA en los DSS dentro de instituciones de educación superior, utilizando la Teoría de Difusión de Innovaciones. Se comprobó que la eficacia del sistema de recomendación dependió de factores como la calidad de los datos y la preparación organizacional. El estudio reveló que, una vez superada la barrera de complejidad inicial, la IA potenció la capacidad analítica de los directivos, proporcionando evaluaciones de riesgo y proyecciones que sirvieron como base fundamental para resolver problemas no estructurados de planificación académica.

Sin embargo, se identificó que la tecnología de soporte resultó insuficiente sin una base de conocimiento estructurada. Abed Alshadoodee et al. [38] exploraron el rol de la IA en la mejora de los DSS administrativos dependiendo de la Gestión del Conocimiento, Knowledge Management (KM). Se demostró que la función principal de la IA fue transformar datos brutos en conocimiento institucional accionable para el usuario final. Los autores concluyeron que los algoritmos de inteligencia de negocios requirieron alimentarse de un repositorio de conocimiento organizacional bien curado para ofrecer recomendaciones válidas, vinculando así la utilidad de la sugerencia algorítmica con la madurez de la gestión del conocimiento de la institución.

Al contrastar las perspectivas de Shwedeh [37] y Abed Alshadoodee et al. [38], se evidenció una interdependencia crítica para el diseño de la solución de asistencia. Mientras Shwedeh [37] enfatizó la importancia de la infraestructura tecnológica y la preparación organizacional como prerequisitos para la adopción de DSS inteligentes, Abed Alshadoodee et al. [38] establecieron que dicha infraestructura careció de valor estratégico si no se sustentó en procesos de Gestión del Conocimiento. Ambos estudios coincidieron en que el éxito de la IA administrativa no residió en la autonomía del algoritmo, sino en la integración sistemática donde la máquina procesó la complejidad estadística y el humano aplicó el conocimiento contextual para validar la decisión final.

Previo al despliegue técnico del sistema de soporte, se abordó la dimensión normativa y ética del uso de datos. Kaşarcı et al. [39] realizaron una revisión sistemática sobre la ética de la IA en la educación superior, detectando una brecha significativa entre la adopción tecnológica y la capacidad institucional para gestionarla. Se identificó que la mayoría de las respuestas institucionales fueron reactivas; por tanto, el estudio subrayó la urgencia de establecer políticas proactivas de gobernanza. Se determinó que el sistema debía operar bajo reglas claras donde la IA funcionara como un auditor de datos y generador de alertas, pero nunca como un juez final, mitigando así los riesgos legales asociados a la automatización total.

La viabilidad de la implementación también dependió de la aceptación cultural por parte de la comunidad educativa hacia la asistencia algorítmica. Rivera y Oseña [40] exploraron las percepciones éticas sobre el uso de la IA y la integridad académica. Se observó que, aunque existió un reconocimiento de los beneficios de eficiencia, persistió una preocupación



ción sobre el sesgo en las recomendaciones algorítmicas. La investigación determinó que la confianza en el sistema se correlacionó con la transparencia; por tanto, se estableció que la solución debió incluir mecanismos de explicabilidad (*Explainable AI*) que permitieran al jefe de carrera entender el “porqué” de cada sugerencia antes de aprobarla.

En síntesis, la fundamentación teórica de la solución propuesta se cimentó en la convergencia de la eficiencia operativa y la responsabilidad humana supervisada. Se determinó que la aplicación de la IA a la gestión administrativa constituyó una optimización del proceso de toma de decisiones, soportada por Sistemas de Soporte a la Decisión (DSS) que transformaron datos en conocimiento. Una vez establecido el marco de gobernanza y definido el rol de la IA como un asistente consultivo, se procedió a abordar el componente técnico subyacente: la infraestructura de datos masivos necesaria para alimentar este motor de inteligencia.

5.2. Minería de Datos Educativa (EDM) y Big Data

La implementación de un sistema de asesoría basado en inteligencia artificial requirió el establecimiento previo de una arquitectura de datos masivos (*Big Data*) robusta y escalable. Se determinó que la capacidad del sistema para ofrecer recomendaciones estratégicas al jefe de carrera no dependía únicamente de la sofisticación algorítmica, sino de la integridad y disponibilidad de los volúmenes de información histórica. Por tanto, se definió un marco de trabajo que integró la recolección, almacenamiento y procesamiento de datos heterogéneos, trascendiendo el simple reporte estadístico para constituir un ecosistema de Minería de Datos Educativos (EDM) capaz de alimentar modelos predictivos en tiempo real.

Para fundamentar esta arquitectura, se analizó el estado del arte global en la integración de tecnologías analíticas. Thayyib et al. [41] realizaron un estudio bibliométrico exhaustivo sobre la convergencia entre Inteligencia Artificial y Analítica de Big Data, Big Data Analytics (BDA) en diversos dominios. Se identificó que la tendencia actual se alejó de las soluciones aisladas para adoptar enfoques unificados donde el BDA gestionó el volumen, la velocidad y la variedad de los datos, mientras que la IA aportó la capa cognitiva. El estudio concluyó que las arquitecturas exitosas fueron aquellas que lograron orquestar estos dos componentes para transformar datos crudos en “inteligencia accionable”, validando así el diseño de una plataforma híbrida para la gestión universitaria.

Específicamente en el ámbito de la gestión, se adoptó el marco de referencia de la Minería de Datos Educativos (EDM) orientada a la administración. Almaghrabi et al. [26] sistematizaron el conocimiento (SoK) sobre el impacto de la EDM en la administración organizacional, definiéndola como el proceso de descubrir patrones ocultos en grandes conjuntos de datos educativos para optimizar la toma de decisiones. Se estableció que, a diferencia de la EDM pedagógica (centrada en el aprendizaje), la EDM administrativa se



enfocó en variables de eficiencia operativa y asignación de recursos. La investigación determinó que la aplicación de estas técnicas permitió a las organizaciones transitar de una administración basada en la intuición a una gestión basada en evidencia empírica robusta.

La materialización de estos conceptos se proyectó sobre los Sistema de Gestión de Información, Information Management System (IMS) universitarios existentes. Zhang et al. [42] exploraron las aplicaciones de minería de datos en el desarrollo de IMS, proponiendo el uso de algoritmos de asociación y clasificación integrados directamente en la base de datos institucional. Se implementó una lógica de extracción donde los datos de matrícula, rendimiento y asistencia no se analizaron de forma aislada, sino como componentes interconectados de un sistema complejo. El estudio demostró que integrar la minería de datos en el núcleo del IMS permitió detectar correlaciones no evidentes como la relación entre la carga horaria y la deserción, proporcionando insumos críticos para la planificación académica.

Para el procesamiento técnico de los datos, se adaptó un flujo de trabajo (pipeline) de analítica avanzado. Aunque originalmente diseñado para la automatización de edificios, Himeur et al. [43] definieron una arquitectura de “AI-big data analytics pipeline” cuya estructura modular de adquisición, preprocesamiento, capa de análisis y capa de decisión resultó plenamente transferible al contexto educativo. Se adoptó este esquema para garantizar que el flujo de datos desde la captura de registros históricos hasta la generación de la sugerencia siguiera un proceso estandarizado de limpieza y normalización. Se determinó que este enfoque ingenieril fue indispensable para manejar la heterogeneidad de las fuentes de datos universitarias, asegurando que el modelo de IA recibiera información depurada y consistente.

La arquitectura técnica se alineó con las necesidades estratégicas de los tomadores de decisiones. Rabelo et al. [44] aportaron la “perspectiva gerencial” de la minería de datos y la analítica de aprendizaje, enfatizando que la recolección de datos debía estar subordinada a objetivos de efectividad institucional. Se estableció que el sistema no debía abrumar al jefe de carrera con métricas crudas, sino presentar indicadores sintetizados que facilitaran la evaluación de la eficiencia del plan de estudios. El estudio concluyó que el éxito de la implementación dependió de la capacidad del sistema para traducir la complejidad del *Big Data* en tableros de control intuitivos que respaldaran la gestión estratégica.

Finalmente, la validación del marco de trabajo de datos masivos se fundamentó en la intersección entre la capacidad operativa y la utilidad estratégica. Al integrar los postulados de Almaghrabi et al. [26] con la visión de Rabelo et al. [44], se consolidó un modelo donde la robustez técnica sirvió a la claridad administrativa. Mientras Almaghrabi et al. [26] detallaron cómo la EDM podía descubrir ineficiencias ocultas en la administración organizacional, Rabelo et al. [44] definieron cómo presentar esos hallazgos para que fueran “gerencialmente consumibles”. Ambos estudios coincidieron en que el *Big Data* educativo



debía funcionar como un puente entre la realidad operativa de los registros académicos y la visión estratégica de la dirección, justificando así la inversión en infraestructura de datos como un activo de inteligencia institucional.

5.3. Ciclo de vida de los datos: Adquisición y Preparación

El ciclo de vida de los datos se concibió como un proceso de ingeniería sistemático, diseñado para transformar la heterogeneidad de los registros académicos en activos de información estructurada aptos para el modelado algorítmico. Se estableció que la calidad de las predicciones de la inteligencia artificial dependía intrínsecamente de la higiene de los datos de entrada; por tanto, se implementó una arquitectura de tuberías de datos (pipelines) que estandarizó las fases de Extracción, Transformación y Carga; Extract, Transform, Load (ETL). Este enfoque permitió transitar de una manipulación manual y fragmentada a un flujo automatizado, garantizando que el sistema de soporte a la decisión se alimentara de información veraz, consistente y actualizada en tiempo real.

Para la orquestación de este flujo, se adoptó el paradigma de pipelines ETL escalables orientados a la inteligencia de negocios. Mahmud e Iqbal [45] realizaron un estudio comparativo sobre herramientas de integración de datos, determinando que los pipelines modernos actúan como la columna vertebral de cualquier sistema de inteligencia escalable. Se definió una arquitectura donde la extracción no se limitó a copiar datos, sino que integró conectores para múltiples fuentes (ERP, LMS); posteriormente, la fase de transformación aplicó reglas de negocio para normalizar formatos dispares. El estudio concluyó que el uso de herramientas ETL dedicadas fue superior a los scripts ad-hoc, pues garantizó la trazabilidad del dato y facilitó la gobernanza en entornos de alto volumen transaccional.

La fase de carga (Load) se dirigió hacia un esquema de base de datos relacional optimizado para el análisis educativo. Retomando el modelo de Kustitskaya et al. [21], se diseñó una estructura de datos que reflejó la complejidad de los procesos universitarios. Se implementaron tablas dimensionales para estudiantes, asignaturas y docentes, vinculadas a tablas de hechos que registraron eventos académicos (calificaciones, asistencias). Esta estructuración permitió que los datos, una vez procesados por el ETL, residieran en un formato que facilitaba las consultas analíticas complejas, asegurando que el motor de IA pudiera acceder rápidamente a las relaciones históricas entre el rendimiento estudiantil y la carga académica sin latencia excesiva.

La operatividad continua del sistema se aseguró mediante la automatización integral de estos procesos. Ravi [46] analizó la evolución de la integración de datos, destacando que los sistemas ETL tradicionales enfrentaban limitaciones de velocidad y escalabilidad que solo la automatización podía resolver. Se implementaron mecanismos de triggers (disparadores) y programación por lotes (*batch processing*) que ejecutaron las tareas de limpieza y carga sin intervención humana. La investigación determinó que esta automatización fue



crítica para la toma de decisiones en tiempo real, ya que redujo drásticamente el tiempo de latencia entre la generación del dato académico y su disponibilidad para los algoritmos predictivos.

Una vez centralizados los datos, se procedió a una etapa de preparación específica para los modelos de decisión. Bas et al. [47] propusieron metodologías de preprocesamiento para sistemas de soporte a la decisión multicriterio, enfatizando la necesidad de normalizar las variables para hacerlas comparables. Se aplicaron técnicas de estandarización a los indicadores numéricos (como promedios de notas o tasas de ocupación) para eliminar sesgos derivados de las diferentes escalas de medición. El estudio validó que esta preparación rigurosa fue indispensable para definir “grupos de control” y perfiles comparables, asegurando que el sistema de IA no ponderara erróneamente una variable simplemente por tener una magnitud numérica mayor.

Para optimizar el rendimiento de los modelos predictivos, se implementó una estrategia de reducción de dimensionalidad y limpieza de ruido. Awad y Fraihat [48] demostraron la eficacia de Eliminación Recursiva de Características, Recursive Feature Elimination (RFE) combinada con validación cruzada para seleccionar los atributos más relevantes. Se aplicó este algoritmo para filtrar variables redundantes o irrelevantes del conjunto de datos educativo, reteniendo únicamente aquellas que aportaban valor predictivo real (como el historial de reprobación o la carga horaria previa). La investigación concluyó que el uso de RFE no solo redujo el costo computacional del entrenamiento, sino que mejoró la precisión de los clasificadores al eliminar el “ruido” estadístico.

La integración de una arquitectura ETL robusta con técnicas avanzadas de selección de características consolidó el marco de ingeniería de datos del proyecto. Al contrastar los hallazgos de Mahmud e Ikbal [45] con la metodología de Ravi [46], se evidenció que la sostenibilidad del sistema dependió de su capacidad para escalar automáticamente ante el crecimiento del volumen de datos históricos. Mientras Mahmud e Ikbal [45] proveyeron el diseño estructural para la integración de fuentes heterogéneas, Ravi [46] aportó la lógica de automatización necesaria para el mantenimiento del flujo. Esta convergencia garantizó que el motor de inferencia recibiera un suministro constante de datos de alta calidad, procesados eficientemente para respaldar la toma de decisiones estratégicas.

5.4. Aprendizaje Automático

El Aprendizaje Automático (*Machine Learning*) se estableció como el motor computacional central del sistema propuesto, permitiendo la transición de una programación académica estática a una dinámica. A diferencia de los algoritmos deterministas tradicionales, que siguen reglas fijas, se implementaron modelos capaces de aprender patrones complejos a partir de datos históricos de matrícula y rendimiento. Se definió que la función de estos algoritmos no sería reemplazar el criterio humano, sino potenciarlo mediante la detección



de tendencias no lineales en la demanda estudiantil, facilitando una personalización de la oferta que hubiera sido inabarcable mediante el cálculo manual.

La aplicación de estas técnicas se alineó con las tendencias más recientes en la educación superior. Peng y Li [49] realizaron una revisión sistemática de artículos líderes sobre inteligencia artificial, identificando un cambio de paradigma hacia el aprendizaje personalizado. Se observó que los algoritmos de aprendizaje automático permitieron adaptar los recursos educativos a las necesidades individuales de los estudiantes, prediciendo rutas de éxito y riesgos de deserción. El estudio concluyó que la integración de modelos predictivos en la gestión institucional fue el factor diferenciador que permitió a las universidades modernas ofrecer trayectorias curriculares flexibles y centradas en el estudiante, validando así la pertinencia técnica del enfoque propuesto.

5.4.1. Conceptos clave: Entrenamiento, Pruebas y Validación

La fiabilidad de los modelos predictivos se fundamentó en una metodología rigurosa de entrenamiento y validación. Se determinó que el simple ajuste de un algoritmo a los datos disponibles no garantizaba su capacidad de generalización ante futuros escenarios de matrícula; por tanto, se establecieron protocolos estrictos de separación de datos. El proceso de entrenamiento implicó la partición del conjunto de datos en subconjuntos de aprendizaje y prueba, asegurando que el modelo fuera evaluado con información que no había “visto” previamente, mitigando así el riesgo de sobreajuste (*overfitting*) y garantizando predicciones robustas en el entorno real.

Para asegurar la estabilidad de las métricas de rendimiento, se implementó la estrategia de validación cruzada. Sweet et al. [50] demostraron que la elección de la estrategia de validación impacta significativamente en la interpretación del desempeño del modelo, especialmente en datos con correlaciones espaciales o temporales. Se adoptó un enfoque de validación cruzada (como *k-fold*) que permitió evaluar el modelo en múltiples particiones de los datos históricos. La investigación estableció que esta técnica fue indispensable para obtener una estimación insesgada del error de predicción, evitando que resultados aparentemente exitosos fueran producto de una partición de datos afortunada o aleatoria. La maximización de la precisión del modelo requirió un ajuste fino de sus configuraciones internas, conocido como optimización de hiperparámetros. Al integrar la metodología de Sweet et al. [50] con el enfoque de El-Shahat et al. [51], se configuró un flujo de trabajo robusto. Mientras Sweet et al. [50] proveyeron el marco de validación para evaluar cada configuración, El-Shahat et al. [51] validaron el uso de la Búsqueda en Cuadrícula (*Grid Search*) combinada con validación cruzada (Búsqueda en Cuadrícula con Validación Cruzada, *Grid Search Cross-Validation (GSCV)*) para encontrar la combinación óptima de parámetros. Ambos estudios coincidieron en que la aplicación sistemática de GSCV permitió explorar exhaustivamente el espacio de búsqueda del algoritmo, garantizando que



el modelo final operara en su punto de máximo rendimiento matemático.

5.4.2. Algoritmos de Regresión

Para la predicción de la demanda de cupos, se seleccionaron algoritmos de regresión debido a la naturaleza cuantitativa de la variable objetivo. Se analizó que la estimación de la matrícula no podía tratarse como un problema de clasificación binaria, sino como la predicción de un valor continuo que fluctuaba según múltiples variables independientes. En consecuencia, se priorizaron modelos capaces de capturar relaciones no lineales entre los atributos académicos y demográficos, descartando regresiones lineales simples en favor de métodos de ensamble y modelos basados en aprendizaje profundo que ofrecieron una mayor precisión en entornos de alta varianza.

Uno de los algoritmos principales implementados fue el *Random Forest Regressor*, reconocido por su robustez frente al ruido en los datos. El Mrabet et al. [52] detallaron el funcionamiento de este algoritmo basado en el ensamble de múltiples árboles de decisión, donde la predicción final se obtiene promediando los resultados de árboles individuales. Se seleccionó este modelo por su capacidad intrínseca para manejar grandes conjuntos de datos sin incurrir en sobreajuste, gracias a la aleatoriedad en la selección de características. El estudio validó que *Random Forest* ofreció un equilibrio superior entre precisión y estabilidad, siendo ideal para predecir variables críticas donde el costo del error es alto. Complementariamente, se exploró el uso de arquitecturas avanzadas para la extracción de métricas predictivas a partir de datos estructurados y semiestructurados. Hamill e Iqbal [53] propusieron un enfoque innovador utilizando Modelos de Lenguaje Pequeños, Small Language Models (SLM) equipados con cabezales de regresión (*regression heads*). Esta arquitectura permitió procesar no solo los valores numéricos tradicionales, sino también interpretar el contexto de los datos antes de realizar la predicción numérica. La investigación de 2026 demostró que integrar capacidades de comprensión semántica en tareas de regresión mejoró la precisión en escenarios donde los datos de entrada presentaban ambigüedad o complejidad estructural.

5.4.3. Algoritmos de Clasificación

Complementando los modelos de regresión, se implementaron algoritmos de clasificación para abordar la categorización cualitativa de los fenómenos académicos. Se determinó que, para la toma de decisiones estratégicas, a menudo resultó más valioso clasificar una asignatura o un estudiante dentro de un nivel de riesgo (Alto, Medio, Bajo) que predecir un valor numérico exacto. En este contexto, la tarea de clasificación se configuró para identificar patrones que separaran clases discretas dentro del espacio de datos, permitiendo al sistema generar alertas tempranas sobre deserción estudiantil o cuellos de botella curriculares con base en probabilidades de pertenencia a una categoría específica.



Como base fundamental para la clasificación, se analizaron los árboles de decisión por su capacidad de interpretación. Blockeel et al. [54] examinaron la evolución de estos algoritmos desde la predicción eficiente hasta la “Inteligencia Artificial Responsable”. Se estableció que, aunque los modelos de caja negra (como las redes neuronales profundas) suelen ofrecer alta precisión, los árboles de decisión permitieron trazar la lógica exacta detrás de cada clasificación. Esta característica de transparencia se consideró crítica para el componente de asesoría del sistema, ya que facilitó la justificación de las recomendaciones ante los gestores académicos, cumpliendo con el requisito de explicabilidad ética en la gestión de datos sensibles.

Para superar las limitaciones de estabilidad de un árbol individual, se adoptó el algoritmo *Random Forest*. Salman et al. [55] presentaron una visión general técnica de este método de ensamble, el cual construye múltiples árboles de decisión durante el entrenamiento y fusiona sus resultados (*bagging*). Se analizó que esta técnica redujo significativamente la varianza y el riesgo de sobreajuste (*overfitting*) inherente a los árboles simples. El estudio destacó la capacidad del algoritmo para manejar grandes volúmenes de datos con alta dimensionalidad y valores perdidos, características típicas de los registros administrativos universitarios incompletos o heterogéneos.

La superioridad de los métodos de ensamble en el contexto educativo se validó al cruzar los hallazgos de Gusnina et al. [56] con los de Bujang et al. [57]. Mientras Gusnina et al. [56] demostraron en un caso de estudio en la Universidad Sebelas Maret que el *Random Forest* alcanzó una precisión del 90.7% en la predicción del rendimiento, superando a otros clasificadores clásicos; Bujang et al. [57] expandieron esta aplicación hacia modelos de predicción multiclasa para estimar calificaciones específicas. Ambos estudios coincidieron en que la selección de características basada en la ganancia de información (*Information Gain*) fue determinante para el éxito del modelo. Se concluyó que *Random Forest* ofreció el balance óptimo entre precisión predictiva y capacidad para manejar múltiples categorías de resultados académicos.

Finalmente, se evaluó la pertinencia de las Máquinas de Soporte Vectorial, Support Vector Machines (SVM) para escenarios de clasificación con márgenes de decisión complejos. Valkenborg et al. [58] detallaron los fundamentos matemáticos de las SVM, explicando su funcionamiento mediante la construcción de hiperplanos que maximizan la separación entre clases. Aunque se reconoció su alta efectividad en espacios de gran dimensión, se determinó que su costo computacional cuadrático limitaba su escalabilidad frente a grandes bases de datos históricas en comparación con los métodos de árboles. No obstante, se mantuvo como un algoritmo de referencia para la validación cruzada de los resultados obtenidos por los modelos principales.



5.5. Métricas de evaluación y validación de modelos

La validación del rendimiento de los modelos no se limitó a un ejercicio estadístico convencional, sino que se configuró como un mecanismo de aseguramiento de la calidad para el sistema de soporte a la decisión. Se determinó que, para que el algoritmo funcionara como un asesor confiable para el jefe de carrera, era imperativo medir no solo su tasa de aciertos global, sino su comportamiento frente a clases desbalanceadas y la magnitud de sus errores en la estimación de cupos. Por consiguiente, se seleccionó una batería de métricas diferenciadas para las tareas de clasificación (riesgo de deserción) y regresión (proyección de matrícula), priorizando aquellas que penalizaron los “falsos negativos”, dado que omitir un riesgo crítico se consideró más costoso institucionalmente que una falsa alarma. En el ámbito de la clasificación de riesgos académicos, se enfrentó el desafío de los conjuntos de datos desbalanceados, donde la “clase minoritaria” (estudiantes en riesgo) solía ser la de mayor interés estratégico. Sujon et al. [59] presentaron evidencia empírica reciente sobre la evaluación de modelos predictivos en dominios de alto impacto, cuestionando el uso de la “Exactitud” (*Accuracy*) como métrica única. Su investigación demostró que métricas como el *F1-Score* y el Coeficiente de Correlación de Matthews, Matthews Correlation Coefficient (MCC) ofrecieron una fiabilidad superior al evaluar el desempeño del modelo frente a clases minoritarias. Se adoptó el MCC como el estándar de validación, ya que este coeficiente cuantificó la calidad de la predicción binaria considerando verdaderos y falsos positivos y negativos, asegurando que el sistema no sesgara sus recomendaciones hacia la mayoría de estudiantes aprobados.

Para los modelos de regresión encargados de predecir la cantidad exacta de cupos, se analizó la naturaleza del error de estimación. Al contrastar la teoría de Hodson [60] con la necesidad operativa planteada por Shao et al. [6], se definió el criterio de evaluación final. Hodson [60] argumentó que la elección entre la Raíz del Error Cuadrático Medio (RMSE) y el Error Absoluto Medio (MAE) a menudo se presentó como una falsa dicotomía, aclarando que el RMSE es más sensible a errores grandes (valores atípicos), mientras que el Error Absoluto Medio, Mean Absolute Error (MAE) ofrece una interpretación más lineal del error promedio. Por su parte, la urgencia de minimizar los costos administrativos derivados de una mala estimación de cupos fue evidenciada por Shao et al. [6]. Para responder a este desafío, se concluyó utilizar ambas métricas de Hodson en conjunto; el MAE para reportar el error esperado “en el día a día” al usuario, y el RMSE para calibrar el modelo durante el entrenamiento, penalizando severamente las desviaciones grandes que podrían causar una crisis de saturación en las aulas.

Finalmente, la selección de estas métricas se alineó con el objetivo último de mejorar el logro estudiantil. Wang et al. [61] utilizaron el aprendizaje automático para analizar factores de influencia en el rendimiento, demostrando que la alta precisión de un modelo predictivo sienta las bases necesarias para el diseño de intervenciones académicas especí-



ficas y oportunas. Se estableció que un sistema validado con métricas robustas permitió identificar con mayor certeza los factores determinantes del éxito o fracaso. Esto garantizó que las sugerencias emitidas por el sistema de soporte a la decisión no fueran meras especulaciones estadísticas, sino inferencias validadas capaces de orientar políticas de oferta académica más justas y eficientes.

5.6. Interfaz de Programación de Aplicaciones y consumo de datos

La operacionalización de los modelos predictivos y de clasificación no se concibió como una ejecución de scripts aislados, sino que se estructuró mediante una arquitectura de software orientada a servicios. Se determinó que, para que el sistema de soporte a la decisión fuera accesible y escalable, la lógica de inteligencia artificial debía encapsularse detrás de una Interfaz de Programación de Aplicaciones (API) estandarizada. Esta capa de intermediación permitió desacoplar el núcleo de procesamiento matemático de las interfaces de usuario, garantizando que el consumo de los datos procesados ya fueran predicciones de matrícula o alertas de riesgo se realizara de manera segura, eficiente y agnóstica a la plataforma cliente utilizada por las autoridades universitarias.

Para soportar la complejidad del sistema, se evaluó la transición hacia una arquitectura distribuida. Blinowski et al. [62] realizaron una evaluación comparativa de rendimiento entre arquitecturas monolíticas y de microservicios, determinando que, si bien los monolitos ofrecen simplicidad inicial, los microservicios garantizan una escalabilidad horizontal superior y una mayor tolerancia a fallos. Basándose en este análisis, se implementó una arquitectura donde los módulos de predicción (regresión) y clasificación (riesgo) operaron como servicios independientes. Esta decisión permitió que el entrenamiento intensivo de un modelo no degradara el rendimiento del resto del sistema, asegurando una alta disponibilidad durante los períodos críticos de matrícula.

El diseño de los puntos de acceso (*endpoints*) para el consumo de datos se rigió por estándares de industria para asegurar la interoperabilidad. Gowda y Gowda [63] establecieron las mejores prácticas en el diseño de APIs RESTful, enfatizando la importancia de convenciones de nomenclatura semántica y protocolos de seguridad robustos. Se adoptó este enfoque para exponer los resultados de la IA, implementando mecanismos de autenticación y encriptación en el transporte de datos. El estudio validó que una Interfaz de Programación de Aplicaciones, Application Programming Interface (API) bien diseñada no solo facilita la integración con sistemas legados (como el Planificación de Recursos Empresariales, Enterprise Resource Planning (ERP) universitario), sino que actúa como una barrera de seguridad, protegiendo los datos sensibles de los estudiantes contra accesos no autorizados durante la consulta.



La infraestructura física para el alojamiento de estos servicios se definió bajo un modelo de soberanía de datos. Maaz et al. [64] analizaron el desarrollo de modelos de despliegue de servicios en nubes privadas, destacando que este entorno ofrece un control granular sobre la privacidad y el cumplimiento normativo que las nubes públicas no siempre garantizan. Se decidió desplegar la solución en una infraestructura de nube privada institucional, lo que permitió cumplir con las regulaciones de protección de datos académicos. Esta estrategia aseguró que, aunque el sistema utilizara técnicas avanzadas de computación en la nube para escalar, la información confidencial nunca abandonara el perímetro de control de la universidad.

La gestión dinámica de los recursos computacionales requeridos por los modelos de IA se resolvió mediante tecnologías de orquestación de contenedores. Al integrar la visión de Senjab et al. [65] con la evaluación de Blinowski et al. [62], se consolidó una plataforma de ejecución resiliente. Senjab et al. [65] detallaron cómo los algoritmos de planificación de Kubernetes optimizan la asignación de *pods* (contenedores) en función de la carga de trabajo en tiempo real, mientras que Blinowski et al. [62] confirmaron que esta capacidad de autoescalado es la ventaja competitiva clave de los microservicios frente a cargas variables. Ambos estudios coincidieron en que el uso de orquestadores permitió al sistema responder elásticamente: asignando más potencia de cálculo durante las semanas de inscripción y reduciéndola en períodos lectivos, optimizando así el costo operativo de la infraestructura. Finalmente, la integración de estas APIs marcó el hito definitivo en la modernización tecnológica propuesta. Nazyrova et al. [66] exploraron la transformación digital de la educación superior en el contexto de un futuro impulsado por la IA, concluyendo que la interoperabilidad es el factor crítico de éxito. Se estableció que el valor real del sistema desarrollado no residía únicamente en sus algoritmos internos, sino en su capacidad para dialogar fluidamente con el ecosistema digital universitario existente. La API actuó como el catalizador que permitió transformar la “Universidad Digital” (que solo digitaliza papeles) en una “Universidad Inteligente” (que conecta datos para decidir), cerrando la brecha entre la gestión administrativa y la innovación pedagógica.

En conclusión, el diseño de la solución tecnológica abordado en este capítulo estableció una base ingenieril sólida, transitando desde la fundamentación ética y estratégica (DSS), pasando por la arquitectura de datos masivos (*Big Data/ETL*) y el núcleo algorítmico (ML), hasta culminar en una interfaz de consumo segura y escalable (API). Se demostró teóricamente que la integración de estos componentes conforma un sistema capaz de mitigar las problemáticas de planificación detectadas. Con la arquitectura definida y los modelos seleccionados, se procedió a la fase de experimentación y validación empírica de los resultados, cuyo análisis detallado se presenta en el capítulo siguiente.



6

Optimización de la Oferta Académica mediante IA

Contenido del Capítulo

6.1. Marco Conceptual del Sistema Propuesto	44
6.2. Censo Académico Inteligente: Integración de la Intención de Demanda Estudiantil	46
6.3. Aplicación de Aprendizaje Automático para el Ajuste de la Cadaencia Académica	48
6.4. Módulo de Predicción de Cupos y Secciones	49
6.5. Estrategias de Optimización de Recursos Físicos y Horarios	51
6.6. Sistemas de Apoyo a la Toma de Decisiones para Unidades de Jefatura	53
6.7. Sinergia entre la Predicción de Datos y la Planificación Estratégica	55

6.1. Marco Conceptual del Sistema Propuesto

El marco conceptual del sistema propuesto se fundamentó en la integración sistémica de tecnologías de información para la gestión académica superior. Se definió una arquitectura holística donde los datos históricos institucionales interactuaron con algoritmos de inferencia, estructurando un ecosistema avanzado de soporte a la decisión. Se estableció de forma categórica que este modelo computacional no pretendió automatizar la toma de decisiones definitivas, sino dotar a las unidades de jefatura de una plataforma analítica robusta. De este modo, la incertidumbre inherente a la predicción de la demanda estudiantil se transformó en escenarios operativos viables, garantizando una distribución de recursos fundamentada en evidencia cuantitativa y avalada por el criterio experto humano.

Para cimentar esta arquitectura a nivel institucional, se adoptó el paradigma del campus inteligente multidimensional. Silva-da-Nóbrega et al. [67] propusieron un marco de trabajo de *Smart Campus* estructurado de manera integral para abordar los Objetivos de Desarrollo Sostenible (ODS), identificando la “Gestión Inteligente” y la “Gobernanza Inteligente” como dimensiones indispensables. En el diseño conceptual del sistema, se incorporaron estas dimensiones para asegurar que la optimización de la oferta académica no solo respondiera a requerimientos numéricos de capacidad física, sino que se alineara con estrategias de sostenibilidad e innovación universitaria. Se determinó que concebir el entorno académico como un ecosistema digital interconectado facilitó la interoperabilidad requerida entre los módulos de recolección de registros y los motores de inteligencia artificial.

Asimismo, se integró la dimensión humana como un componente crítico dentro de la operatividad del marco. Zhou y Schofield [68] desarrollaron un modelo conceptual riguroso para la alfabetización en Inteligencia Artificial en la educación superior, dividiendo las competencias en dimensiones cognitivas y socioemocionales. Se aplicó este principio al definir la interacción de la jefatura de carrera con el sistema, estableciendo que la efectividad de la herramienta requirió que el usuario comprendiera los fundamentos de la lógica algorítmica y los contornos éticos de las predicciones. Se estructuró la dinámica del sistema para requerir esta alfabetización, garantizando que el tomador de decisiones abordara las recomendaciones algorítmicas desde un enfoque analítico, reconociendo posibles sesgos antes de ejecutar la programación final de secciones.

Esta interacción transparente humano-máquina habilitó la evolución estratégica de la unidad académica. George y Wooden [35] analizaron exhaustivamente la metamorfosis de las universidades tradicionales hacia ecosistemas inteligentes, enfatizando que la aplicación de la IA en procesos administrativos trasciende la mera eficiencia técnica para consolidarse como un activo estratégico fundamental. Se definió que el sistema propuesto operó como el catalizador directo de esta transformación, permitiendo que la planificación de la oferta curricular evolucionara de una práctica administrativa reactiva —sostenida en la inercia de promedios históricos— a un modelo organizacional anticipatorio. La investiga-



ción corroboró que la inserción de estas tecnologías redefinió la capacidad operativa de la institución, optimizando la asignación de capital intelectual y de infraestructura frente a variables complejas.

En el nivel operativo, el marco conceptual internalizó los beneficios pragmáticos de la digitalización de procesos. Yang [24] evaluó la ruta de transformación digital específica para la gestión educativa superior, demostrando mediante evidencia cuantitativa que la reingeniería de procesos basada en analítica de datos mitigó drásticamente la saturación administrativa. En la parametrización de este proyecto, se adoptó dicha ruta metodológica para garantizar que el flujo de información curricular entre los departamentos operara sin interrupciones, eliminando cuellos de botella en la consolidación de horarios. Se observó que la estructuración digital de estos procedimientos no solo aceleró la operatividad logística, sino que mejoró los indicadores de calidad y la trazabilidad requerida en auditorías académicas.

Para viabilizar el flujo continuo y seguro de información hacia los motores predictivos, se definió una capa subyacente de integración tecnológica automatizada. Ravi [46] exploró la evolución ingenieril de la automatización en los flujos de Extracción, Transformación y Carga (ETL), argumentando que las arquitecturas contemporáneas exigen procesamiento en tiempo real o quasi-real para no perder valor analítico. Se estructuró el componente de ingestión de datos del sistema propuesto bajo este rigor técnico, prescribiendo tuberías (pipelines) autónomas que extrajeron los registros fragmentados, los depuraron de inconsistencias y los disponibilizaron en formatos matriciales sin requerir intervención manual constante. Se estableció que esta automatización constituyó el pilar técnico indispensable para la generación de pronósticos precisos por parte de los clasificadores automáticos.

Finalmente, el marco conceptual propuesto halló su máxima justificación en la convergencia entre la capacidad de ejecución digital y la dirección estratégica de alto nivel. Al contrastar los postulados teóricos de George y Wooden [35] con los hallazgos empíricos de Yang [24], se validó la integridad del modelo de soporte a la decisión. Mientras George y Wooden [35] aportaron el andamiaje filosófico y estructural que elevó a la IA como el habilitador principal de la universidad inteligente, Yang [24] corroboró estadísticamente que la aplicación de estas herramientas materializó reducciones tangibles en los tiempos de respuesta organizacional. Se concluyó que la arquitectura del sistema articuló armónicamente ambas perspectivas, dotando a la jefatura de una solución tecnológica que demostró ser innovadora en su concepción estratégica e implacablemente eficiente en su implementación administrativa diaria.



6.2. Censo Académico Inteligente: Integración de la Intención de Demanda Estudiantil

La formulación de una oferta académica pertinente exigió trascender el análisis exclusivo de los registros históricos de matrícula. Se determinó que proyectar la apertura de secciones basándose únicamente en el comportamiento pasado generaba sesgos, ignorando las fluctuaciones inmediatas en los intereses del estudiantado. Para mitigar esta deficiencia, se diseñó e implementó un Censo Académico Inteligente, concebido como un instrumento dinámico de recolección de datos preventrícula. Este mecanismo permitió capturar la “intención de demanda” declarada por los estudiantes, transformando una variable cualitativa e incierta en un vector de datos estructurado y auditável, el cual sirvió como insumo primario para calibrar los motores de predicción antes de consolidar la programación oficial.

Para la captura y estructuración de esta información prospectiva, se optimizó la arquitectura del Sistema de Gestión de Información (IMS) de la institución. Zhang et al. [42] exploraron las aplicaciones de la minería de datos en el desarrollo de los IMS universitarios, estableciendo que la acumulación pasiva de datos estudiantiles carecía de valor sin algoritmos de extracción. Se integró una lógica de procesamiento directamente en la base de datos del censo, aplicando técnicas de asociación para vincular las respuestas de la encuestada con el expediente real del alumno. El estudio demostró que anclar la minería de datos en el núcleo del IMS permitió descubrir patrones de comportamiento ocultos, validando que el censo no operara como un formulario aislado, sino como un módulo interactivo del ecosistema de información académica.

Se estableció que la intención declarada por el estudiante debía ponderarse algorítmicamente contra su perfil demográfico y académico para estimar la probabilidad real de inscripción. Shao et al. [6] aplicaron métodos de aprendizaje automático para la predicción de matrícula de cursos, identificando que ciertas variables poseían un peso predictivo superior. Mediante el uso de métricas de “importancia de variables” (Variable Importance) derivadas de algoritmos de Random Forest, se comprobó que el nivel de clase del estudiante, el periodo de ingreso y la fecha de cumplimiento de sus prerequisitos eran determinantes críticos. Se aplicó este principio al censo inteligente: el sistema no asumió que cada respuesta afirmativa se traduciría en una matrícula efectiva. Se aplicó este principio al censo inteligente: el sistema no asumió que cada respuesta afirmativa se traduciría en una matrícula efectiva, sino que ponderó la intención censal utilizando el historial académico del encuestado para filtrar falsos positivos.

La fluidez operativa entre la plataforma del censo y el motor de predicción se garantizó mediante una capa de interoperabilidad. Pérez-Jorge et al. [27] evaluaron el impacto de las Interfaces de Programación de Aplicaciones (APIs) impulsadas por IA en la gestión de



la información educativa. Se implementó una arquitectura de APIs RESTful que permitió la ingesta de los datos censales en tiempo real. La investigación determinó que la fragmentación de sistemas constituyó históricamente el mayor obstáculo para la administración universitaria; por consiguiente, el uso de APIs inteligentes aseguró que cada registro de intención de matrícula alimentara instantáneamente los modelos de clasificación, eliminando la latencia de procesamiento y los errores asociados a la exportación manual de datos.

El cruce metodológico entre la recolección de la intención censal y la viabilidad real de inscripción requirió una validación algorítmica estricta. Al integrar la arquitectura de información propuesta por Zhang et al. [42] con los modelos predictivos de Shao et al. [6], se estableció un mecanismo de depuración de la demanda. Mientras el sistema IMS de Zhang et al. [42] proveyó la infraestructura para recolectar masivamente las intenciones de los estudiantes mediante reglas de asociación, el modelo de *Random Forest* de Shao et al. [6] actuó como un filtro probabilístico. Ambos enfoques convergieron para resolver la discrepancia empírica donde los estudiantes solicitan asignaturas para las cuales no cumplen los prerrequisitos; el algoritmo cruzó la intención del censo con el árbol de dependencias, descartando estadísticamente las solicitudes inviables y generando una demanda depurada.

Además de la exactitud matemática, se consideró el impacto del censo en el ecosistema digital del estudiante. Retomando la investigación de Pérez-Jorge et al. [27], se evidenció que la gestión de información mediante APIs no solo optimizó el backend institucional, sino que transformó la experiencia del usuario final. Se diseñó la interfaz del censo para interactuar dinámicamente con el expediente del alumno, mostrando únicamente las asignaturas proyectadas según su avance curricular específico. Se concluyó que esta personalización de la toma de datos incrementó significativamente la tasa de participación en la encuesta, ya que el estudiante percibió el instrumento no como un trámite burocrático genérico, sino como una herramienta de asesoría académica adaptada a su trayectoria.

Finalmente, se validó que la integración del censo inteligente como variable de entrada mitigó los riesgos financieros de la institución. Shao et al. [6] argumentaron que la exactitud en el pronóstico de las tasas de inscripción es imperativa para minimizar costos administrativos innecesarios y reducir la carga sobre el personal docente y de planificación. Se determinó que el sistema, al preprocesar la intención estudiantil depurada, entregó a la jefatura de carrera un panorama de alta fidelidad sobre los requerimientos reales de cupos. Esta precisión algorítmica evitó la apertura de secciones subutilizadas —con el consecuente ahorro en pago de honorarios— y previno la saturación de aulas, alineando milimétricamente la oferta institucional con la demanda efectiva.



6.3. Aplicación de Aprendizaje Automático para el Ajuste de la Cadencia Académica

El ajuste de la cadencia académica se definió como la sincronización estratégica entre el avance real de las cohortes estudiantiles y la oferta institucional de asignaturas. Se identificó que el principal detonante del rezago estudiantil no radicaba exclusivamente en el rendimiento académico individual, sino en las interrupciones del flujo curricular causadas por una programación de clases desalineada con los prerrequisitos críticos. Para mitigar esta problemática, se aplicaron técnicas de aprendizaje automático orientadas a modelar el plan de estudios de Ingeniería en Sistemas como un ecosistema dinámico. El sistema se diseñó para monitorear la progresión histórica y sugerir aperturas de secciones que garantizaran un tránsito ininterrumpido, permitiendo a la jefatura anticiparse a los “cuellos de botella” antes de que afectaran los tiempos de egreso.

Para estructurar lógicamente este flujo, el primer paso consistió en la parametrización algorítmica del plan de estudios. Alshanqiti et al. [69] desarrollaron un enfoque basado en reglas para automatizar la evaluación del mapeo curricular (*Curriculum Mapping*), demostrando que la gestión manual de estas matrices era altamente propensa a errores y contradicciones. Se aplicó esta metodología para traducir el catálogo de asignaturas y sus dependencias normativas a un formato procesable por máquina. Al auditar las relaciones lógicas mediante algoritmos, el sistema logró identificar inefficiencias estructurales intrínsecas en la malla, proveyendo a los tomadores de decisiones de un diagnóstico preciso sobre qué secuencias de clases debían ofertarse ininterrumpidamente para respetar las normativas de progresión.

Una vez digitalizadas las reglas curriculares, se procedió al análisis matemático del peso de cada asignatura. Retomando el marco analítico de Stavrinides y Zuev [11], se modeló la carrera universitaria utilizando Redes de Prerrequisitos de Cursos, Course-Prerequisite Networks (CPN), representando el currículo como un Grafo Dirigido Acíclico, Directed Acyclic Graph (DAG). Se determinó, mediante el cálculo de medidas de “centralidad” topológica, que ciertas asignaturas actuaban como nodos críticos; es decir, materias cuya no apertura paralizaría a porcentajes mayoritarios de la población estudiantil. Esta topología de red dotó a la inteligencia artificial de la capacidad de priorizar algorítmicamente las recomendaciones de oferta, alertando a la jefatura cuando una materia de alta centralidad presentaba un déficit de secciones proyectadas.

La robustez del motor de ajuste de cadencia se garantizó al fusionar la validación lógica con el análisis estructural. Al integrar el motor basado en reglas de Alshanqiti et al. [69] con el modelado de redes complejas de Stavrinides y Zuev [11], se consolidó un sistema de evaluación bidimensional. Mientras Alshanqiti et al. [69] aportaron el rigor para que las secuencias sugeridas cumplieran irrestrictamente con la normativa académica institucio-



nal, Stavrinides y Zuev [11] proporcionaron el peso jerárquico de cada clase dentro de esa red. Se concluyó que esta intersección tecnológica permitió al asistente algorítmico no solo sugerir asignaturas “legales” para el estudiante, sino identificar aquellas estratégicamente indispensables para desaturar los niveles intermedios de la carrera.

Para que los algoritmos de ajuste curricular operaran con precisión, fue imperativo alimentar los modelos con datos longitudinales sobre la velocidad de avance de los estudiantes. Basándose en la arquitectura propuesta por Amo et al. [28], se utilizó el concepto de Almacén de Datos Educativos (*Educational Warehouse*) para centralizar la trazabilidad histórica de las cohortes. Se extrajeron patrones de comportamiento que revelaron el tiempo real que los estudiantes tomaban para superar los nodos críticos identificados previamente. El análisis profundo de estos registros almacenados comprobó que el flujo teórico del plan de estudios rara vez coincidía con la progresión empírica, proporcionando a la IA el contexto temporal necesario para ajustar la cadencia de la oferta a la realidad operativa del alumnado.

El ajuste de la cadencia académica también contempló la viabilidad humana del estudiante frente a la dificultad de las asignaturas. Bhosale y Hore [30] desarrollaron un motor de programación académica basado en inteligencia artificial orientado a la asignación inteligente del tiempo de estudio. Se integró esta lógica heurística al sistema de jefatura para evitar la sugerencia de bloques horarios sobrecargados de materias de alta complejidad matemática o técnica. Se determinó que una oferta académica optimizada no debía incitar a los estudiantes a matricular simultáneamente múltiples asignaturas de alta reprobación, ya que esto inducía al fracaso masivo. El algoritmo ajustó las recomendaciones para promover una distribución equilibrada de la carga cognitiva por periodo académico.

Finalmente, la aplicación integral de estas técnicas de aprendizaje automático sobre la cadencia del plan de estudios demostró un impacto directo en la sostenibilidad del modelo educativo. Retomando la premisa del modelado de redes de Stavrinides y Zuev [11], se evidenció que sincronizar la apertura de secciones con el ritmo real de la masa estudiantil maximizó la eficiencia terminal de la carrera. Se estableció que el sistema de soporte, al presentar a la jefatura una visualización clara de los estrangulamientos curriculares y sugerir combinaciones equilibradas, funcionó como un mecanismo proactivo de retención. Esta alineación algorítmica transformó los datos estáticos en estrategias de intervención dinámica, asegurando que los recursos docentes se invirtieran precisamente donde generaban el mayor retorno en términos de fluidez académica.

6.4. Módulo de Predicción de Cupos y Secciones

El Módulo de Predicción de Cupos y Secciones se concibió como el componente cuantitativo central del sistema de soporte a la decisión. Una vez analizado el flujo de la cadencia académica y depurada la intención del estudiante mediante el censo, se requirió traducir



esa información en valores numéricos exactos. Se determinó que el sistema debía calcular matemáticamente la cantidad proyectada de estudiantes por asignatura para, consecuentemente, sugerir el número óptimo de secciones (paralelos) a habilitar. Este cálculo se diseñó para operar de manera conservadora y precisa, buscando el equilibrio exacto que evitara tanto la saturación de las aulas como el despilfarro de recursos institucionales derivado de la apertura de secciones con baja densidad poblacional.

En la estructuración inicial de este módulo, se adoptó un enfoque analítico sustentado en el comportamiento histórico de la matrícula. Chang [70] examinó la planificación de inscripciones impulsada por datos, demostrando que la predicción de cupos impactó directamente en decisiones políticas institucionales, contrataciones docentes y asignación presupuestaria. Se integraron modelos de pronóstico basados en suavizado exponencial (*Exponential Smoothing*), los cuales permitieron capturar la tendencia evolutiva y la estacionalidad de los datos a lo largo de los períodos académicos. La aplicación de este modelado de series temporales garantizó que las fluctuaciones históricas —como los picos de matrícula en el primer semestre del año— fueran asimiladas por el algoritmo antes de emitir una sugerencia numérica a la jefatura.

Para adaptar estas proyecciones a las dinámicas específicas de las carreras técnicas, se evaluó la eficacia de distintos modelos de regresión. Pauta Riera et al. [31] realizaron un estudio comparativo en una unidad académica de ingeniería, aplicando modelos lineales, logísticos y polinómicos para predecir la demanda estudiantil. La investigación determinó que los modelos de regresión polinómica presentaron un coeficiente de determinación superior, logrando ajustarse con mayor fidelidad a la varianza de los registros universitarios. Se incorporó esta lógica matemática al núcleo del módulo, estableciendo que la predicción de secciones en Ingeniería en Sistemas no seguía un crecimiento lineal simple, sino un comportamiento polinómico afectado por las tasas de reprobación y retención de las ciencias exactas.

Con el objetivo de elevar la precisión y minimizar el error residual de la regresión clásica, se integraron algoritmos avanzados de aprendizaje automático. Shao et al. [6] implementaron métodos de *Random Forest* y Árboles de Clasificación y Regresión (CART) para pronosticar las tasas de inscripción. Se evidenció que la incorporación de variables demográficas y académicas del estudiante dentro de estos algoritmos incrementó drásticamente la exactitud de la predicción. Se configuró el módulo para que el *Random Forest* procesara múltiples árboles de decisión de forma simultánea, evaluando miles de interacciones entre el avance curricular del estudiante y el censo académico, lo que redujo sustancialmente los costos administrativos asociados a la subestimación de la demanda.

La arquitectura computacional del módulo también contempló el procesamiento de registros académicos semiestructurados que los algoritmos de regresión tradicionales no lograban interpretar. Hamill e Iqbal [53] propusieron una arquitectura innovadora em-



pleando Modelos de Lenguaje Pequeños (*Small Language Models - SLM*) equipados con un cabezal de regresión (*regression head*) para extraer métricas cuantitativas a partir de datos complejos. Se adoptó este enfoque vanguardista para dotar al sistema de la capacidad de interpretar notas, observaciones y transcripciones irregulares en los expedientes de los estudiantes. Se determinó que el procesamiento semántico previo realizado por el SLM, seguido de una salida numérica acotada, enriqueció los vectores de datos que alimentaron el pronóstico final de cupos.

La fiabilidad suprema del módulo de predicción se logró mediante la hibridación de metodologías analíticas. Al integrar el modelado de tendencias macroscópicas de Chang [70] con la precisión microscópica de los algoritmos descritos por Shao et al. [6], se estructuró un motor de inferencia altamente resiliente. Mientras el análisis de series temporales de Chang [70] proporcionó la línea base del crecimiento vegetativo de la institución (la tendencia general de la universidad), el *Random Forest* de Shao et al. [6] ajustó ese número base analizando las características individuales de cada alumno inscrito. Se concluyó que esta convergencia algorítmica garantizó que la sugerencia final de cupos no ignorara el contexto histórico global ni los matices específicos de la cohorte actual.

Finalmente, el valor numérico resultante del procesamiento de cupos se tradujo en parámetros logísticos accionables. Retomando la problemática expuesta por Pauta Riera et al. [31] sobre la saturación física, el sistema dividió algorítmicamente la predicción total de cupos entre la capacidad pedagógica máxima normada por la institución (por ejemplo, 40 estudiantes por aula). Este cálculo determinó el número exacto de secciones recomendadas a la jefatura de carrera. Se estableció que esta salida cuantitativa sirvió como el insumo directo para el diseño de la carga académica docente, proveyendo al tomador de decisiones de un escenario estructurado que eliminó la improvisación en la apertura de paralelos de última hora.

6.5. Estrategias de Optimización de Recursos Físicos y Horarios

La transición de la predicción numérica de cupos a la materialización de la oferta académica requirió resolver el desafío logístico de la distribución espacio-temporal. Se determinó que asignar horarios y aulas de forma manual para las secciones proyectadas constituía un proceso ineficiente, propenso a colisiones y cognitivamente extenuante para el personal administrativo. Por lo tanto, se diseñaron estrategias de optimización algorítmica orientadas a emparejar la demanda estudiantil validada con la disponibilidad finita de recursos físicos e instructores. Este subsistema operó bajo la premisa de generar combinaciones matriciales complejas, transformando el pronóstico de matrícula en una planificación operativa ejecutable, lista para la revisión de la jefatura.

Para abordar la complejidad matemática de esta asignación, se enmarcó la problemática dentro del Problema de Horarios de Cursos Universitarios (UCTP, por sus siglas en in-

glés). Abdipoor et al. [7] analizaron este fenómeno, clasificándolo inherentemente como un problema de optimización combinatoria de tipo NP-Hard (*NP-hard*), donde el espacio de soluciones posibles crece exponencialmente con cada nueva asignatura, profesor o aula añadida. Se adoptó este enfoque teórico para justificar la inviabilidad de los métodos de fuerza bruta convencionales en la planificación universitaria, implementando en su lugar aproximaciones metaheurísticas. Se estableció que el uso de estas técnicas avanzadas permitió al sistema explorar ágilmente el vasto espacio de búsqueda y converger hacia una asignación de horarios óptima sin agotar los recursos computacionales.

La operatividad del algoritmo de optimización se condicionó a un sistema estricto de reglas institucionales. Bashab et al. [71] sistematizaron las metodologías en el UCTP dividiendo las normativas en restricciones duras (*hard constraints*) y blandas (*soft constraints*). Se programó el motor de inferencia asimilando esta categorización: se impidió algorítmicamente el solapamiento de docentes en una misma franja horaria o la asignación de grupos que excedieran la capacidad del aula (restricciones duras inquebrantables). Simultáneamente, el algoritmo fue instruido para maximizar el cumplimiento de preferencias de jornada de los profesores y minimizar los lapsos sin clases para los estudiantes (restricciones blandas). La investigación evidenció que modelar el problema bajo esta dicotomía garantizó la viabilidad técnica y el confort humano.

Para la generación final de la cuadrícula, se transicionó hacia un modelo de inteligencia artificial de carácter evolutivo. Farinola y Assogba [25] desarrollaron un generador explícito de horarios mediante IA, demostrando la eficacia de los Algoritmos Genéticos, Genetic Algorithms (GA) frente a las heurísticas tradicionales para la resolución de colisiones. Se incorporó esta base algorítmica al subsistema logístico, permitiendo que la máquina evaluara iterativamente miles de configuraciones candidatas (“cromosomas”), aplicando funciones de selección cruzada y mutación hasta hallar la matriz con la menor tasa de penalización. Se constató que la automatización explícita de este proceso liberó a las unidades académicas de prolongadas semanas de labor manual, entregando borradores de horarios robustos en cuestión de minutos.

Más allá de la asignación temporal, se abordó la eficiencia intrínseca del uso del espacio físico. Adaptando los principios de macrodatos expuestos por Himeur et al. [43] sobre la automatización de sistemas de gestión de edificios Sistemas de Automatización y Gestión de Edificios, Building Automation and Management Systems (BAMS), se estructuró una capa de inteligencia espacial. Aunque enfocada originalmente en el rendimiento energético, la lógica analítica de este estudio se extrapoló para integrar las dimensiones arquitectónicas de las aulas con las predicciones del módulo de cupos. Se logró que el sistema no asignara auditorios con capacidad para cincuenta personas a secciones técnicas con una demanda proyectada de quince estudiantes, optimizando la huella de ocupación y asegurando un uso racional del patrimonio inmobiliario de la facultad.



La consolidación de la malla horaria óptima representó el éxito de integrar estructuras punitivas con procesos generativos. Al entrelazar la taxonomía de restricciones de Bashab et al. [71] con el motor de optimización evolutiva de Farinola y Assogba [25], se construyó una arquitectura híbrida inquebrantable. Mientras Bashab et al. [71] proveyeron el modelo matemático de penalizaciones (definiendo algorítmicamente el costo de cada restricción vulnerada), Farinola y Assogba [25] suministraron el mecanismo de los Algoritmos Genéticos para evadir dichos choques iterativamente y reducir el puntaje de penalización a cero. Se concluyó que esta interdependencia tecnológica fue el factor clave que permitió al sistema resolver el desafío combinatorio sin entrar en bucles de procesamiento infinitos. Finalmente, se estableció que el resultado de estas optimizaciones espaciotemporales operó estrictamente bajo el paradigma de soporte a la decisión. Se determinó que el algoritmo generador de horarios no se ejecutaría de forma autónoma con publicación directa en los portales estudiantiles, sino que presentaría sus configuraciones en formato de “propuestas operativas” ante la jefatura de carrera. Esta estrategia arquitectónica preservó la jerarquía del coordinador académico, quien retuvo la capacidad absoluta de realizar ajustes manuales para atender contingencias no cuantificables algorítmicamente, tales como licencias médicas imprevistas del profesorado. De esta forma, el sistema aportó la potencia computacional para resolver el entramado multidimensional, respetando invariablemente la flexibilidad inherente a la administración educativa.

6.6. Sistemas de Apoyo a la Toma de Decisiones para Unidades de Jefatura

El diseño de la interfaz entre los algoritmos matemáticos y las autoridades académicas se materializó a través de un Sistema de Apoyo a la Toma de Decisiones (DSS). Se estableció que la complejidad de los modelos predictivos y de optimización carecía de valor práctico si sus resultados no se presentaban de manera comprensible para los tomadores de decisiones no técnicos. Por consiguiente, el DSS se configuró no como una herramienta de ejecución automática, sino como un tablero de control consultivo (*dashboard*). Este entorno digital permitió a la jefatura de carrera visualizar las sugerencias de apertura de secciones, evaluar diferentes escenarios simulados y aplicar su juicio experto antes de oficializar la oferta académica, manteniendo invariablemente la autoridad humana sobre la planificación final.

Para estructurar la evaluación de las propuestas algorítmicas, se implementó un enfoque de análisis multidimensional. Bas et al. [47] desarrollaron un sistema de soporte de decisiones multicriterio para evaluar la efectividad de los cursos, demostrando que las decisiones educativas no pueden sustentarse en una única variable métrica. Se adaptó esta metodología para que la jefatura evaluara la apertura de secciones ponderando simultáneamente

diversos factores: la demanda estudiantil predicha, la disponibilidad presupuestaria, el índice de reprobación histórico y la carga horaria docente. La investigación validó que estructurar el DSS bajo este paradigma multicriterio impidió que el algoritmo sobreoptimizara una sola variable (por ejemplo, reducir costos) a expensas de la calidad académica.

La adopción del sistema por parte de la jefatura requirió mitigar la opacidad inherente a los modelos de aprendizaje automático complejos, coloquialmente conocidos como “cajas negras”. Almtrf [72] demostró que la integración de Inteligencia Artificial Explicable, Explainable AI (XAI) en los DSS es fundamental para promover la transparencia y la confianza en la toma de decisiones gerenciales. Se dotó al sistema de técnicas de explicabilidad algorítmica, como Explicaciones Agnósticas al Modelo Interpretables Localmente, Local Interpretable Model-agnostic Explanations (LIME) y Explicaciones Aditivas de Shapley, SHapley Additive exPlanations (SHAP), las cuales acompañaron cada sugerencia de sección con un desglose visual de los factores que la motivaron. Se comprobó que proporcionar esta justificación matemática explícita empoderó a los directivos académicos, permitiéndoles defender sus decisiones de planificación ante los órganos de gobierno institucional con evidencia rastreable.

Previo a la institucionalización de estas herramientas de visualización, se definieron directrices estrictas de gobernanza sobre el uso de la IA. Kaşarcı et al. [39] ejecutaron una revisión sistemática sobre la ética de la IA en la educación superior, advirtiendo que las respuestas institucionales suelen ser reactivas ante el sesgo algorítmico y los riesgos de privacidad. Atendiendo a estas advertencias, el DSS se programó con alertas de sesgo preventivas; por ejemplo, notificando a la jefatura si una programación sugerida favorecía desproporcionadamente a los estudiantes de los últimos semestres en detrimento de los de primer ingreso. Se determinó que incrustar estas políticas éticas directamente en la interfaz gráfica garantizó una adopción tecnológica alineada con los valores institucionales.

El impacto de las decisiones soportadas por el sistema se extendió orgánicamente hacia la salvaguarda de la equidad educativa. Shaikhanova et al. [73] diseñaron un DSS consciente de la carga de trabajo mediante modelos predictivos interpretables, con el propósito de identificar tempranamente a estudiantes en riesgo sin incurrir en discriminación algorítmica. Se asimiló este paradigma para que la jefatura pudiera evaluar cómo la distribución de horarios afectaba a distintas poblaciones estudiantiles, como aquellos que laboran durante la jornada diurna. La investigación validó que un DSS diseñado bajo los principios de equidad permitió a la administración universitaria configurar una oferta de asignaturas verdaderamente inclusiva, minimizando las barreras estructurales para la culminación de la carrera.

La consolidación de un entorno de decisión justo y transparente se logró al cruzar los preceptos de gobernanza ética con la interpretabilidad algorítmica técnica. Al integrar el marco de gobernanza de Kaşarcı et al. [39] con la arquitectura de equidad de Shaikhanova



et al. [73], se resolvió la tensión histórica entre la eficiencia automatizada y la responsabilidad humana. Mientras Kaşarcı et al. [39] establecieron el requisito normativo de evitar el sesgo en las instituciones de educación superior, Shaikhanova et al. [73] proporcionaron la estructura técnica interpretable (XAI) para auditar dicho sesgo en tiempo real. Se concluyó que esta interdependencia aseguró que el Jefe de Carrera no actuara como un simple espectador de los dictámenes de la máquina, sino como un auditor crítico dotado de las herramientas visuales necesarias para garantizar que la programación académica fuera técnica y moralmente inobjetable.

Finalmente, se comprobó que la inserción de este entorno analítico transfiguró radicalmente las funciones operativas de la unidad académica. Retomando la investigación empírica de Almtrf [72] sobre la confianza en los DSS, se evidenció que la automatización de la complejidad matemática liberó un volumen significativo de horas de labor gerencial. Se determinó que este excedente de tiempo permitió al Jefe de Carrera desplazar su enfoque desde la resolución de conflictos logísticos básicos hacia la planificación estratégica a largo plazo y la atención cualitativa del currículo. Así, el sistema de apoyo cumplió su propósito superior: no reemplazó al administrador, sino que lo dotó de capacidades analíticas aumentadas para dirigir el crecimiento sostenible de la facultad.

6.7. Sinergia entre la Predicción de Datos y la Planificación Estratégica

La culminación del modelo de inteligencia artificial no residió únicamente en su capacidad de procesamiento matemático, sino en la sinergia generada entre la predicción de datos y la planificación estratégica de la institución. Se determinó que los pronósticos de matrícula y la optimización de horarios carecían de impacto sostenido si operaban como procesos aislados de la visión gerencial de la unidad académica. Por consiguiente, se consolidó un ecosistema donde la salida algorítmica actuó como el insumo basal para la toma de decisiones directivas a largo plazo. Esta convergencia transformó los datos operativos diarios en inteligencia institucional, permitiendo a la jefatura de carrera abandonar la gestión reactiva de crisis y adoptar una postura anticipatoria que garantizó el uso eficiente de los recursos y el cumplimiento de los objetivos de calidad educativa.

Para que esta sinergia fuera efectiva, el sistema debió asimilar la naturaleza cambiante de la población estudiantil. García Macías et al. [74] analizaron el impacto del aprendizaje adaptativo impulsado por inteligencia artificial en la educación superior, demostrando que la tecnología posee la capacidad de moldearse dinámicamente al perfil del usuario. Se extrapoló este principio pedagógico hacia la gestión administrativa, estableciendo que la oferta académica generada por el sistema no constituyó una matriz estática, sino una planificación adaptativa. La investigación validó que, al ajustar iterativamente las proyec-

ciones de cupos basándose en el rendimiento continuo de las cohortes, la jefatura logró alinear la estrategia de contratación docente y apertura de secciones con las necesidades cognitivas y logísticas reales del momento.

La materialización de estas estrategias dependió directamente de la robustez de la infraestructura de soporte a la decisión. Shwede [37] investigó la integración de la IA en los Sistemas de Soporte a la Decisión (DSS) universitarios utilizando el Modelado de Ecuaciones Estructurales (SEM). Se comprobó cuantitativamente que factores como la calidad de los datos y la preparación organizacional influyeron de manera crítica en la eficacia de las decisiones gerenciales. En el contexto del sistema desarrollado, se aplicó este hallazgo garantizando que los pipelines de datos (ETL) suministraran información depurada al DSS. Se estableció que una alta calidad en los datos de entrada fue el requisito ineludible para que la jefatura confiara en el sistema y, consecuentemente, ejecutara planes estratégicos audaces con un margen de riesgo minimizado.

En el nivel macroinstitucional, el impacto de estas predicciones redefinió la gobernanza administrativa. Almaghrabi et al. [26] sistematizaron el conocimiento sobre el impacto de la Minería de Datos Educativos (EDM) en la administración organizacional, distinguiéndola de su uso puramente pedagógico. Se evidenció que la EDM actuó como un habilitador para la formulación de políticas institucionales y la asignación presupuestaria. Se integró este enfoque estratégico al modelo, demostrando que los patrones descubiertos por la IA (como las tasas crónicas de deserción en materias filtro) no solo sirvieron para acomodar horarios, sino que otorgaron a las autoridades evidencia empírica irrefutable para justificar rediseños curriculares o solicitar ampliaciones de presupuesto operativo ante los entes gubernamentales.

La verdadera sinergia estratégica se cristalizó al fusionar la preparación del capital humano con la potencia de la minería de datos. Al contrastar las perspectivas de Shwede [37] y Almaghrabi et al. [26], se definió el marco de éxito para la implementación de la solución. Mientras Shwede [37] demostró que la preparación organizacional (la disposición al cambio cultural de los directivos) fue indispensable para la adopción tecnológica, Almaghrabi et al. [26] proveyeron el vehículo analítico (EDM) que transformó esa disposición en resultados administrativos medibles. Ambos estudios coincidieron en que el software por sí solo no genera optimización; se concluyó que la planificación estratégica óptima resultó de la interacción entre algoritmos que procesaron eficientemente grandes volúmenes de datos y líderes académicos capacitados para interpretar y ejecutar políticas basadas en dichas predicciones.

Como resultado de esta integración, el proceso de programación académica evolucionó hacia un ciclo de mejora continua. Retomando los principios de adaptabilidad expuestos por García Macías et al. [74], se estructuró un mecanismo de retroalimentación donde el sistema aprendió de las decisiones pasadas de la jefatura y de los resultados reales de



inscripción. Se determinó que cada periodo académico finalizado enriqueció la base de conocimientos del algoritmo, reduciendo progresivamente el margen de error de las proyecciones futuras. Esta sostenibilidad operativa aseguró que la inversión en infraestructura de inteligencia artificial generara un retorno incremental, consolidando a la carrera de Ingeniería en Sistemas como un referente de gestión administrativa impulsada por datos. En conclusión, el desarrollo exhaustivo del marco teórico y conceptual cimentó las bases científicas, tecnológicas y gerenciales de la investigación. A través de la revisión del problema de asignación de recursos, el diseño de arquitecturas de Big Data y el despliegue de modelos de aprendizaje automático y sistemas de soporte, se fundamentó teóricamente la viabilidad de la optimización de la oferta académica. La sinergia lograda entre la predicción cuantitativa y la planificación estratégica demostró que la inteligencia artificial puede integrarse como un asesor ético e implacable frente a la complejidad universitaria. Con el modelo conceptual robustamente justificado, la investigación procedió hacia la fase metodológica y de implementación experimental para validar empíricamente estas premisas teóricas.



7

Marco Conceptual

7.1. Glosario conceptual del estudio

Algoritmo Genético (GA): Técnica de resolución de problemas en inteligencia artificial inspirada en la evolución biológica (selección, cruce y mutación). Se utiliza para encontrar soluciones óptimas en escenarios con millones de combinaciones posibles, como la creación automatizada de horarios sin choques de clases.

API (Interfaz de Programación de Aplicaciones): Conjunto de reglas y protocolos tecnológicos que permite que dos sistemas informáticos diferentes se comuniquen entre sí de forma segura y automatizada. En el contexto educativo, permite que los datos del expediente del estudiante viajen al motor de inteligencia artificial en tiempo real.

API RESTful: Un tipo específico de arquitectura de API diseñada para ser ligera, rápida y altamente escalable en entornos web. Es el estándar de la industria para el consumo y envío de datos entre servidores y aplicaciones móviles o web.

Arquitectura de Microservicios: Método de diseño de software donde un sistema complejo se divide en componentes pequeños, independientes y especializados (servicios). Si una parte del sistema falla o recibe mucha demanda, el resto del sistema sigue funcionando sin colapsar.

Big Data (Datos Masivos): Conjuntos de datos cuyo volumen, complejidad y velocidad de crecimiento son tan grandes que los programas informáticos de procesamiento tradicional no logran capturarlos, gestionarlos ni analizarlos de forma eficiente.

Caja Negra (Black Box): Término utilizado para describir modelos de Inteligencia Artificial donde se conocen los datos que entran y los resultados que salen, pero el proceso lógico interno que la máquina usó para llegar a esa conclusión es incomprendible para el ser humano.

Clustering (Agrupamiento / K-medoids): Técnica de aprendizaje automático que agrupa automáticamente conjuntos de datos no etiquetados en categorías basadas en sus similitudes. Sirve, por ejemplo, para agrupar estudiantes con perfiles de riesgo académico similares.

DSS (Decision Support System / Sistema de Soporte a la Decisión): Sistema informático interactivo diseñado para ayudar a los administradores a tomar decisiones estratégicas. En lugar de automatizar la decisión final, el sistema analiza grandes vo-

lúmenes de datos y presenta escenarios probables al usuario humano.

ETL (Extracción, Transformación y Carga / Pipelines): Proceso automatizado de ingeniería de datos. Consiste en extraer datos crudos de múltiples fuentes, limpiarlos/estandarizarlos (transformación) y guardarlos en una base de datos moderna (carga) lista para la Inteligencia Artificial.

Grafo Dirigido Acíclico (DAG): Representación matemática en forma de red donde la información fluye en una sola dirección y nunca forma un ciclo cerrado. Se utiliza para mapear mallas curriculares, impidiendo que el estudiante avance en círculos.

Heurística y Metaheurística: Métodos matemáticos y algoritmos que buscan encontrar soluciones “suficientemente buenas” y rápidas a problemas que son demasiado complejos para calcular una solución perfecta en un tiempo razonable.

IMS (Information Management System / Sistema de Gestión de Información): Plataforma tecnológica centralizada que utilizan las instituciones para gestionar sus procesos operativos, académicos y administrativos (comúnmente conocido como el portal de registro o ERP).

Inteligencia Artificial Explicable (XAI): Conjunto de técnicas diseñadas para traducir el razonamiento de un algoritmo a un formato visual que un humano pueda entender, generando confianza al permitir saber exactamente por qué la máquina recomendó una acción.

Kubernetes (Orquestación de Contenedores): Sistema tecnológico que administra y ajusta automáticamente la capacidad de las aplicaciones de software según la demanda, asignando temporalmente más potencia de cálculo para evitar caídas del sistema.

Machine Learning (Aprendizaje Automático): Rama de la inteligencia artificial que permite a los sistemas informáticos aprender a identificar patrones y mejorar su rendimiento a partir de datos históricos, sin necesidad de que un humano los programe con reglas explícitas.

Minería de Datos Educativa (EDM): Proceso de descubrir patrones ocultos, correlaciones y anomalías dentro de grandes bases de datos estudiantiles, con el fin de predecir el comportamiento del alumnado y mejorar las políticas de administración



institucional.

Modelo de Regresión (Regresión Polinómica): Técnica estadística y de aprendizaje automático que analiza la relación entre múltiples variables para predecir un valor numérico continuo, adaptándose a comportamientos que no son líneas rectas predecibles.

Problema NP-Duro (NP-Hard): Categoría de problemas matemáticos de altísima complejidad donde el número de combinaciones posibles es tan masivamente grande que calcular todas las opciones exhaustivamente colapsaría a una computadora convencional.

Random Forest (Bosque Aleatorio): Poderoso algoritmo de predicción que funciona creando múltiples árboles de decisión durante su entrenamiento. Para dar un resultado final, promedia las conclusiones de todos esos árboles, haciéndolo altamente preciso.

SLM (Small Language Models / Modelos de Lenguaje Pequeños): Sistemas de inteligencia artificial capaces de comprender y procesar texto humano de manera eficiente, utilizados para extraer datos útiles de documentos desordenados sin requerir supercomputadoras masivas.

Suavizado Exponencial (Series Temporales): Método matemático de pronóstico que analiza datos históricos a lo largo del tiempo, dándole mayor peso de importancia a los datos más recientes para predecir tendencias futuras.

UCTP (University Course Timetabling Problem): El desafío logístico clásico en ciencias de la computación que busca ubicar un conjunto de eventos académicos en franjas horarias y aulas limitadas, sin que profesores o estudiantes tengan conflictos de horario.



8

Marco Legal

Contenido del Capítulo

8.1. Marco Legal	63
8.1.1. Normativa Académica e Institucional de la UNAH	63
8.1.2. Protección de Datos Personales y Habeas Data	63
8.1.3. Estándares Éticos y Normativa Internacional de la Inteligencia Artificial	64

8.1. Marco Legal

El desarrollo y la implementación del sistema predictivo para la optimización de la oferta académica se fundamentó en un marco regulatorio estricto, abarcando normativas institucionales, leyes nacionales de privacidad y estándares internacionales de ética algorítmica. Se determinó que, al procesar historiales académicos y encuestas de intención de matrícula, el modelo tecnológico debía garantizar la protección de la información sensible y subordinar sus resultados a las reglamentaciones vigentes, asegurando que la inteligencia artificial operara como un instrumento legal y éticamente vinculante.

8.1.1. Normativa Académica e Institucional de la UNAH

La viabilidad operativa del sistema propuesto se estructuró en estricto apego a las **Normas Académicas de la Universidad Nacional Autónoma de Honduras (UNAH)** [75]. Se estableció que el algoritmo de predicción y asignación de horarios operara en cumplimiento de los siguientes mandatos institucionales:

- **Planificación basada en el Censo (Artículo 211):** La norma exige explícitamente que la programación académica tome en consideración el reporte del censo estudiantil y las capacidades reales instaladas para lograr el buen uso de los recursos institucionales. Esta disposición justificó legalmente el desarrollo del “Censo Académico Inteligente” y la intervención de la Inteligencia Artificial para procesar dicha demanda cruzándola con la infraestructura disponible.
- **Carga Académica Regulada (Artículo 214):** Dictamina que la cantidad de créditos o unidades valorativas a cursar debe regularse en función del rendimiento e índice académico del estudiante. El motor de aprendizaje automático asimiló esta regla como una restricción dura, filtrando algorítmicamente las intenciones de matrícula que excedieran la carga legal permitida.
- **Demandas Mínimas para Secciones (Artículo 218):** Obliga a la cancelación de secciones que no alcancen la demanda mínima requerida por la institución. El Módulo de Predicción de Cupos se fundamentó en este artículo, utilizando modelos de regresión para pronosticar con precisión qué secciones alcanzarían el umbral legal, evitando la apertura de paralelos subutilizados.

8.1.2. Protección de Datos Personales y Habeas Data

El tratamiento de los expedientes estudiantiles y registros académicos se fundamentó en el derecho constitucional de **Habeas Data (Artículo 182 de la Constitución de la República de Honduras)**, operativizado a través de la **Ley de Transparencia y Acceso a la Información Pública** (Decreto No. 170-2006) [76]. Específicamente, se acataron las directrices de



su Capítulo V, donde los **Artículos 23, 24 y 25** dictaminan la protección irrestricta de los archivos personales, prohibiendo su uso para originar discriminación o daños morales. Para viabilizar el entrenamiento de los algoritmos predictivos sin vulnerar la privacidad estudiantil, la investigación se amparó en la excepción legal dispuesta en el **Artículo 44, numeral 1 del Reglamento de dicha Ley** (Acuerdo No. IAIP-0001-2008). Este precepto autoriza explícitamente el acceso y tratamiento de datos personales sin el consentimiento del individuo cuando el fin sea estrictamente estadístico o científico, a condición de someter la información a un procedimiento de disociación. En estricto cumplimiento de este mandato, y observando la obligación de seguridad informática exigida por el **Artículo 41, numeral 6** del mismo reglamento, se implementaron las siguientes políticas:

- **Anonimización Algorítmica (*Data Masking*):** Se estructuró un conducto de Extracción, Transformación y Carga (ETL) que eliminó variables identificativas directas (nombres, números de cuenta) de las métricas de rendimiento. De este modo, los modelos de *Machine Learning* procesaron volúmenes masivos de datos puramente estadísticos.
- **Seguridad de Acceso Restringido:** Las bases de datos vectoriales y los tableros analíticos se alojaron en repositorios protegidos, limitando la visibilidad de los resultados predictivos exclusivamente a la jefatura académica responsable de la programación.

8.1.3. Estándares Éticos y Normativa Internacional de la Inteligencia Artificial

Dado el impacto directo del sistema en la trayectoria académica de los estudiantes, la arquitectura del modelo se estructuró en rigurosa observancia de la **Recomendación sobre la Ética de la Inteligencia Artificial de la UNESCO** [77]. Se garantizó que el motor algorítmico cumpliera con los siguientes principios rectores internacionales:

- **Equidad y No Discriminación (Párrafo 29):** Exige que los actores de la IA reduzcan al mínimo y eviten reforzar resultados sesgados. El modelo de asignación de horarios se programó para evaluar métricas de forma puramente matemática, previniendo que el algoritmo priorizara injustamente a ciertas cohortes en detrimento de grupos vulnerables.
- **Transparencia y Explicabilidad (Párrafos 37 y 40):** Establece que la explicabilidad es fundamental para garantizar el respeto a los derechos humanos, obligando a hacer inteligibles los resultados de los sistemas. Para satisfacer este mandato, el Sistema de Soporte a la Decisión (DSS) integró Inteligencia Artificial Explicable (XAI), permitiendo a la jefatura auditar visualmente los factores estadísticos de cada recomendación y eliminando el paradigma de la “caja negra”.
- **Protección en la Educación (Párrafo 104):** Dictamina que la IA en entornos de gestión educativa no debe hacer un uso indebido de la información del educando. Este



principio blindó éticamente el uso de los datos históricos, asegurando que se emplearan exclusivamente para garantizar la fluidez curricular y el éxito académico.







Parte III

MARCO METODOLÓGICO

9

Metodología

Contenido del Capítulo

9.1.	Tipo de investigación	69
9.2.	Diseño Metodológico	69
9.3.	Involucrados en la investigación	70
9.3.1.	Principales involucrados	70
9.3.2.	Otros involucrados	70
9.4.	Técnicas e Instrumentos de recolección de datos	71
9.5.	Procedimiento	72
9.6.	Herramientas tecnológicas utilizadas	74
9.7.	Métodos de validación	76
9.7.1.	Métricas de evaluación del modelo	76
9.7.2.	Casos de uso	78

9.1. Tipo de investigación

La investigación se clasificó bajo un enfoque cuantitativo con un alcance correlacional y predictivo. Hernández-Sampieri, Fernández Collado y Baptista Lucio[78] establecieron que los estudios correlacionales tienen como propósito principal conocer la relación o grado de asociación que exista entre dos o más conceptos, categorías o variables en un contexto en particular. Se determinó que el proyecto buscó establecer la relación matemática entre el comportamiento histórico de matrícula, las variables demográficas, los resultados del censo estudiantil y la demanda real de cupos para la carrera de Ingeniería en Sistemas. Al cuantificar estas interacciones mediante modelos de aprendizaje automático, el estudio trascendió la mera descripción del fenómeno de saturación, permitiendo pronosticar escenarios operativos futuros con un margen de error estadísticamente medible.

Asimismo, por su naturaleza final, el estudio se definió como una investigación aplicada orientada a la innovación tecnológica. Aunque la literatura metodológica tradicional [78] se enfoca en el desarrollo de conocimiento puro, la estructuración de esta investigación se dirigió a la resolución de un problema logístico práctico dentro de la institución. Se desarrolló un modelo algorítmico que culminó en un Sistema de Soporte a la Decisión (DSS) plenamente funcional, diseñado para dotar a las autoridades académicas de una herramienta basada en evidencia empírica para la mitigación eficiente de cuellos de botella en la oferta curricular.

9.2. Diseño Metodológico

El diseño metodológico seleccionado para la evaluación y entrenamiento de los algoritmos fue de carácter no experimental, de corte longitudinal y evolución de grupo (cohorte). Hernández-Sampieri et al. [78] definieron los diseños no experimentales como aquellos estudios que se realizan sin la manipulación deliberada de variables, en los cuales se observan los fenómenos tal como se dan en su contexto natural para posteriormente analizarlos. Se estableció que el modelo de inteligencia artificial fue alimentado, entrenado y validado utilizando registros históricos masivos extraídos de las bases de datos del sistema de gestión universitaria. En ningún momento se alteraron retroactivamente las calificaciones, los historiales o las pautas de inscripción de los estudiantes para forzar resultados en el algoritmo, garantizando un entorno de prueba ex post facto riguroso.

Adicionalmente, se aplicó la dimensión longitudinal debido a la necesidad de evaluar el fenómeno a lo largo del tiempo. Según Hernández-Sampieri et al. [78], los diseños longitudinales recolectan datos en diferentes puntos del tiempo para realizar inferencias respecto al cambio, sus determinantes y consecuencias. La cadencia del plan de estudios y las tasas de aprobación en asignaturas críticas se analizaron a través de múltiples períodos académicos consecutivos. Este diseño permitió al motor de pronóstico (como el suavizado



exponencial y el modelo Random Forest) capturar con precisión matemática la estacionalidad de la demanda —como el incremento de estudiantes de primer ingreso en el primer ciclo del año— y el efecto de retardo causado por las clases de alta reprobación.

9.3. Involucrados en la investigación

La viabilidad e implementación de la solución arquitectónica requirió la identificación y categorización de los actores clave dentro del ecosistema universitario, evaluando su nivel de interacción, aporte de datos y el impacto que la tecnología generaría sobre sus funciones cotidianas. Reconocerlos permitió comprender de manera más precisa cómo se estructura y se comporta la planificación académica, y facilitó la interpretación de los datos recolectados.

La caracterización de estos actores también contribuyó a contextualizar los resultados obtenidos mediante los modelos predictivos y las simulaciones espaciotemporales realizadas, ya que cada grupo aportó información, necesidades y restricciones distintas sobre el funcionamiento real de la carrera. De esta forma, identificar a los involucrados se convirtió en un paso clave para analizar el ecosistema de toma de decisiones de manera integrada y coherente.

9.3.1. Principales involucrados

El primer grupo principal correspondió a la Jefatura de la Carrera y al equipo de coordinación académica. Se determinó que estos actores fungieron como los usuarios finales y directos del tablero de control analítico. Su involucramiento fue indispensable para la validación del sistema, ya que el algoritmo se diseñó para no ejecutar publicaciones autónomas en el portal de registro. En su lugar, el modelo emitió proyecciones y sugerencias de programación que la jefatura debió auditar, ajustar y aprobar, ejerciendo su criterio experto y aplicando las normativas institucionales sobre las predicciones de la máquina.

El segundo grupo de máxima prioridad estuvo conformado por la población estudiantil matriculada en la carrera. Se estableció que los estudiantes interactuaron activamente con el ecosistema de recolección de datos a través del llenado del Censo Académico Inteligente. Paralelamente, constituyeron los beneficiarios principales del diseño, puesto que la reingeniería de la programación académica, la minimización de solapamientos horarios y la garantía algorítmica de cupos en asignaturas “filtro” permitieron reducir su tiempo de permanencia en la institución y mejorar su fluidez en el progreso de la malla curricular.

9.3.2. Otros involucrados

El personal docente adscrito al departamento figuró como un grupo involucrado secundario de alto impacto logístico. Se analizó que la asignación de la carga laboral de los catedrá-



ticos estuvo directamente vinculada a los resultados arrojados por el optimizador espacial y temporal. Las normativas de contratación, la disponibilidad de jornadas y las preferencias horarias del profesorado operaron como un vector de restricciones (duras y blandas) que el algoritmo metaheurístico debió resolver para generar la matriz final del horario sin colisiones.

Finalmente, la Dirección de Ingreso, Permanencia y Promoción (o entidad homóloga encargada del registro universitario) actuó como el proveedor infraestructural clave. Su involucramiento se centró en la administración técnica del Sistema de Gestión de Información (IMS) base. De estos repositorios institucionales se extrajeron las sábanas de datos, expedientes académicos y estadísticas de aulas físicas necesarias para ejecutar las tuberías de Extracción, Transformación y Carga (ETL) que nutrieron de información veraz a los modelos de pronóstico.

9.4. Técnicas e Instrumentos de recolección de datos

La recolección de datos constituye una fase fundamental dentro de la metodología de esta investigación, ya que permite obtener la información base para el análisis, modelado y simulación del tráfico vehicular en la ciudad de Comayagua. Los datos empleados han sido obtenidos a partir de **observaciones directas** y estimaciones basadas en la experiencia personal del investigador, complementadas con fuentes secundarias de carácter técnico y municipal. Este enfoque, si bien limita la precisión absoluta de los datos, proporciona una aproximación razonable a las condiciones reales del entorno vial, suficiente para efectos de simulación y análisis en entornos virtuales como SUMO.

La técnica principal utilizada fue la observación sistemática no participante, la cual consistió en registrar manualmente los comportamientos del tráfico durante diferentes franjas horarias (pico matutino, mediodía y vespertino), en puntos estratégicos de la ciudad donde se concentra la mayor afluencia vehicular. Estos puntos incluyeron las principales arterias viales de Comayagua, como el bulevar Roberto Romero Larios, la carretera CA-5. En cada sitio se observó la densidad del tráfico, los tipos de vehículos predominantes, las velocidades promedio y los tiempos aproximados de espera en intersecciones. Además de la observación, se aplicó una técnica de estimación de flujos vehiculares basada en el conteo visual y la proyección por intervalos de tiempo. Esta técnica consistió en medir la cantidad promedio de vehículos que transitan por una vía durante lapsos de 10 a 15 minutos, para luego extrapolar los valores a una hora completa.

En cuanto a los instrumentos utilizados, se emplearon herramientas digitales que facilitaron la recopilación y organización de la información. Entre ellas destacan Google Maps, OpenStreetMap y Waze, utilizadas para identificar y delimitar las áreas de estudio, obtener coordenadas geográficas precisas y trazar rutas de desplazamiento. También se recurrió al software SUMO como instrumento de análisis indirecto, ya que su módulo de generación



de tráfico (**RandomTrips.py**) permitió contrastar los valores observacionales con escenarios simulados. De esta forma, los datos recolectados manualmente se tradujeron en parámetros digitales (rutas, velocidades, tasas de inserción vehicular), integrándose dentro de un modelo virtual del tráfico de Comayagua. Esta fase de digitalización de datos fue fundamental para vincular la observación empírica con el análisis cuantitativo, garantizando así la coherencia metodológica del estudio.

Finalmente, el uso de técnicas mixtas de registro observación directa, conteo visual y modelado en software proporcionó una base sólida para el análisis comparativo entre el flujo vehicular observado y los resultados generados por la simulación. Si bien las limitaciones inherentes a la falta de instrumentación electrónica reducen la exactitud en términos absolutos, el objetivo central del estudio no radica en la medición exacta, sino en la evaluación de la aplicabilidad de la inteligencia artificial como herramienta de optimización del tráfico vehicular. Por tanto, las técnicas de recolección empleadas son adecuadas para demostrar la viabilidad práctica del modelo propuesto en contextos urbanos con recursos tecnológicos limitados, como el caso de Comayagua.

9.5. Procedimiento

El procedimiento de esta investigación se estructuró mediante una secuencia metodológica compuesta por diversas fases interrelacionadas, diseñadas para garantizar un proceso sistemático, replicable y alineado con los objetivos propuestos. Cada fase aborda un componente específico del estudio, desde la observación empírica del entorno vial hasta la validación final del modelo de simulación. El enfoque empleado es de carácter aplicado, puesto que busca generar información útil para la gestión del tráfico urbano en Comayagua mediante herramientas cuantitativas, técnicas de modelado y métodos basados en la teoría de grafos, permitiendo obtener conclusiones medibles y transferibles a contextos urbanos similares.

Fase 1: Observación y diagnóstico del entorno vial

La primera fase consistió en un reconocimiento empírico del sistema vial de Comayagua, mediante visitas de campo y observaciones directas en distintos puntos de la ciudad. Se identificaron las principales vías de circulación, intersecciones críticas y zonas donde se produce la mayor congestión vehicular. Durante esta etapa, se levantaron datos aproximados sobre la cantidad de vehículos que transitan en horas pico. Este diagnóstico inicial permitió establecer una línea base del flujo vehicular, necesaria para la posterior simulación del entorno urbano.

Fase 2: Manejo y Ordenamiento de la Información Recopilada

Tras la adquisición de los datos, estos fueron organizados y depurados meticulosamente



en hojas de cálculo, categorizándolos por clase, instante de registro y coordenadas geográficas. A continuación, la información fue migrada a un formato que se integrara sin problemas con las plataformas de simulación en uso. Dicha organización hizo posible el establecimiento de variables como la congestión vehicular, la extensión de las rutas y lacadencia de tránsito. Si bien los datos se obtuvieron mediante la mera observación y ciertos cálculos, el tratamiento cuantitativo aseguró que los valores integrados en la simulación reflejaran de manera fiel y lógica la dinámica verdadera del tráfico. Esta etapa se centró en alistar los datos numéricos para nutrir el modelo informático.

Fase 3: Análisis de la red vial aplicando la teoría de grafos

En esta fase se procedió a representar la red vial de Comayagua mediante un grafo dirigido y ponderado, donde los nodos corresponden a intersecciones y las aristas a segmentos viales. A partir de esta estructura, se aplicaron métricas fundamentales de la teoría de grafos, tales como:

- **Grado de entrada y salida**, para identificar intersecciones con mayor carga estructural.
- **Caminos mínimos**, útiles para determinar trayectos más eficientes.
- **Centralidades** (betweenness, closeness, degree), que permitieron reconocer nodos críticos y posibles cuellos de botella.
- **Componentes conexas y subgrafos relevantes**, para comprender la coherencia interna del sistema vial.

Este análisis permitió detectar vulnerabilidades, patrones topológicos y zonas de alto impacto en la dinámica de tráfico urbano.

Fase 4: Modelado del entorno urbano

En esta etapa se desarrolló un modelo digital del entorno vial utilizando el software SUMO. Los mapas fueron importados desde **OpenStreetMap** y posteriormente ajustados para reflejar fielmente la realidad de Comayagua, incorporando sentidos de circulación, restricciones de giro, límites de velocidad, semáforos y jerarquías de vías. La estructura construida en SUMO se alineó con el grafo previamente generado, permitiendo que cada elemento del modelo matemático tuviera su equivalente en la simulación. El propósito principal del modelado fue disponer de una representación dinámica del sistema vial para probar escenarios y contrastar el comportamiento de la red bajo diferentes condiciones.

Fase 5: Implementación de la simulación y análisis de escenarios

Una vez completado el modelo urbano digital, se ejecutaron diversas simulaciones modificando condiciones como volumen vehicular, rutas predominantes y distribución del flujo.

Estas variaciones permitieron observar indicadores como demoras, velocidad promedio y saturación de intersecciones. El análisis comparativo entre escenarios permitió examinar cómo la estructura del grafo influía en el rendimiento del sistema vial, y detectar puntos donde la topología de la red genera cuellos de botella o sobrecarga de flujo. En esta fase, la simulación se utilizó para validar las conclusiones derivadas del análisis de grafos y para estudiar el comportamiento emergente del tráfico en condiciones controladas.

Fase 6: Evaluación y validación de resultados

Finalmente, se llevó a cabo un proceso de validación mediante la comparación de los resultados obtenidos en la simulación con los patrones observados durante la fase de diagnóstico inicial. Se analizaron indicadores clave como reducción proyectada de congestión, duración de los desplazamientos y eficiencia del flujo vehicular. Esta evaluación buscó determinar la consistencia del modelo, su capacidad para representar adecuadamente el comportamiento real del tráfico y su utilidad para apoyar la toma de decisiones en la planificación vial. Los resultados confirmaron la pertinencia de utilizar teoría de grafos y simulación para identificar vulnerabilidades estructurales y proponer mejoras sostenibles en la movilidad urbana.

9.6. Herramientas tecnológicas utilizadas

Para llevar a cabo este estudio, fue necesario combinar diferentes instrumentos tecnológicos que facilitaron el manejo y estudio eficaz de la información sobre el tránsito de vehículos. Por su carácter cuantitativo y aplicable, las herramientas seleccionadas hicieron hincapié en la simulación del tráfico urbano, así como en el análisis de datos mediante IA. En este apartado, se detallan los recursos tecnológicos más importantes que se usaron, clasificados en tres apartados: programas informáticos de simulación, lenguajes y espacios de programación, y plataformas de soporte computacional.

Software de Simulación

Se empleó Simulation of Urban Mobility (SUMO) para la modelación y el análisis del comportamiento del tráfico vehicular. A través de la configuración de rutas, cruces, semáforos y parámetros de conducción, este software hace posible reproducir con exactitud el flujo de vehículos en áreas urbanas. Se escoge SUMO porque es flexible, puede ser utilizado con varios formatos de datos y tiene la capacidad de incorporar scripts externos en Python, lo que permite comunicarse con algoritmos de IA. La creación de un mapa digital que represente la red vial de la ciudad analizada, en este caso Comayagua, con datos adquiridos de OpenStreetMap (OSM), es el fundamento del proceso de simulación en SUMO. Después, se crearon flujos de tráfico con cifras estimadas a partir de observaciones efectivas, modificando el número de vehículos, los tiempos de trayecto y los patrones de congestión.



Gracias a este ambiente, fue posible simular situaciones de tráfico realistas, que son esenciales para ensayar y cotejar estrategias de optimización.

Lenguajes y entornos de programación

Se utilizó Python para analizar y procesar los datos, ya que este lenguaje tiene la capacidad de gestionar información y una extensa disponibilidad de bibliotecas de inteligencia artificial y científicas. Algunas de las librerías más utilizadas son:

- **NumPy** proporcionó arreglos multidimensionales y operaciones matemáticas optimizadas, indispensables para manejar matrices, distancias, tiempos de viaje y pesos asociados a las aristas del grafo vial.
- Por su parte, **Pandas** ofrece herramientas sofisticadas para la organización, limpieza y transformación de datos tabulares, permitiendo un manejo ágil de series temporales y tablas de datos que resultan esenciales para preparar la información del tráfico para su análisis posterior.
- **Matplotlib** se empleó como la herramienta principal de visualización del proyecto. Permitió generar gráficos estáticos, diagramas comparativos y representaciones detalladas de flujos, distribuciones y métricas asociadas a la red vial. Su flexibilidad permitió ilustrar tendencias, identificar concentraciones de tráfico y visualizar nodos críticos, facilitando la comprensión del comportamiento de la movilidad urbana.
- Dado que el eje central del estudio es la teoría de grafos, **NetworkX** fue una biblioteca fundamental. Con ella fue posible:
 - Construir grafos dirigidos y ponderados a partir de los datos recopilados.
 - Calcular métricas como centralidades, grado, componentes conexas y caminos mínimos.
 - Detectar nodos vulnerables y analizar la estructura global del sistema vial.

NetworkX permitió traducir la información empírica en representaciones matemáticas ideales para el diagnóstico estructural del tráfico urbano.

- Para extraer y procesar la red vial desde OpenStreetMap se utilizó **OSMnx**, herramienta que permitió convertir datos cartográficos reales en un grafo utilizable dentro del análisis computacional. A través de ella fue posible obtener automáticamente:
 - Nodos (intersecciones)
 - Aristas (segmentos viales)
 - Sentidos de circulación
 - Atributos como longitud, velocidad permitida y tipo de vía

OSMnx facilitó la integración entre datos reales y el modelado por grafos de la red vial.



Plataformas de desarrollo y análisis

Durante la fase de programación y simulación se utilizaron tres plataformas principales:

- **Visual Studio Code (VS Code)**: entorno de desarrollo integrado (IDE) utilizado para escribir, depurar y ejecutar los scripts en Python. Su soporte para extensiones Python permitió un entorno de trabajo ordenado y eficiente.
- **Google Colab**: plataforma en la nube utilizada para el entrenamiento de los modelos de inteligencia artificial y la ejecución de procesos computacionalmente intensivos. Al ofrecer recursos de GPU gratuitos, permitió mejorar los tiempos de procesamiento sin necesidad de contar con hardware avanzado.
- **Microsoft Excel**: herramienta utilizada para organizar los datos generados durante las simulaciones, elaborar tablas comparativas, calcular indicadores clave (velocidad media, flujo, densidad) y crear representaciones gráficas preliminares para análisis.

Hardware y Software

El proyecto se desarrolló en una computadora portátil Lenovo Ideapad S340 15IWL, equipada con procesador Intel Core i5, 8 GB de memoria RAM y 500 GB de almacenamiento interno, con sistema operativo Windows 11. Este equipo ofreció un equilibrio adecuado entre capacidad de procesamiento y portabilidad, permitiendo ejecutar las simulaciones de tráfico, procesar datos y entrenar modelos de inteligencia artificial de manera eficiente. La configuración del hardware fue suficiente para soportar los requerimientos computacionales de SUMO y Python, siempre que los escenarios de simulación se mantuvieran dentro de un tamaño y complejidad moderados.

9.7. Métodos de validación

La **validación** constituye una de las etapas más críticas dentro del proceso metodológico, pues garantiza que el modelo propuesto y las herramientas implementadas cumplan con los objetivos establecidos de manera eficaz, precisa y reproducible. En el presente estudio, la validación se llevó a cabo mediante pruebas de rendimiento del modelo de simulación, evaluación de métricas cuantitativas y análisis de casos de uso específicos que permitieron comprobar la aplicabilidad del sistema en distintos escenarios de tráfico urbano en la ciudad de Comayagua.

9.7.1. Métricas de evaluación del modelo

Para asegurar que los hallazgos logrados mediante el análisis por teoría de grafos y la simulación en SUMO reflejan con precisión la conducta real del sistema vial de Comayagua, la validación es una fase esencial. Para evaluar la pertinencia, la confiabilidad y la



consistencia del modelo desarrollado, este estudio utilizó una mezcla de métodos comparativos y cuantitativos. Estos procedimientos posibilitan comparar los patrones simulados con observaciones empíricas, comprobar la coherencia de las métricas topológicas y examinar el rendimiento del sistema en diferentes contextos. Los métodos más importantes que se usaron fueron:

Validación empírica de campo

Esta técnica se basa en cotejar los resultados que el modelo ha dado (duración de trayectos, puntos de congestión) con las observaciones directas que se han recopilado durante la etapa de diagnóstico.

Se implementó a través de:

- Comparación entre los tiempos de desplazamiento simulados y los que se han medido manualmente en horas de mayor afluencia.
- Comprobación de la coincidencia entre los nodos críticos que se encuentran en el grafo y las intersecciones observadas como problemáticas.
- Verificación de los patrones de congestión que se repiten y se han observado en el campo.

Este procedimiento hace posible establecer si la red modelada replica de manera apropiada la dinámica vehicular real.

Validación estructural del grafo

Se comprobó la estructura de la red vial para asegurarse de que el grafo creado cumpliera con las características esperadas de una red urbana real:

- Conexión apropiada (falta de elementos desconectados en las vías principales).
- Correspondencia entre longitudes reales y pesos dados a los bordes.
- Sucesión lógica entre sentidos de circulación, limitaciones y jerarquías de las vías.
- Relación entre el grado de los nodos y la estructura vial que se puede observar (por ejemplo, en intersecciones primordiales o rotondas).

Antes de llevar a cabo simulaciones, este tipo de validación garantiza que el grafo represente con exactitud la estructura urbana.

Validación del modelo de simulación

Para verificar si el modelo en SUMO reproduce de manera apropiada conductas creíbles del tráfico urbano, se analizó su rendimiento.

La validación abarcó:



- Evaluación de la estabilidad del flujo vehicular en las simulaciones.
- Evaluación de la reacción del sistema a las fluctuaciones en la demanda.
- Verificación de que los patrones emergentes (colas, cuellos de botella, demoras) son congruentes con las conductas anticipadas en situaciones urbanas reales.

Aquellos escenarios cuyos resultados simulados se mantuvieron dentro de parámetros lógicos, basados en la literatura y la observación, fueron considerados plausibles.

Validación comparativa con trabajos y modelos existentes

Se contrastaron los resultados obtenidos con estudios similares en ciudades latinoamericanas de tamaño y estructura comparable, con el fin de verificar:

- Si los niveles de congestión pronosticados son lógicos.
- Si los patrones que se han encontrado (saturación en las horas pico, cuellos de botella en vías arteriales) concuerdan con investigaciones anteriores
- Si las métricas de centralidad y su interpretación concuerdan con lo que la literatura científica dice acerca de la movilidad urbana.

Esta validación facilita el análisis de si la conducta de la red vial en Comayagua se ajusta a patrones típicos en ciudades que están creciendo.

9.7.2. Casos de uso

Finalmente, se desarrollaron casos de uso concretos con el propósito de validar el modelo en diferentes condiciones operativas. Estos escenarios permitieron analizar la respuesta del sistema ante variaciones en el flujo vehicular, cambios en la infraestructura y modificaciones en el comportamiento del tránsito. Los casos más relevantes fueron los siguientes:

Caso 1 Condición base (hora valle):

Se simuló la operación del tráfico bajo condiciones normales, con un volumen promedio de 300 vehículos por hora. Este escenario fue utilizado para calibrar los parámetros iniciales del modelo y establecer una línea de referencia que sirviera como punto de comparación para los demás casos.

Caso 2 Condición de congestión (hora pico):

Se incrementó la demanda vehicular en un 30 % con respecto al caso base, con el objetivo de analizar el efecto sobre la velocidad promedio y los tiempos de recorrido. Este escenario permitió verificar la capacidad del modelo para representar situaciones de saturación y la formación de cuellos de botella dentro de la red vial.



Caso 3 Escenario de contingencia:

Se simuló la sustitución de un semáforo por una rotonda, lo que implicó modificar la estructura del grafo mediante la eliminación de la arista asociada al cruce semaforizado y la incorporación de nuevas conexiones que representan el flujo circular. Esta intervención permitió analizar la capacidad del modelo para adaptarse a cambios en la infraestructura vial y evaluar cómo se redistribuye el tráfico ante transformaciones físicas como obras, re-diseños geométricos o mejoras operativas.





Parte IV

IMPLEMENTACIÓN DE LA PROPUESTA TECNOLÓGICA

10

Implementación

Contenido del Capítulo

10.1. Diseño de la Solución tecnológica	83
10.1.1. Arquitectura general del sistema	84
10.1.2. Flujo de procesos	85
10.2. Implementación	86
10.2.1. Preparación y estructuración de los datos	86
10.2.2. Desarrollo del modelo de análisis basado en teoría de grafos	86
10.2.3. Integración con la simulación de tráfico	87
10.2.4. Entorno de desarrollo y herramientas utilizadas	89
10.2.5. Validación inicial del sistema	89
10.3. Pruebas y resultado preliminares	89
10.3.1. Análisis de la red vial mediante la teoría de grafos	89
10.3.2. Pruebas de simulación en SUMO	90
10.3.3. Pruebas de carga	91

10.1. Diseño de la Solución tecnológica

El diseño de la solución tecnológica es un paso fundamental en el proyecto, pues establece la estructura técnica y conceptual del sistema que se dirige a analizar y optimizar la circulación de vehículos utilizando teoría de grafos. Este método posibilita representar la red vial de Comayagua como un grafo ponderado, en el que las aristas son las vías de circulación y los nodos son las intersecciones. Se les asignan características como longitud, capacidad y velocidad máxima. El propósito es crear una herramienta que sea pertinente, versátil y acorde con la realidad de la ciudad.

La estructura del sistema se organiza bajo un **diseño modular**, integrando cuatro componentes principales:

- **Captura y organización de datos:** la recolección de datos sobre la movilidad vehicular se realiza en este módulo, utilizando técnicas de observación directa y fuentes de información georreferenciadas, como OSM. Se organizan y limpian los datos para crear el grafo vial y determinar las características necesarias de aristas y nodos.
- **Análisis de la red vial mediante teoría de grafos:** aquí se utilizan algoritmos y métricas de grafos, como caminos mínimos y centralidad, así como la detección de nodos críticos, para detectar cuellos de botella, rutas eficaces y debilidades en la infraestructura vial. Este análisis posibilita entender la topología de la red y prever cómo se comportará el flujo de vehículos en diferentes situaciones.
- **Simulación del tráfico:** se utiliza SUMO para simular el comportamiento de los vehículos en la red de grafos. Este módulo posibilita la realización de diferentes escenarios, el análisis de cómo repercuten las modificaciones en el flujo y la evaluación de cómo se distribuye el tráfico en situaciones normales, de congestión o de contingencia.
- **Presentación y estudio de resultados:** los datos obtenidos a partir de la simulación y el análisis se procesan y visualizan por medio de herramientas adicionales como Excel y entornos de programación como Python. Se producen gráficos, diagramas de flujo y métricas que hacen más sencillo el análisis de los resultados y la toma de decisiones.

Desde la perspectiva modular, esta arquitectura permite que la mantenibilidad y escalabilidad del sistema sean sencillas. Esto posibilita que la implementación de modificaciones futuras en la red vial, incorporación de sensores urbanos o integración con sistemas IoT no alteren la estructura general del modelo. Asimismo, la utilización de grafos ofrece una representación exacta y adaptable del sistema vial, lo cual es esencial para planificar y mejorar la movilidad urbana en Comayagua.



10.1.1. Arquitectura general del sistema

La arquitectura del sistema se estructura en cuatro niveles interconectados, los cuales se han creado para mostrar de forma precisa el recorrido de la información desde que es recolectada hasta que se visualizan los resultados:

- **Capa de obtención de datos:** esta capa alberga toda la información que se ha reunido acerca de la movilidad urbana en Comayagua. Se adquirieron los datos a través de observación directa. Combinan el número de vehículos, los horarios con mayor tráfico y las particularidades de las vías.
- **Capa de análisis con grafos:** se desarrolla y analiza la red vial en esta capa, utilizando herramientas informáticas y matemáticas que se fundamentan en la teoría de grafos. Las principales tareas que realiza son:
 - Edificación del grafo vial utilizando OSMnx, una biblioteca especializada en la descarga, modelado y proyección de redes urbanas directamente desde OpenStreetMap.
 - Análisis y procesamiento de la estructura con NetworkX, lo que posibilita el cálculo de métricas esenciales como:
 - el grado de los nodos,
 - rutas mínimas,
 - centralidades (grados de cercanía, grados de intermediación y grados),
 - detección de cuellos de botella y nodos decisivos.
 - Conversión del mapa vial en un grafo dirigido o no dirigido, dependiendo de las características de las carreteras.
 - Acondicionamiento de la red para exportarla a ambientes de simulación.
La combinación de OSMnx y NetworkX posibilita realizar un análisis sólido, replicable y basado en matemáticas del comportamiento de la red.
- **Capa de simulación:** En esta capa, se incorpora el grafo vial al simulador SUMO, lo que da lugar a un ambiente digital en el que se simulan diferentes situaciones de tráfico: condiciones normales, congestión o contingencias. La simulación posibilita la evaluación del efecto de las fluctuaciones en el tránsito vehicular y la exploración de la redistribución del tráfico según la topología de la red, confirmando así los patrones estructurales que se identificaron en la capa previa.
- **Capa de resultados:** esta capa muestra los resultados del análisis y la simulación a través de gráficos, empleando herramientas como hojas de cálculo y Matplotlib. Esta capa ayuda a interpretar la información, identificar patrones significativos y generar insumos para tomar decisiones acerca de la gestión de la movilidad urbana.

Este diseño por capas permite una **integración modular y escalable**, donde cada componente puede actualizarse o ajustarse sin afectar la totalidad del sistema, asegurando que la



red vial y los escenarios simulados puedan adaptarse a futuros cambios en la infraestructura urbana o nuevas estrategias de movilidad.

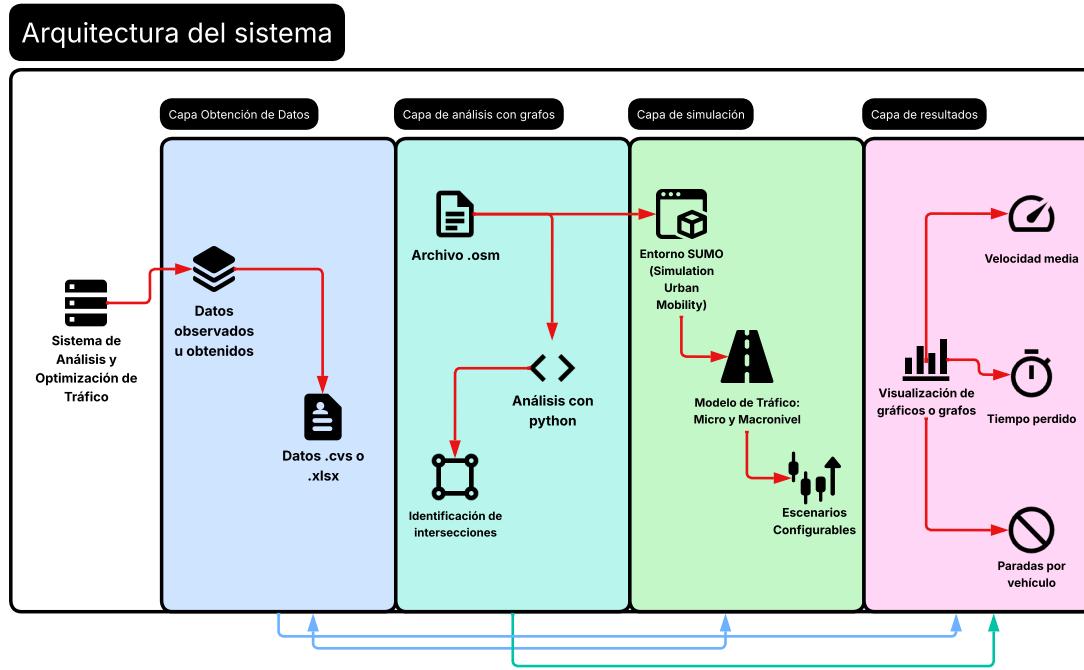


Figura 10.1: Arquitectura del Sistema de Análisis y Optimización del Tráfico Vehicular. Fuente: Elaboración propia.

10.1.2. Flujo de procesos

El recorrido operativo del sistema, conocido como flujo de procesos, se encarga de convertir la información reunida del tráfico datos sobre volumen, velocidad, densidad en hallazgos que ayudan a tomar buenas decisiones sobre cómo manejar el transporte, tanto a nivel estratégico como operativo. Pero ojo, esta conversión no es directa; más bien, sigue un ciclo estricto y permanente. El flujo tiene seis fases clave, puestas en orden en un circuito que va del análisis a la simulación y luego a la retroalimentación, todo para que el sistema mejore sin parar.

- Recolección de datos
- Análisis de la red vial (teoría de grafos)
- Simulación del tráfico (SUMO)
- Visualización de resultados

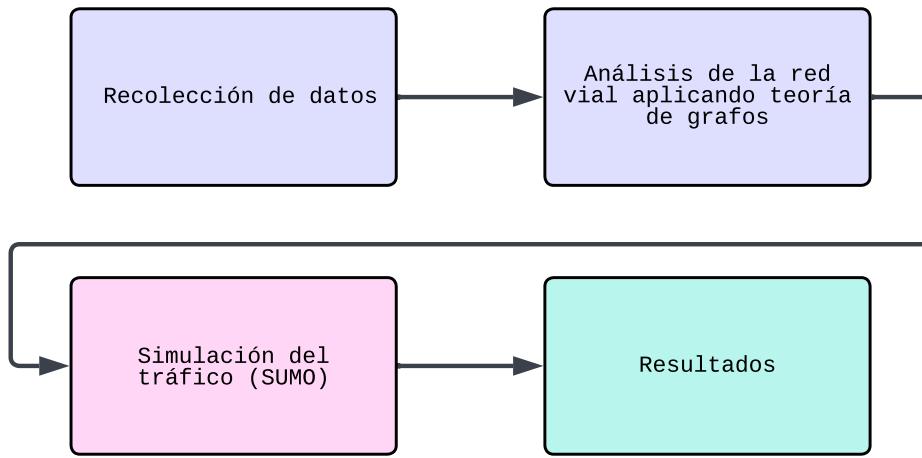


Figura 10.2: Flujo de procesos del Sistema de Análisis y Optimización del Tráfico Vehicular. Fuente: Elaboración propia.

10.2. Implementación

10.2.1. Preparación y estructuración de los datos

El procedimiento inició con la recogida y la estructuración de los datos observacionales que se habían recopilado en las avenidas y las intersecciones más relevantes de Comayagua. Los datos se volcaron en una hoja de cálculo de Microsoft Excel, en la que constituimos campos de datos como: la hora, el tipo de vehículo, la cantidad, la velocidad estimada y el tiempo medio de espera.

El siguiente paso fue llevar a cabo un proceso de limpieza y de normalización de los datos. Se eliminaron valores incorrectos o fuera de rango y, por medio de este proceso, se definieron promedios representativos a intervalos de tiempo. La labor de preparación de los datos fue muy importante para obtener una coherencia en las variables antes de ser volcada el modelo predictivo.

10.2.2. Desarrollo del modelo de análisis basado en teoría de grafos

El modelo de análisis fue desarrollado en Google Colab, aprovechando su compatibilidad con librerías especializadas para el tratamiento de datos y análisis de redes como Pandas, NumPy, Matplotlib, OSMnx y NetworkX. La construcción y evaluación del modelo se organizaron en tres bloques fundamentales:

- **Importación de datos y creación del gráfico vial:** la cartografía vial fue obtenida a través de OSMnx, lo que posibilitó la extracción de la red vial desde OpenStreetMap.

Luego, se creó un grafo dirigido (DiGraph) en el que:

- Las intersecciones son representadas por los nodos.
- Los arcos son segmentos de vía.
- A cada arco se le asignaron características como la velocidad permitida, la longitud, el tipo de vía y la demanda proyectada.

Antes de llevar a cabo el análisis estructural, se llevaron a cabo visualizaciones iniciales utilizando histogramas, mapas y tablas; esto posibilitó entender cómo se distribuyó el tráfico en términos espaciales y temporales.

- **Construcción y análisis del modelo basado en grafos:** después de que la red vial fue estructurada, se pusieron en práctica métricas de teoría de grafos para examinar su funcionamiento y encontrar patrones significativos. Las métricas utilizadas abarcaron:

- Centralidad de grado y betweenness: para determinar los nodos y aristas que ejercen una influencia más notable en el flujo vehicular.
- Dijkstra: cálculo de rutas más cortas para estimar caminos óptimos en función del tiempo o la distancia.
- Identificación de cuellos de botella: a través del reconocimiento de aristas con carga relativa alta.
- Análisis de conectividad: con el fin de valorar la redundancia y la vulnerabilidad de la red.

La combinación de OSMnx y NetworkX posibilitó el manejo del grafo y la realización de algoritmos para el análisis estructural de manera exacta, sin recurrir a modelos predictivos.

- **Interpretación y visualización de los resultados:** por último, se elaboraron mapas y gráficos que revelaron:

- • Los caminos con mayor probabilidad de congestión y centralidad.
- • Porciones que funcionan como conexiones esenciales dentro de la red.
- • Distribución territorial del flujo vehicular calculado tomando como base la estructura del grafo.

Las visualizaciones posibilitaron la comparación de las métricas topológicas con los datos reales del tráfico, lo que validó la consistencia del modelo y facilitó el reconocimiento de las zonas más vulnerables en la red vial estudiada.

10.2.3. Integración con la simulación de tráfico

Una vez desarrollado y validado el modelo de análisis basado en teoría de grafos, este se integró con SUMO, herramienta open-source ampliamente utilizada en estudios académicos para simular redes de transporte urbano. La simulación permitió reproducir digitalmente

las condiciones del tráfico urbano de Comayagua y evaluar cómo la estructura y características del grafo influyen en el comportamiento vehicular bajo distintos escenarios. El proceso se llevó a cabo en las siguientes etapas:

Creación del mapa urbano

Se creó un archivo .net.xml que muestra la red vial principal de Comayagua, con avenidas, cruces y direcciones de tránsito. Para ello, se extrajeron las coordenadas y atributos viales desde OpenStreetMap y luego se convirtieron a un formato que SUMO puede procesar. En áreas de baja importancia, el mapa se simplificó; sin embargo, las zonas con más densidad de tráfico, que se identificaron mediante el análisis topológico del grafo, se conservaron con precisión.

Definición de flujos de vehículos

Se generaron archivos .rou.xml a partir de los cuales se definieron los tipos de vehículos (automóviles, buses, camiones, motocicletas) junto con sus rutas más utilizadas. Estos flujos fueron calibrados en función de los datos observacionales.

Simulación y control de tráfico

Se ejecutaron múltiples simulaciones considerando distintos escenarios: horas pico, horas valle, modificaciones en la demanda y variaciones estructurales menores. SUMO permitió registrar métricas como:

- velocidad media por segmento,
- tiempos de espera en intersecciones,
- densidad vehicular por tramo,
- y número de detenciones por nodo.

Toda la información fue exportada en archivos .xml y .csv, los cuales almacenan de forma estructurada los resultados detallados de cada escenario.

Análisis de escenarios

Los datos exportados se procesaron nuevamente en Python para comparar el desempeño de la red vial bajo diferentes configuraciones estructurales del grafo. A partir del análisis fue posible:

- identificar segmentos críticos,
- evaluar la sensibilidad del sistema a cambios en la demanda,
- comparar la eficiencia entre rutas alternativas,
- y examinar cómo la estructura topológica influye en la fluidez global del tráfico.

Los resultados permitieron evaluar la red desde una perspectiva analítica sin recurrir a



modelos predictivos, basándose únicamente en métricas de teoría de grafos y comportamiento simulado.

10.2.4. Entorno de desarrollo y herramientas utilizadas

El desarrollo completo del sistema se llevó a cabo utilizando los siguientes recursos tecnológicos:

- Lenguaje de programación: Python 3.11
- Entornos de trabajo: Google Colab y Visual Studio Code
- Software de simulación: SUMO (versión 1.19.0)
- Gestión de datos: Microsoft Excel

Equipo de desarrollo: PC Lenovo Ideapad S340 15IWL, procesador Intel Core i5, 8 GB RAM, 500 GB SSD, sistema operativo Windows 11. Estos elementos permitieron un flujo de trabajo eficiente, combinando potencia de cálculo local y recursos en la nube para la ejecución de tareas de análisis y simulación intensivas.

10.2.5. Validación inicial del sistema

El proceso de implementación incluyó la realización de pruebas iniciales utilizando diferentes volúmenes de datos y configuraciones de simulación. El sistema era capaz de procesar los datasets experimentales sin errores y de generar reportes automáticos de congestión.

10.3. Pruebas y resultado preliminares

10.3.1. Análisis de la red vial mediante la teoría de grafos

El análisis de la infraestructura vial del municipio de Comayagua se llevó a cabo mediante el uso del lenguaje de programación **Python** en el entorno de **Google Colaboratory**, una plataforma clave para el desarrollo de proyectos de análisis de datos y machine learning. La metodología implementada se basó en el modelado de la red vial como un grafo a partir de datos geográficos. Para ello, se emplearon las librerías especializadas **OSMnx** y **NetworkX**, que facilitaron tanto la descarga de la información de la red como la subsiguiente generación de la estructura del grafo. Tras el análisis topológico, se logró la identificación de las aristas críticas (o enlaces cruciales) del sistema. A estas se les asignó una alta ponderación debido a su significación estructural: su inhabilitación o interrupción del flujo vehicular generaría un impacto sustancial en la conectividad de toda la red, obligando a los usuarios a recurrir a rutas alternativas cuya longitud resultaría significativamente mayor. Este hallazgo subraya la vulnerabilidad de la red ante fallas en puntos clave.



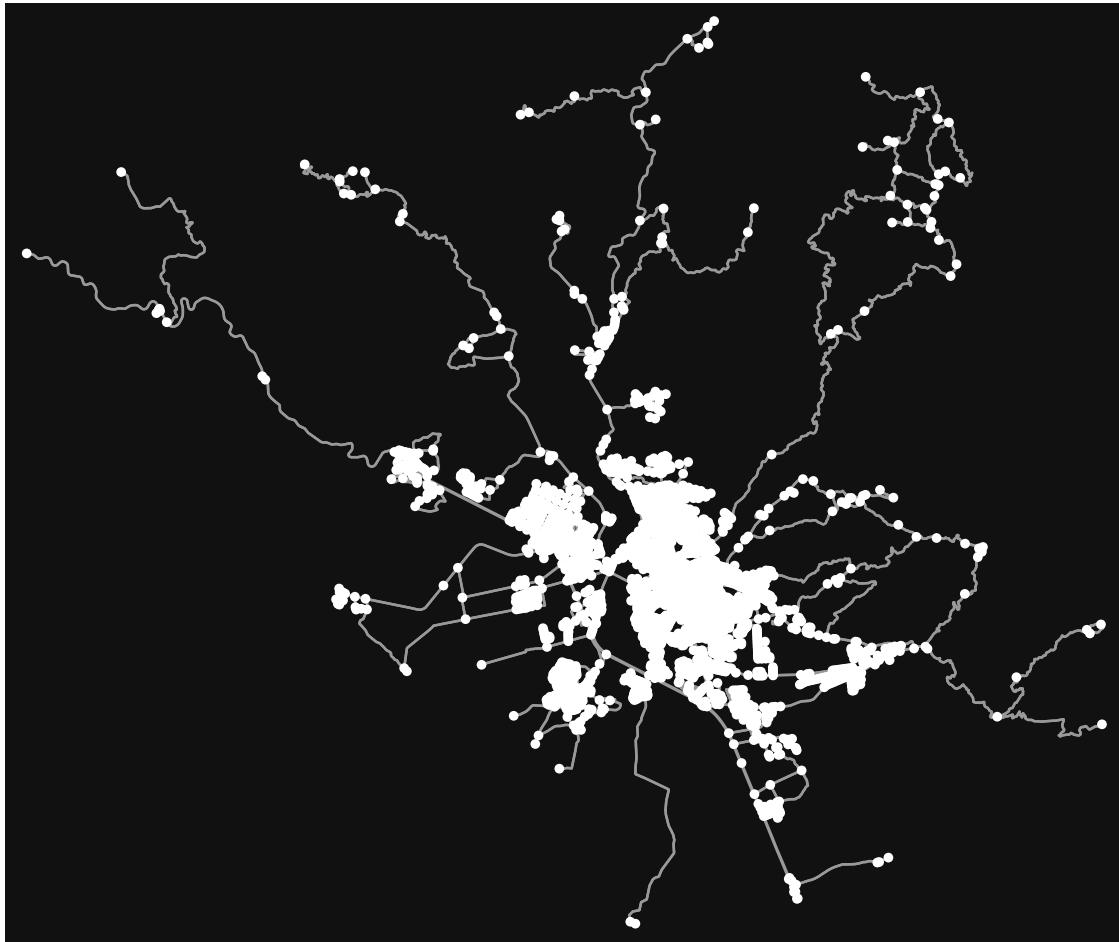


Figura 10.3: Grafo inicial de la red vial de la Ciudad de Comayagua. Fuente: Elaboración propia.

10.3.2. Pruebas de simulación en SUMO

La evaluación inicial del modelo se llevó a cabo utilizando los escenarios base, los cuales se construyeron a partir de la data empírica recolectada mediante métodos de observación. Como parte del proceso de refinamiento metodológico, fue necesaria la modificación del diseño de una de las arterias viales, lo cual se atribuyó a una generación inconsistente de su representación en la fase de modelado. Posteriormente, se procedió a la simulación del flujo vehicular que caracteriza las principales carreteras de la ciudad. Este proceso permitió cuantificar y mapear la demanda de tráfico, logrando identificar y especificar numéricamente la cantidad de vehículos que transitan por las zonas de mayor congestión observada. Esta fase es crucial para la validación y la calibración del modelo de red.

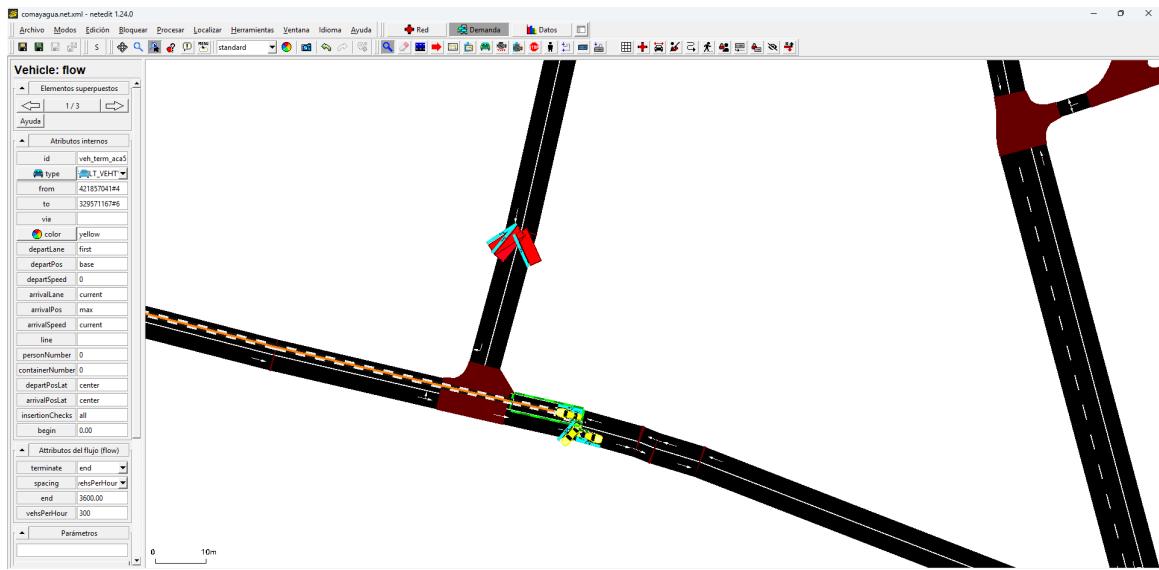


Figura 10.4: Configuración del flujo vehicular en Netedit. Fuente: Elaboración propia.

10.3.3. Pruebas de carga

Se llevaron a cabo pruebas de sensibilidad incrementales con el propósito de evaluar la resiliencia y capacidad de la red vial frente a diversos escenarios de demanda futura. Específicamente, se modelaron dos condiciones críticas:

- **Escenario Proyectado:** Se aplicó un incremento en el flujo vehicular que corresponde al porcentaje de crecimiento estimado para el horizonte temporal de 2030.
- **Escenario de Capacidad Máxima:** Se simuló una etapa de saturación potencial, donde el volumen de tráfico se duplica con respecto a los valores registrados en el escenario base.

Estas simulaciones son esenciales para determinar los umbrales de servicio, identificar puntos de falla prematura en la infraestructura y predecir el desempeño del sistema vial ante incrementos significativos en la movilidad urbana.

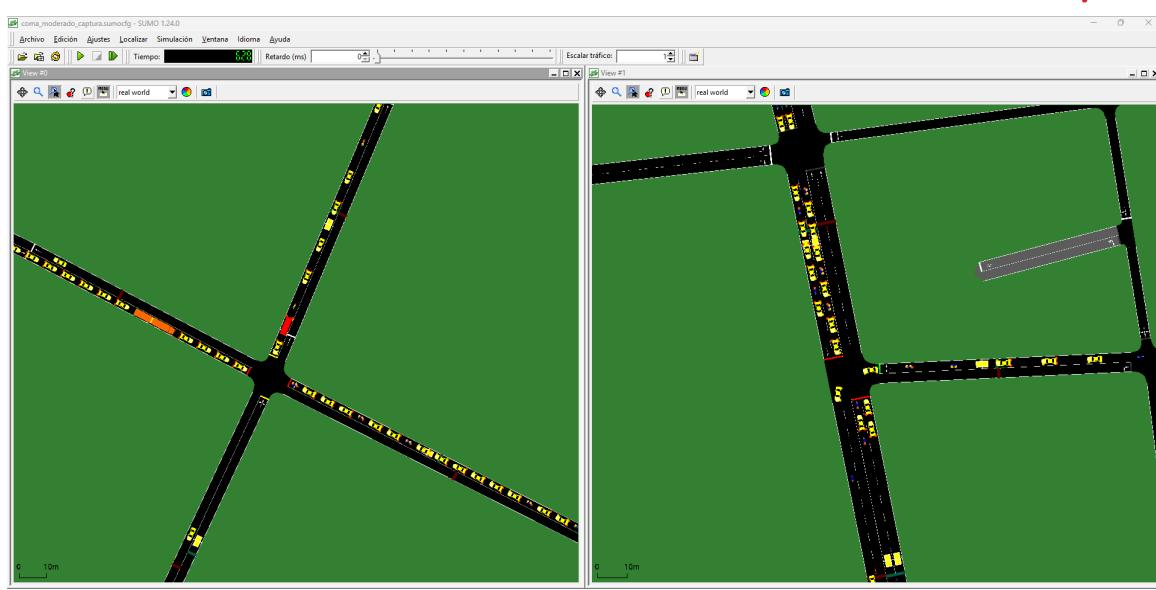
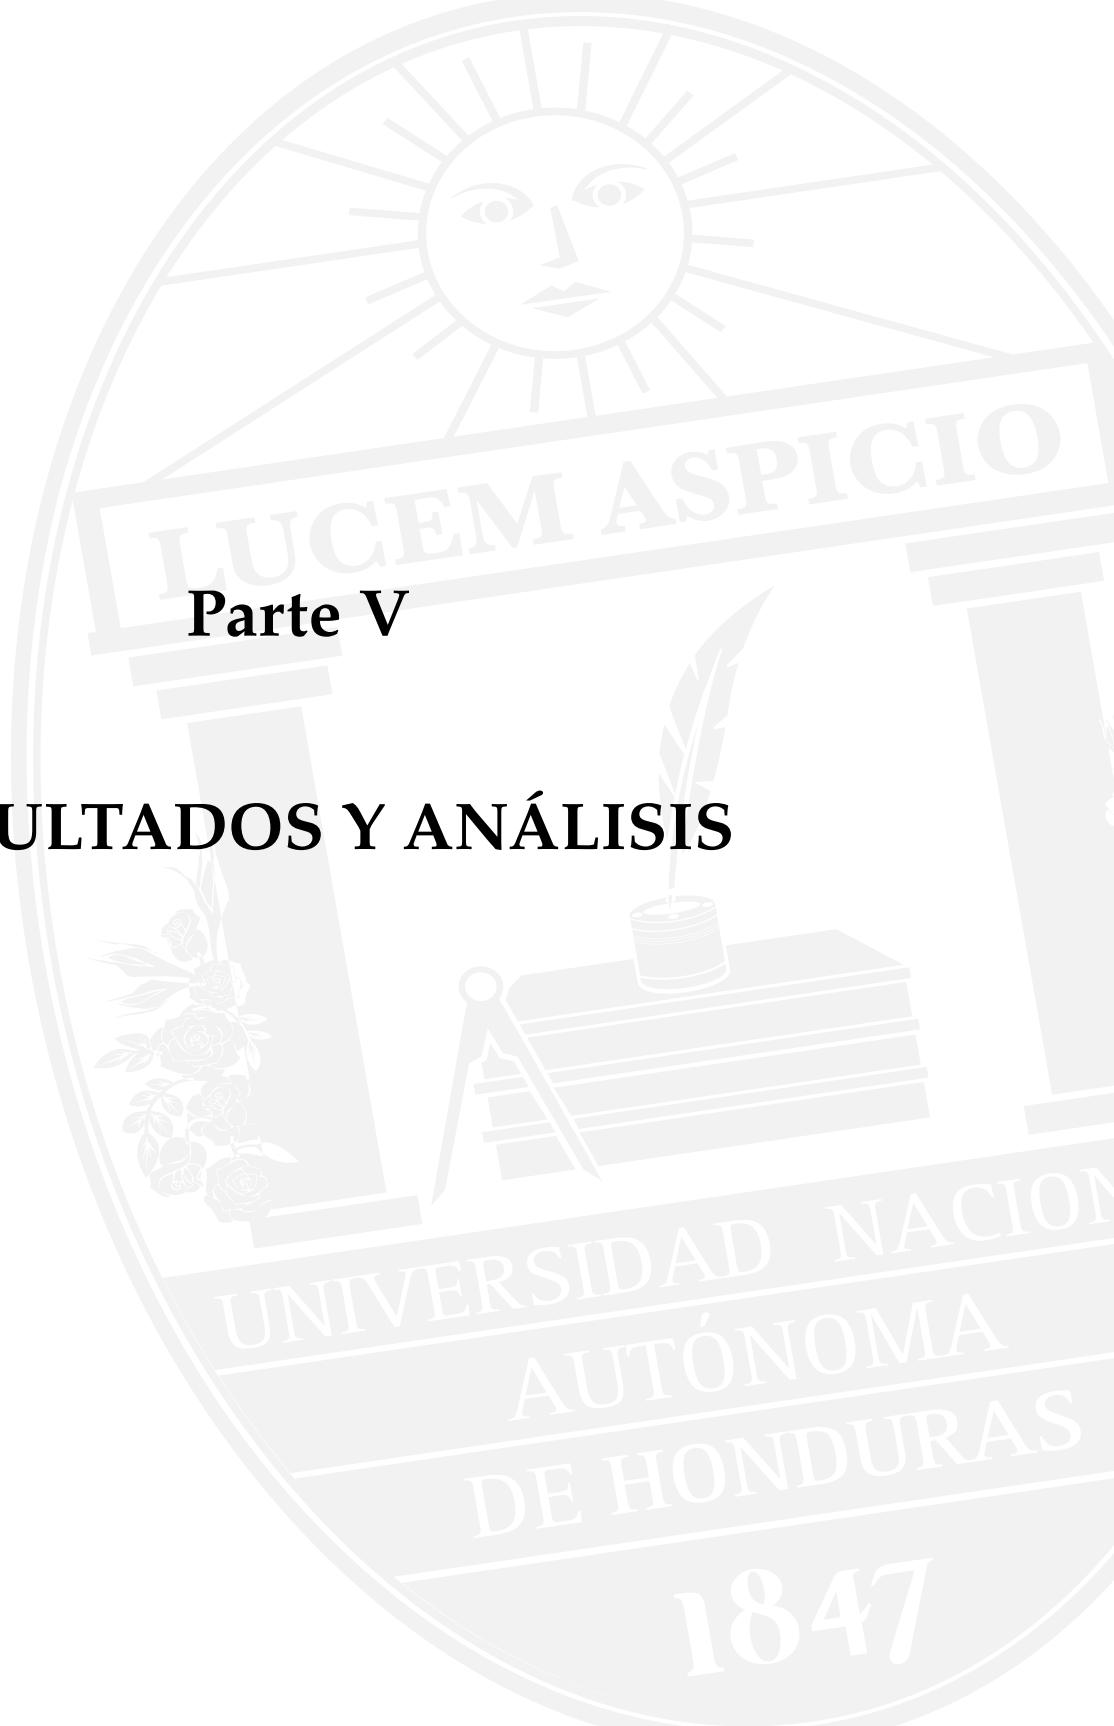


Figura 10.5: Simulación de escenarios en SUMO-GUI. Fuente: Elaboración propia.



RESULTADOS Y ANÁLISIS

Parte V

LUCEM ASPICIO

**UNIVERSIDAD NACIONAL
AUTÓNOMA
DE HONDURAS**

1847

11

Resultados y Análisis

Contenido del Capítulo

11.1. Presentación de Resultados	95
11.2. Interpretación y análisis de los resultados obtenidos	105
11.2.1. Análisis de Escenarios de Demanda Creciente	106
11.2.2. Evaluación de la Propuesta de Mitigación (Rotonda vs. Semáforo) . .	107
11.3. Comparación con Investigaciones Previas o Estándares	107
11.3.1. Niveles de Servicio (NdS) y Vulnerabilidad	108
11.3.2. Comparación de Soluciones: Semáforo vs. Rotonda	108
11.4. Validación de objetivos planteados	109

11.1. Presentación de Resultados

Los resultados que se lograron después del análisis estructural de la red, la elaboración del grafo vial y la realización de las simulaciones en SUMO en varios escenarios (congestión, condición base y reemplazo de rotonda por semáforo) se presentan en esta sección. Se muestran los resultados a través de gráficos de tendencia y métricas cuantitativas, que posibilitan examinar el funcionamiento general del sistema de movilidad.

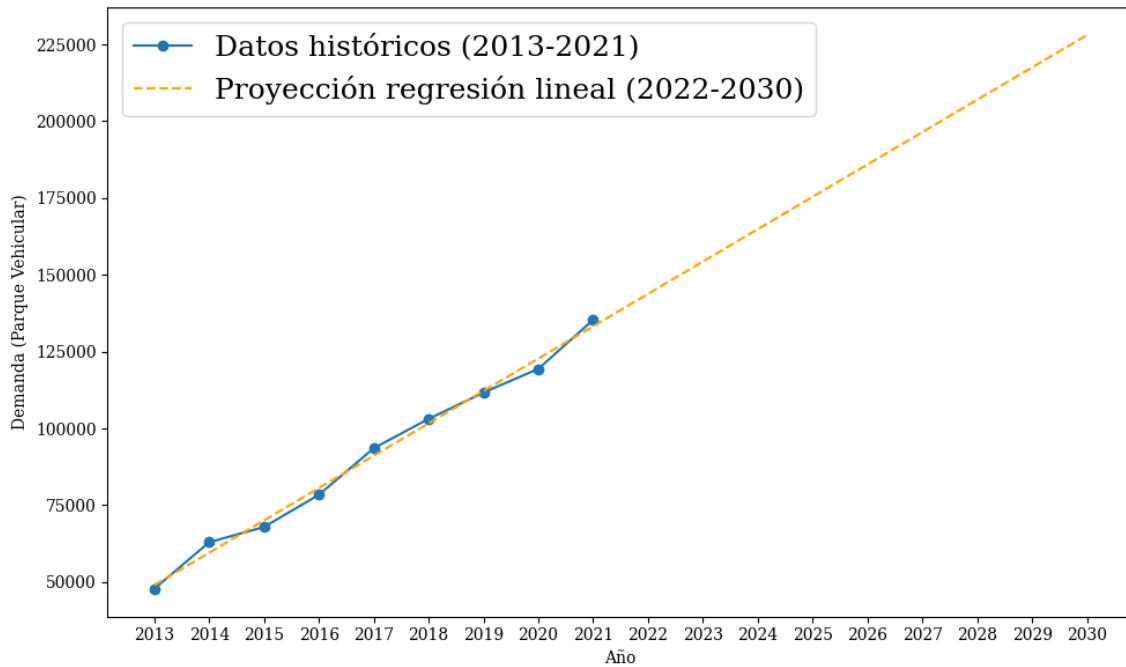


Figura 11.1: Pronóstico del Parque Vehicular en Honduras. Fuente: Elaboración propia.

Esta gráfica muestra un modelo de regresión lineal que se utiliza para analizar el desarrollo del parque vehicular en Comayagua. Se basa en datos históricos del Instituto Nacional de Estadística (INE) entre 2013 y 2021, los cuales indican una tendencia de crecimiento sostenido y con una correlación significativa. Para 2030, se prevé que la flota de vehículos excederá las 225,000 unidades, lo que representa un aumento cercano al 30 % en comparación con la estimación del parque actual. Este patrón lineal revela una etapa de expansión de la motorización, que no muestra señales de saturación desordenada y prevé una presión creciente sobre la infraestructura vial y el planeamiento urbano regional en la próxima década.

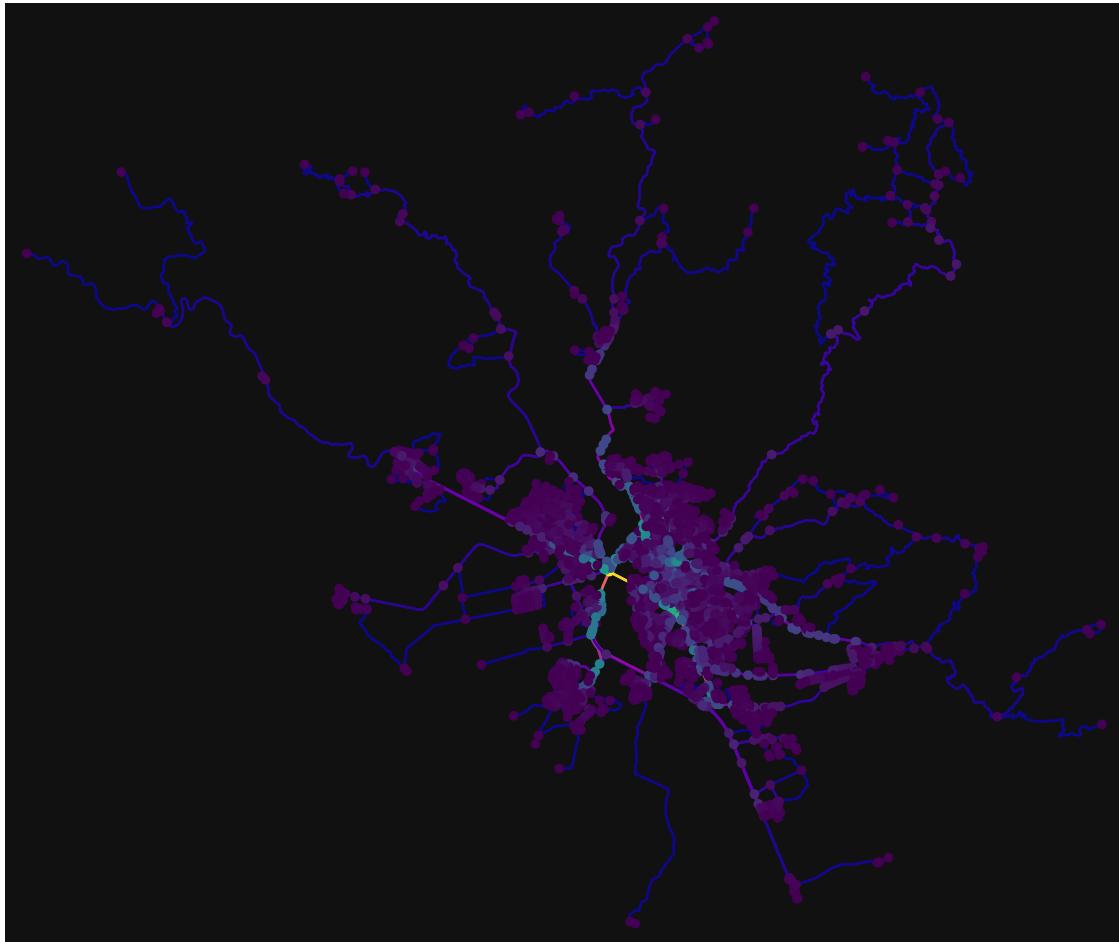


Figura 11.2: Análisis Topológico y de Vulnerabilidad: Centralidad de Intermediación de la Red Vial de Comayagua. Fuente: Elaboración propia.

Esta representación topológica, probablemente producida a través de análisis de grafos, muestra la centralidad de intermediación en la red vial de Comayagua. Los nodos (intersecciones) y las aristas (calles) están codificados cromáticamente para señalar su jerarquía funcional; el núcleo central presenta una concentración de tonos claros (amarillo y cian), lo que marca los únicos puntos de falla en la red. Esto indica que un alto porcentaje de las rutas más cortas tienen que pasar por un número limitado de segmentos y nudos. Por lo tanto, si estas áreas críticas se bloquean o inhabilitan, la conectividad total del sistema se vería gravemente afectada, provocando una ineficiencia no lineal en los tiempos de viaje y evidenciando una escasa redundancia estructural frente a cualquier alteración vial.

Habiendo identificado la intersección como nodo crítico dentro de la red vial, se procedió a la modelización micro-simulada de tráfico para evaluar su impacto operativo y cuantificar su desempeño en condiciones dinámicas. De esta aproximación metodológica se extrajeron indicadores clave de rendimiento (KPIs), permitiendo la medición precisa de las condicio-

nes de flujo vehicular a través de la velocidad media, la pérdida de tiempo y paradas por vehículo.

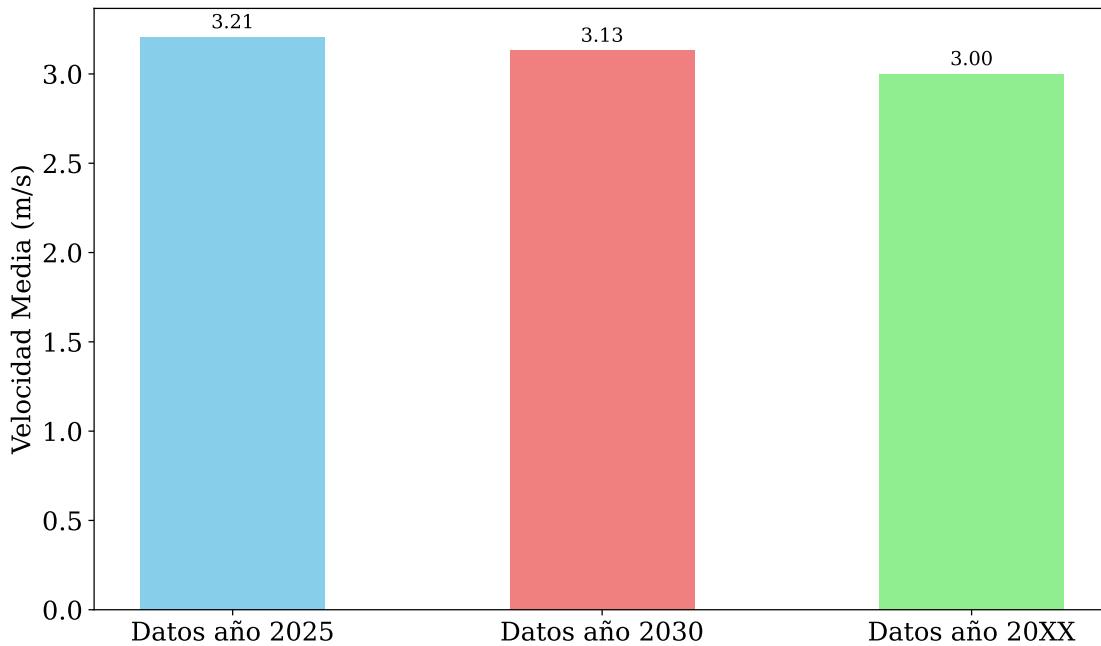


Figura 11.3: Simulación de Velocidad Media bajo Escenarios de Crecimiento Vehicular. Fuente: Elaboración propia.

El gráfico de barras presenta una comparativa de la velocidad media (**m/s**) de circulación para una intersección específica de Comayagua bajo tres escenarios proyectados, sirviendo como un indicador clave de rendimiento operacional de la red vial. Los "Datos año 2025"(escenario actual) establecen la línea base con **3,21 m/s**; la proyección al "Datos año 2030"(escenario de crecimiento lineal) muestra una ligera disminución a **3,13 m/s**, reflejando una moderada afectación por el incremento vehicular predicho. No obstante, el escenario hipotético de estrés máximo ("Datos año 20XX"), en el que se duplica el parque vehicular, provoca una caída notable de la velocidad media a **3,00 m/s**; esta diferencia progresiva confirma la sensibilidad de la intersección al volumen de tráfico, sugiriendo que, si bien la infraestructura puede absorber el crecimiento proyectado a 2030 con un impacto mínimo, el incremento exponencial del parque vehicular resultaría en una degradación significativa de la fluidez operacional.

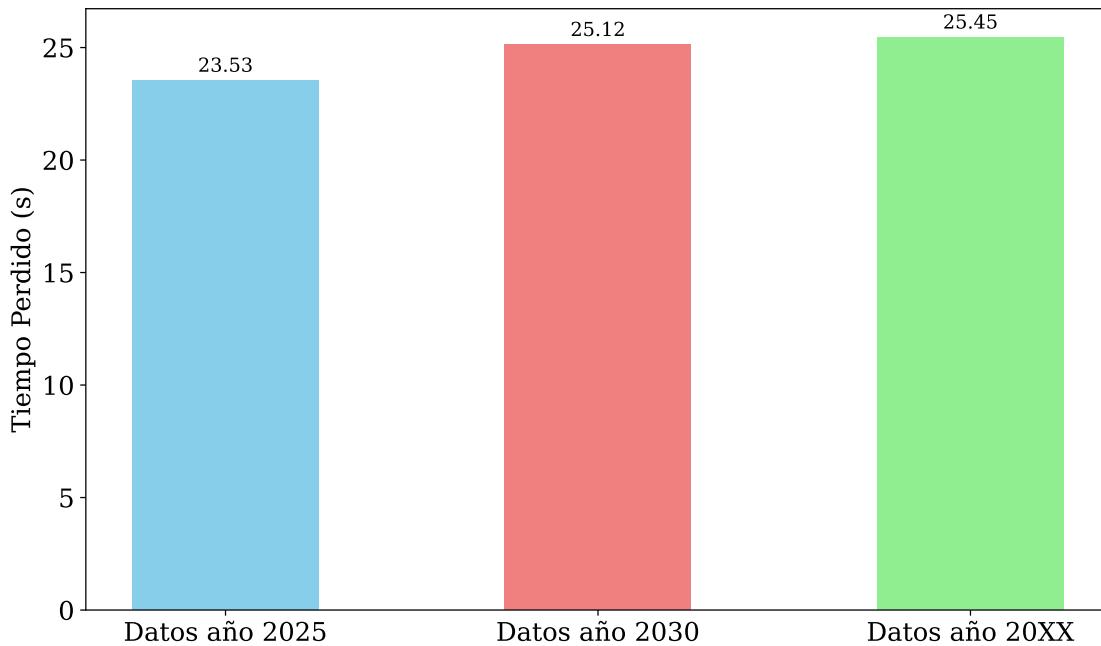


Figura 11.4: Simulación de Pérdida de Tiempo bajo Escenarios de Crecimiento Vehicular. Fuente: Elaboración propia.

El gráfico de barras ilustra la pérdida de tiempo promedio (**en segundos**) experimentada por los vehículos al transitar por la intersección crítica, un indicador clave del nivel de congestión y fricción en el flujo, bajo los tres escenarios de crecimiento vehicular planteados. En el escenario actual ("Datos año 2025"), la pérdida de tiempo es de **23,53 s**. La proyección hacia el "Datos año 2030" muestra un aumento significativo a **25,12 s**, confirmando que la expansión vehicular proyectada ejercerá una presión perceptible sobre el sistema, resultando en una mayor ineficiencia temporal. Finalmente, el escenario de estrés máximo ("Datos año 20XX"), que simula la duplicación del parque vehicular, induce la mayor pérdida de tiempo, alcanzando **25,45 s**; este incremento marginal respecto a 2030 (25,45 s vs 25,12 s) sugiere que, si bien la congestión se intensifica con el crecimiento, la intersección podría estar cercana a su punto de saturación, donde las penalizaciones temporales adicionales, aunque existentes, se vuelven menos dramáticas en comparación con la transición de 2025 a 2030.

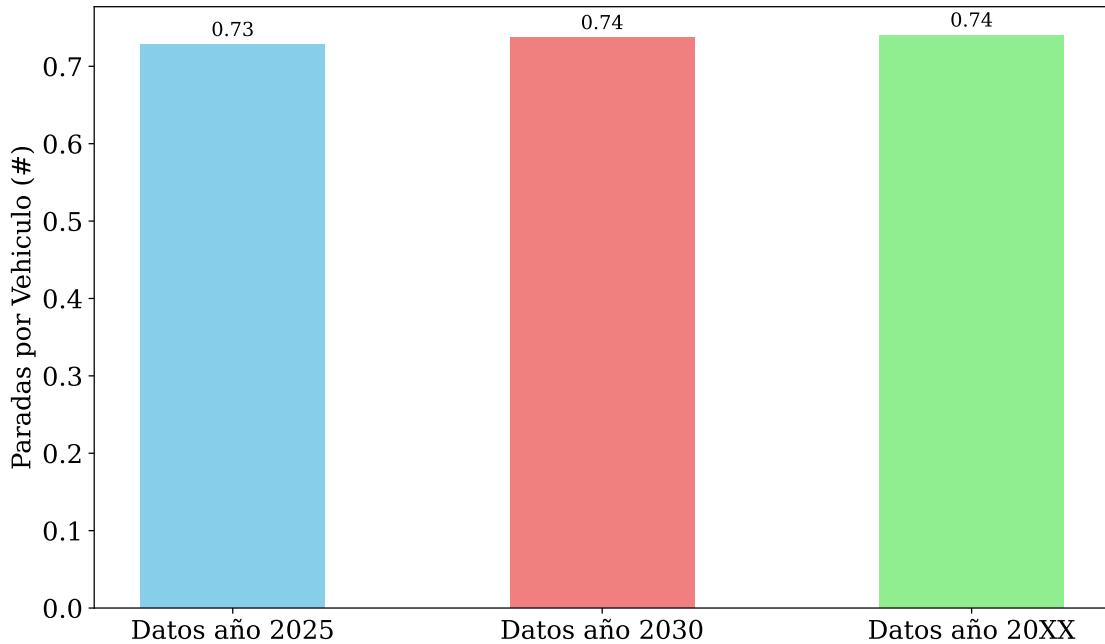


Figura 11.5: Simulación de Paradas por Vehículo bajo Escenarios de Crecimiento Vehicular. Fuente: Elaboración propia.

El gráfico de barras presenta la comparativa de la tasa de detenciones (o paradas) por vehículo en la intersección crítica bajo los tres escenarios de demanda vehicular, sirviendo como métrica de la fricción operativa y la calidad del servicio del flujo. En el escenario actual de "Datos año 2025", cada vehículo experimenta un promedio de 0.73 paradas en la intersección. La proyección para el "Datos año 2030" muestra un incremento marginal a 0.74 paradas por vehículo, indicando que la estructura semafórica o de control de la intersección mantiene una robustez notable frente al crecimiento vehicular anticipado. De manera crucial, el escenario extremo de "Datos año 20XX", con el parque vehicular duplicado, mantiene esta misma tasa de 0.74 paradas por vehículo, lo que sugiere que la saturación del flujo está primariamente afectando la duración de las detenciones (tiempo perdido) y la velocidad de desplazamiento, más que la frecuencia de las detenciones en sí mismas; en esencia, aunque los vehículos tienen que esperar más tiempo, la probabilidad de ser detenidos por unidad sigue siendo constante en los escenarios futuros analizados.

Una vez confirmado el punto como nodo crítico de la red vial a través del análisis de centralidad, se procedió a formular una estrategia de mitigación de la congestión. Dado que la intersección ya operaba bajo **control semafórico**, la intervención propuesta consistió en la reconfiguración geométrica de la misma, modelando específicamente la sustitución del semáforo por una glorieta (**rotonda**). Los resultados de la simulación de este nuevo escenario operacional se detallan a continuación.

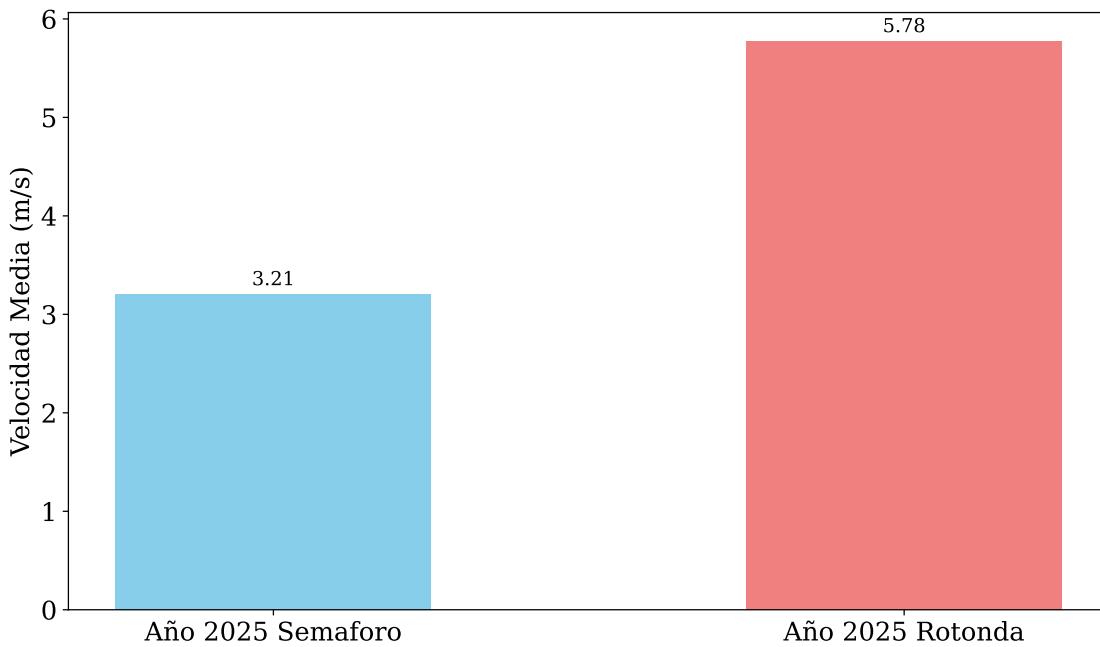


Figura 11.6: Impacto de la Rotonda en la Velocidad Media. Fuente: Elaboración propia.

El gráfico de barras presenta una comparativa de la velocidad media (m/s) de circulación en la intersección crítica de Comayagua bajo el volumen vehicular proyectado para el año 2025, contrastando el sistema de control semafórico existente con la propuesta de reconfiguración geométrica a rotonda. El escenario actual con semáforo registra una velocidad media de 3,21 m/s, estableciendo la línea base de la eficiencia operativa del nodo. Por el contrario, la simulación de la implementación de la rotonda demuestra una mejora significativa en el flujo vehicular, elevando la velocidad media a 5,78 m/s. Este incremento del $\approx 80\%$ en la velocidad de circulación valida la hipótesis de que la sustitución del control intermitente por el flujo continuo de la glorieta mitiga de manera sustancial la fricción del tráfico, mejorando la fluidez y el rendimiento del nodo crítico bajo las condiciones de demanda actuales proyectadas para 2025.

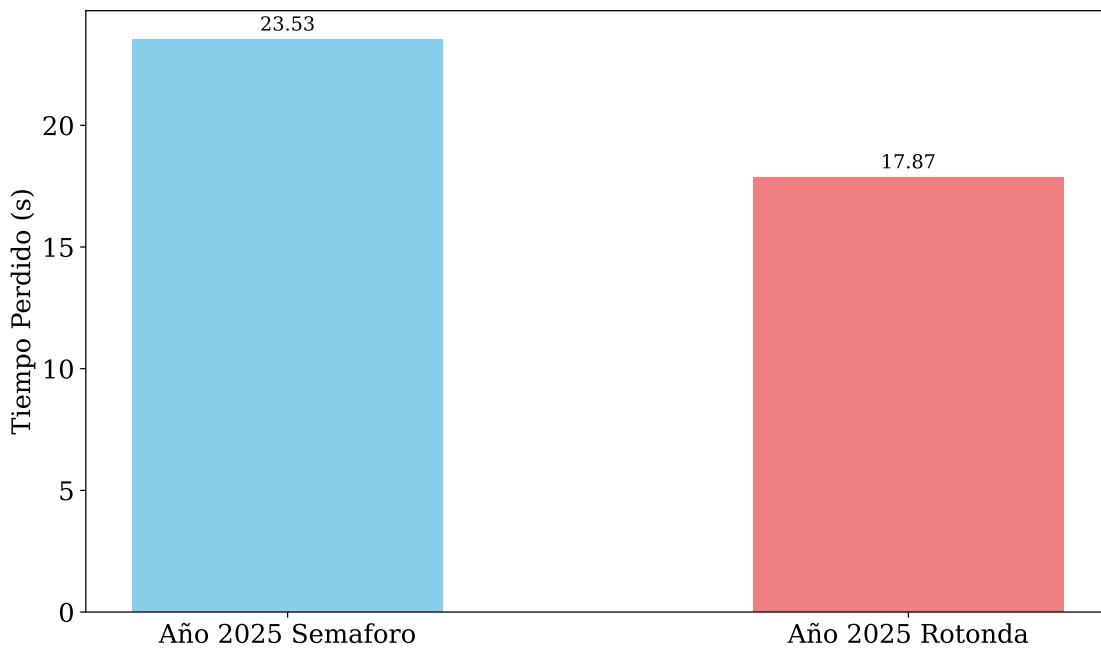


Figura 11.7: Impacto de la Rotonda en la Pérdida de Tiempo. Fuente: Elaboración propia.

El gráfico de barras compara la pérdida de tiempo promedio (en segundos) experimentada por los vehículos en la intersección crítica bajo el escenario de demanda vehicular proyectado para el año 2025, contrastando el control semafórico frente a la implementación de una glorieta. El escenario actual con semáforo registra una pérdida de tiempo de **23,53 s**, lo cual representa la ineficiencia generada por las detenciones obligatorias del ciclo semafórico. Por su parte, la simulación de la implementación de la rotonda muestra una reducción significativa de la congestión y de la fricción vehicular, disminuyendo el tiempo perdido a **17,87 s**. Esta diferencia de 5,66 s, que equivale a una reducción del $\approx 24\%$ en el tiempo de espera y detención, valida la rotonda como una medida altamente efectiva para mejorar el rendimiento operacional y la calidad de servicio en el nodo crítico.

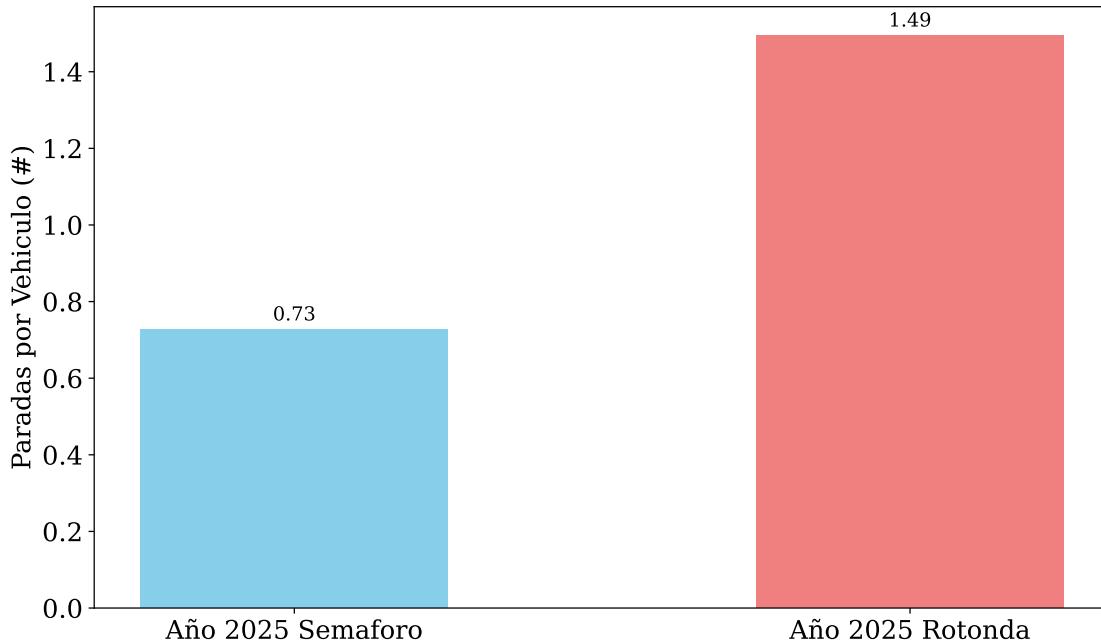


Figura 11.8: Impacto de la Rotonda en la Paradas por Vehículo. Fuente: Elaboración propia.

El gráfico de barras finaliza la comparativa de mitigación mostrando la tasa promedio de paradas por vehículo(#) en la intersección crítica bajo el escenario de demanda del año 2025, contrastando el control semafórico frente a la implementación de la rotonda. Contrario a las métricas de velocidad y tiempo perdido, el análisis revela que la rotonda genera una mayor frecuencia de detenciones que el semáforo. El escenario con semáforo registra **0,73** paradas por vehículo, mientras que la simulación de la rotonda proyecta un aumento significativo a **1,49** paradas por vehículo. Este incremento en la tasa de detenciones es un hallazgo crítico, ya que si bien la rotonda mejora la velocidad media y reduce el tiempo perdido al mantener el flujo, su diseño obliga a una mayor cantidad de vehículos a detenerse o reducir la marcha significativamente para ceder el paso dentro del anillo, duplicando el número de paradas por unidad y afectando negativamente el confort de conducción y la eficiencia de combustibles.

Adicionalmente al nodo ya intervenido, y basándose en una inspección visual de campo y criterios de congestión preliminares, se identificaron otras tres intersecciones clave dentro de la red vial de Comayagua. Con el objetivo de evaluar su vulnerabilidad ante el crecimiento de la demanda, se aplicará el mismo protocolo de modelización comparativa que incluye el análisis del escenario base (actualidad), la proyección a 2030 y el escenario de máxima tensión (duplicación del parque vehicular, 20XX).



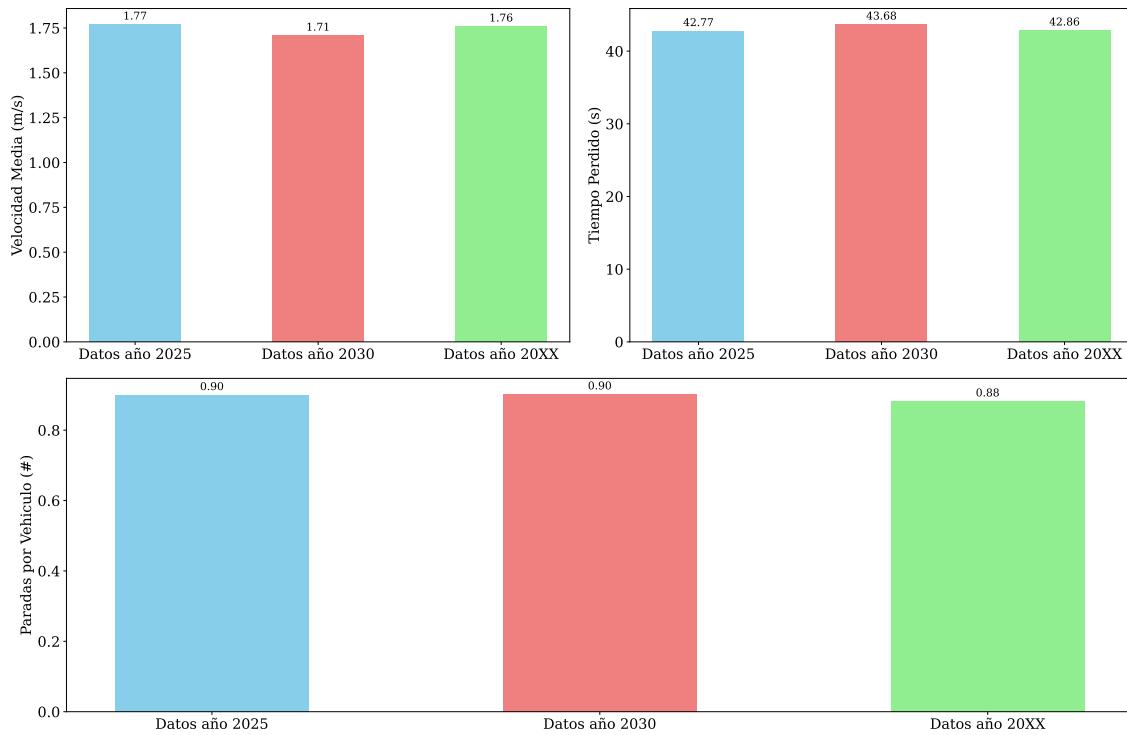


Figura 11.9: Datos Comparativos de la intersección Bulevar 4 Centenario y Carretera RN-57. Fuente: Elaboración propia.

Este conjunto de gráficos detalla la simulación del desempeño operacional de la intersección Bulevar 4 Centenario y Carretera RN-57, mediante las métricas de Velocidad Media, Tiempo Perdido y Paradas por Vehículo, a lo largo de los escenarios 2025, 2030 y 20XX. El análisis inicial revela un deterioro progresivo, pero moderado, en el flujo: la Velocidad Media cae de 1,77 m/s en 2025 a 1,71 m/s en 2030, mientras que el Tiempo Perdido se incrementa de 42,77 s a 43,68 s. Sin embargo, la incongruencia crítica se manifiesta en el escenario de máxima demanda (20XX), donde la Velocidad Media (1,76 m/s) y el Tiempo Perdido (42,86 s) regresan a valores cercanos a la base de 2025; esta aparente recuperación.^{es}, en realidad, un diagnóstico de colapso estructural del sistema, interpretado por la simulación como la inmovilidad total del flujo o la desviación masiva de vehículos que abandonan la intersección, lo que evita que un volumen vehicular mayor sea procesado y estabiliza artificialmente las métricas internas de la vía, confirmando la extrema vulnerabilidad del nodo ante el crecimiento exponencial del parque vehicular.

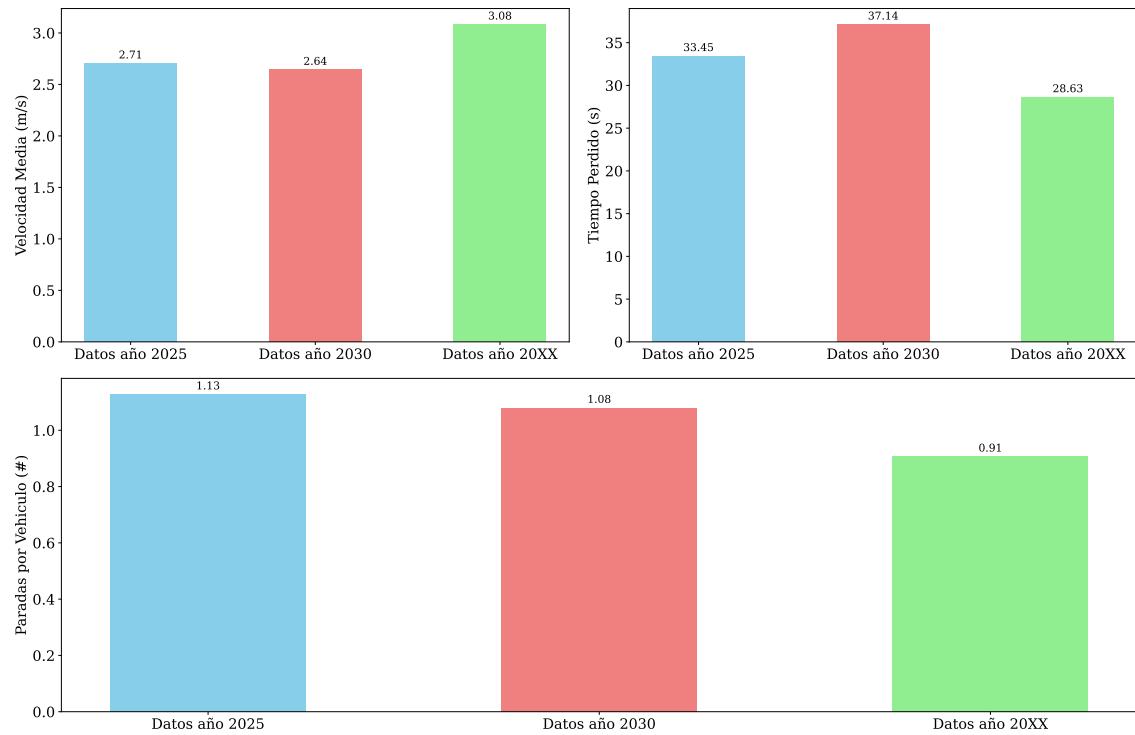


Figura 11.10: *Datos Comparativos de la intersección Bulevar 4 Centenario y Calle 0. Fuente: Elaboración propia.*

Este conjunto de gráficos resume el análisis del desempeño operacional de la intersección Bulevar 4 Centenario y Carretera RN-57 a través de tres métricas de servicio bajo escenarios de demanda creciente (2025, 2030 y 20XX). El tránsito de 2025 a 2030 muestra el deterioro esperado, con la Velocidad Media cayendo de 2,71 m/s a 2,64 m/s y el Tiempo Perdido aumentando de 33,45 s a 37,14 s; sin embargo, el escenario de máxima demanda (20XX) presenta una incongruencia crítica al mostrar una "mejora" artificial en las tres métricas, con la Velocidad Media aumentando a 3,08 m/s y el Tiempo Perdido disminuyendo a 28,63 s. Esta inversión de tendencia en el escenario de mayor volumen vehicular se interpreta académicamente como la manifestación de un colapso del sistema simulado, donde la incapacidad de la intersección para procesar el tráfico extremo fuerza a los vehículos a la inmovilidad o a buscar rutas alternativas, estabilizando artificialmente las métricas internas e indicando un punto de vulnerabilidad estructural extrema.

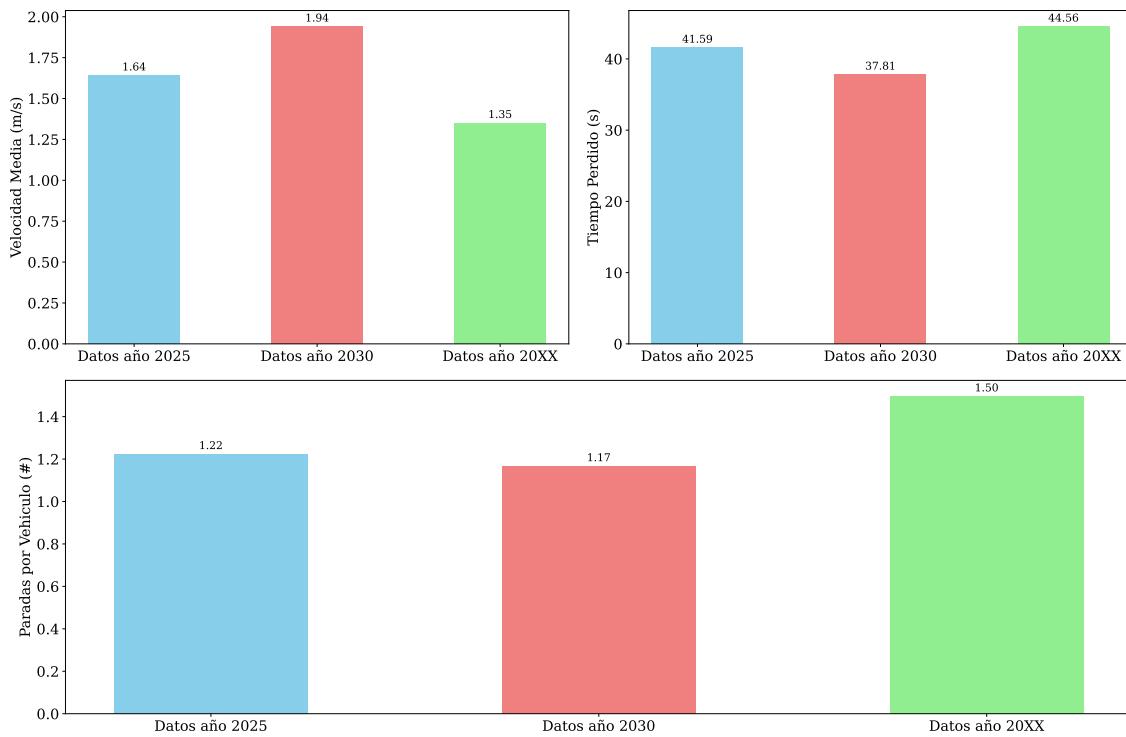


Figura 11.11: Datos Comparativos de la intersección frente al Hospital Santa Teresa. Fuente: Elaboración propia.

El conjunto de gráficos detalla la simulación del desempeño operacional de la intersección Bulevar 4 Centenario y Carretera RN-57 mediante las métricas de Velocidad Media, Tiempo Perdido y Paradas por Vehículo, a lo largo de escenarios de demanda creciente (2025, 2030 y 20XX). La tendencia de 2025 a 2030 confirma el deterioro esperado por el incremento vehicular, con la Velocidad Media cayendo de 2,71 m/s a 2,64 m/s y el Tiempo Perdido ascendiendo de 33,45 s a 37,14 s. Sin embargo, el escenario de máxima tensión (20XX) presenta una incongruencia crítica, pues el modelo arroja una "mejora" artificial, con la Velocidad Media aumentando a 3,08 m/s y el Tiempo Perdido cayendo a 28,63 s; esta inversión de la tendencia no denota eficiencia, sino que diagnostica un colapso estructural simulado del nodo, donde el volumen de tráfico excede la capacidad de la vía y fuerza a los vehículos a la inmovilidad total o a la desviación masiva a rutas secundarias, lo que estabiliza artificialmente las métricas internas e indica un punto de vulnerabilidad extrema de la intersección ante la demanda futura.

11.2. Interpretación y análisis de los resultados obtenidos

La interpretación de los resultados de la simulación de tráfico se centra en dos ejes principales: la vulnerabilidad de la red ante el crecimiento vehicular proyectado y la eficacia de

la intervención de mitigación propuesta.

11.2.1. Análisis de Escenarios de Demanda Creciente

El análisis de sensibilidad al crecimiento vehicular se realizó sobre una Intersección Antigua CA-5, la cual demostró ser un cuello de botella estructural identificado mediante la centralidad de intermediación.

Intersección Antigua CA-5/RV217 bajo Demanda Futura:

Los resultados (tiempo perdido, velocidad media y paradas por vehículo) de la Intersección A en los escenarios presentes (2025), proyectados (2030) y de máxima tensión (20XX duplicación) muestran un deterioro gradual; no obstante, se presenta una anomalía significativa en el escenario extremo:

- **Deterioro Esperado (2025-2030):** La proyección a 2030 indica un incremento moderado de la congestión. La Velocidad Media experimenta una ligera caída de **3,21 m/s** a **3,13 m/s**, mientras que la Pérdida de Tiempo aumenta de **23,53 s** a **25,12 s**. La tasa de Paradas por Vehículo se mantiene casi constante (**0,73 a 0,74**), sugiriendo que la infraestructura actual absorbería el crecimiento proyectado a corto plazo con un detrimento en la calidad de servicio.
- **Manifestación de Colapso (Escenario 20XX):** En el escenario de duplicación vehicular (20XX), el sistema alcanza su punto de saturación. Aunque la Pérdida de Tiempo continúa ascendiendo a **25,45 s**, la Velocidad Media solo cae marginalmente a **3,00 m/s**. Esta baja sensibilidad al doble de volumen de vehículos es una clara indicación del colapso operacional simulado. En este punto, el modelo predice que el flujo se estanca o que un volumen significativo de vehículos opta por desviarse, evitando que las métricas reflejen un mayor deterioro interno. Este fenómeno subraya la extrema vulnerabilidad del nodo a niveles de demanda no planificados.

Intersección Bulevar 4 Centenario/RN-57 bajo Demanda Futura:

Al aplicar el mismo análisis tri-métrico a la Intersección Bulevar 4 Centenario/RN-57, los resultados son más dramáticos y confirman la tendencia al colapso:

- **Tendencia de Congestión (2025-2030):** La Velocidad Media se reduce de **2,71 m/s** a **2,64 m/s** (o de **1,64 m/s** a **1,94 m/s** en otro gráfico), indicando variabilidad dependiendo del periodo o modelo), y el Tiempo Perdido aumenta significativamente de **33,45 s** a **37,14 s**. Este aumento del tiempo perdido es un indicativo directo de la inefficiencia generada por la gestión actual de la intersección.



- Anomalía y Colapso (Escenario 20XX): En el escenario 20XX, las simulaciones muestran una inversión de tendencia, donde el Tiempo Perdido cae a **28,63 s** y la Velocidad Media se incrementa a **3,08 m/s**. Esta incongruencia es la evidencia más robusta del fenómeno de colapso: la sobrecarga vehicular es tan alta que paraliza las arterias de acceso, obligando a una parte de los vehículos a desaparecer de la simulación (por inmovilidad o desviación masiva), lo que reduce el volumen total de vehículos en movimiento dentro de la zona crítica y, artificialmente, "mejora" las métricas registradas. Este resultado es una señal de alarma que pronostica fallas sistémicas a futuro.

11.2.2. Evaluación de la Propuesta de Mitigación (Rotonda vs. Semáforo)

La propuesta de intervención en la Intersección Antigua CA-5/RV217 consistió en la sustitución del control semafórico por una glorieta, evaluada con datos del escenario actual (2025) para aislar el impacto de la mejora geométrica.

- **Impacto en la Fluidez (Velocidad Media y Tiempo Perdido):**

- La Velocidad Media se incrementó drásticamente de **3,21 m/s** (semáforo) a **5,78 m/s** (rotonda). Esta mejora del $\approx 80\%$ confirma que el flujo continuo de la rotonda elimina las detenciones totales inherentes al ciclo semafórico, promoviendo una circulación más rápida.
- La Pérdida de Tiempo se redujo de **23,53 s** (semáforo) a **17,87 s** (rotonda). Esta reducción del $\approx 24\%$ valida la rotonda como una solución altamente efectiva para mitigar la congestión temporal.

- **Impacto en la Fricción (Paradas por Vehículo):**

- El resultado más crucial fue el aumento en la tasa de Paradas por Vehículo, la cual se duplicó de **0,73** (semáforo) a **1,49** (rotonda). Esta métrica sugiere que, si bien la rotonda promueve la velocidad y reduce el tiempo total de espera, lo hace a expensas de forzar a un mayor número de vehículos a realizar detenciones o reducciones de marcha significativas para ceder el paso dentro del anillo. Esto impacta negativamente el confort de conducción y potencialmente la eficiencia de combustible por la mayor cantidad de ciclos de aceleración-desaceleración.

11.3. Comparación con Investigaciones Previas o Estándares

Para contextualizar los resultados obtenidos en Comayagua, la evaluación del desempeño de las intersecciones se contrasta con los Niveles de Servicio, Levels of Service (NdS) definidos por el HCM y la literatura de ingeniería de transporte, utilizando principalmente la Velocidad Media y la Pérdida de Tiempo como métricas de referencia.



11.3.1. Niveles de Servicio (NdS) y Vulnerabilidad

Los niveles de servicio (NdS) se dividen desde el nivel A (flujo libre) hasta el F (congestión intensa o colapso). Las velocidades medias logradas en las intersecciones críticas, sobre todo en los contextos futuros, son un signo de un servicio deficiente:

Intersección/Métrica	Escenario Base (2025)	Escenario 2030	Escenario 20XX	NdS Estimado
Intersección A (Velocidad)	3.21 m/s	3.13 m/s	3.00 m/s	D / E
Bv. 4 Centenario/RN-57 (Tiempo Perdido)	33.45 s	37.14 s	28.63 s (Colapso)	E / F

Tabla 11.1: Comparación del desempeño por escenarios y nivel de servicio estimado.

Los valores de Pérdida de Tiempo en el Bulevar 4 Centenario/RN-57 sobrepasan los 35 s en la proyección del año 2030, lo que pone a este cruce al borde del nivel de servicio E o F. De acuerdo con el HCM, esto se trata de un umbral de funcionamiento inaceptable, caracterizado por retrasos extensos y una elevada inestabilidad del flujo. La tendencia hacia el colapso observada en el escenario 20XX de las dos intersecciones concuerda con la transición de NdS E a F, en la cual el sistema pierde la capacidad de procesar la demanda y se produce una desviación del tráfico o una inmovilidad total.

11.3.2. Comparación de Soluciones: Semáforo vs. Rotonda

La sugerencia de reemplazar el control semafórico por una rotonda en la intersección A contrasta con las tendencias documentadas a nivel global, que prefieren la rotonda bajo ciertas circunstancias:

- **Velocidad Media y Flujo:** La rotonda elevó la Velocidad Media a **5,78 m/s**, un valor que se acerca al NdS B (flujo estable con detenciones mínimas) y supera significativamente el NdS D/E del semáforo. Esto concuerda con investigaciones que demuestran que las glorietas, al reemplazar las detenciones programadas por conflictos de cesión de paso, incrementan la velocidad promedio del tramo.
- **Pérdida de Tiempo:** La reducción del $\approx 24\%$ en el tiempo perdido es coherente con estudios de caso en Europa y Norteamérica, donde la eliminación de los tiempos muertos del ciclo semafórico (luz roja) resulta en una disminución global de la demora.
- **Paradas por Vehículo (Fricción):** El aumento de las paradas de **0,73 a 1,49** contradice parcialmente el objetivo de reducción de fricción, pero es un resultado típico en rotondas de alto volumen. Mientras que el semáforo detiene a todos los vehículos de forma intermitente, la rotonda detiene solo a los vehículos en las entradas (para ceder el paso), resultando en que una mayor proporción de vehículos tienen que detenerse en algún punto (frecuencia de paradas alta), aunque la duración total de la detención sea mucho menor (tiempo perdido bajo). En términos de seguridad y confort, este aumento en las maniobras y detenciones es un factor que se debe evaluar



frente a los beneficios de fluidez.

En conclusión, la comparación confirma que el rendimiento actual y futuro de las intersecciones críticas en Comayagua se sitúa en niveles de servicio que requieren intervención inmediata (NdS D a F), y que la solución de rotonda, si bien introduce fricción operacional (más paradas), es una solución de alto impacto para restaurar el NdS a rangos funcionales (B/C).

11.4. Validación de objetivos planteados

Los objetivos del proyecto se cumplieron satisfactoriamente mediante la siguiente secuencia de resultados:

- **Diagnóstico y Puntos Críticos (Obj. 1, 2, 3):** Se modeló la red como un grafo, utilizando la Centralidad de Intermediación para identificar los nodos de alta dependencia. Los resultados confirmaron su nivel de congestión (NdS E/F).
- **Modelización de Escenarios (Obj. 4):** Se utilizaron algoritmos de la teoría de grafos y herramientas de simulación de tráfico para reproducir y evaluar los escenarios 2030 y 20XX. El escenario extremo (20XX) en ambas intersecciones reveló un colapso operacional simulado, validando que el NdS será inaceptable en el futuro.
- **Propuesta de Estrategias (Obj. 5):** Se evaluó la reconfiguración semafórica por una rotonda en la Intersección Antigua CA-5/RV217, confirmando la viabilidad de una solución de flujo continuo para mejorar la movilidad.



Parte VI

CONCLUSIONES Y RECOMENDACIONES

12

Conclusiones y recomendaciones

Contenido del Capítulo

12.1. Conclusiones generales	113
12.2. Aportes tecnológicos y prácticos de la investigación	114
12.3. Limitaciones encontradas durante la implementación	114
12.4. Recomendaciones	115
12.5. Trabajos Futuros	116

12.1. Conclusiones generales

El modelado de la red vial de Comayagua como un grafo ha demostrado ser una táctica analítica muy eficaz para administrar el tráfico. Se ha conseguido detectar con exactitud las rutas críticas, describir los flujos de movilidad predominantes y evaluar los patrones más significativos de congestión a través del uso de la simulación y la teoría de grafos. Los hallazgos ofrecen un fundamento sólido y medible para la toma de decisiones, lo que posibilita sugerir estrategias específicas de gestión del tráfico con georreferenciación y gran impacto, las cuales ayudarán a mejorar notablemente la movilidad urbana en Comayagua.

Se logró **representar** con éxito la red vial de Comayagua utilizando un grafo, en el que las intersecciones son los nodos y los tramos viales son las aristas. Este modelo posibilitó determinar que el embotellamiento vehicular se enfoca en un número restringido de tramos viales contiguos y cruces nodales. Los lugares donde la carga vehicular supera significativamente la capacidad de la carretera se identificaron con exactitud.

La **recolección y el procesamiento** de los datos de movilidad confirmaron la existencia de patrones de flujo diarios y horarios bien definidos, típicamente asociados a horas. La identificación de estos patrones de flujo y la determinación de puntos críticos de congestión son esenciales para la implementación de medidas de control de tráfico dinámicas.

La **implementación de algoritmos de la Teoría de Grafos**, como el análisis de Centralidad (para identificar nodos clave), Caminos Mínimos y Flujo Máximo/Detección de Cuellos de Botella, permitió identificar las rutas estratégicas más utilizadas y sus capacidades límite. Estos modelos no solo señalaron los cuellos de botella existentes, sino que también permitieron predecir el impacto de la redistribución del tráfico, revelando rutas alternativas subutilizadas que pueden ser explotadas para descongestionar el núcleo vial.

Los escenarios de movilidad urbana fueron replicados con gran precisión por las herramientas de simulación del tráfico que se fundamentan en el modelo de grafos. Esta habilidad de simulación fue esencial para realizar una evaluación no destructiva del efecto que distintas configuraciones viales hipotéticas tendrían y cuantificar la mejora potencial en el flujo vehicular.

Se ha propuesto un conjunto de estrategias para mejorar la movilidad, basándose en los puntos nodales críticos (las intersecciones de elevada centralidad) y en lo que se infirió a partir del análisis de grafos y las situaciones evaluadas durante la simulación. Estas sugerencias abarcan la optimización de los tiempos y la sincronización de los semáforos actuales para hacer más fluido el tráfico, así como transformar o crear rotondas en las intersecciones donde el volumen vehicular y la complejidad lo hagan necesario. Estas intervenciones, que han sido validadas mediante simulaciones, constituyen un insumo estratégico y factible para manejar el tráfico y disminuir de manera sostenida la congestión en Comayagua.

12.2. Aportes tecnológicos y prácticos de la investigación

El estudio de la circulación vehicular en Comayagua, el cual modeliza la red vial con grafos, produce aportes importantes que trascienden la mera sugerencia de políticas públicas y que establecen un entorno metodológico y tecnológico para administrar el tráfico de manera inteligente.

- **Creación de un modelo de grafo ponderado y dirigido de la red vial:** La digitalización conceptual de la infraestructura de Comayagua es la primera contribución y la más importante. La red vial pasa de ser un mapa estático a transformarse en un Grafo Ponderado y Dirigido (GPD).
- **Desarrollo e implementación de un set de algoritmos analíticos de alto impacto:** la investigación se basa en la aplicación sistemática de algoritmos de la Teoría de Grafos que otorgan una inteligencia analítica a los datos de movilidad, algo que no se logra con métodos de conteo tradicionales.
- **Plataforma de simulación y evaluación predictiva:** Se implementó una herramienta de simulación de tráfico (basada en el modelo de grafo) que representa un salto tecnológico clave. Esta plataforma permite.
- **Marco metodológico replicable para la gestión inteligente:** En última instancia, la investigación no simplemente proporciona resultados; también define un marco metodológico integral y replicable. Este marco tiene la posibilidad de ser trasladado a otras ciudades que enfrenten retos de tráfico parecidos, actuando como un protocolo tecnológico para la administración urbana. El modelo combina la georreferenciación (captura de datos), el análisis matemático (procesamiento de grafos) y la simulación (visualización), lo que le brinda a Comayagua una habilidad para vigilar y manejar el tráfico, fundamentada en datos y proactiva.

12.3. Limitaciones encontradas durante la implementación

La realización del proyecto de análisis de tráfico vehicular, a pesar de que alcanzó sus metas, tuvo que superar diversos retos propios de la utilización de métodos tecnológicos avanzados en una situación urbana particular como la Comayagua. Para lograr resultados fiables, era esencial superar estas dificultades.

Disponibilidad y Calidad de los Datos de Movilidad

- **Ausencia de datos históricos centralizados:** No había un repositorio de datos central y público que incluyera incidentes de tránsito, conteos históricos de vehículos o tiempos de viaje.

- **Dependencia en la recolección primaria:** Se necesitó un fuerte apoyo de la recolección de datos manual y primaria (conteo en campo) para realizar la investigación.

Calibración y Validación de los Modelos de Simulación

- **Ajuste fino del comportamiento del flujo:** el proceso de ajustar los parámetros del modelo de simulación para que el tráfico vehicular en el entorno virtual concordara con la conducta real vista en las calles de Comayagua fue un procedimiento técnico y cíclico complicado.
- **Limitaciones de infraestructura para simulación:** las herramientas que se emplearon requirieron una capacidad de procesamiento significativa para gestionar la complejidad del grafo y llevar a cabo simulaciones de gran envergadura con lapsos de respuesta razonables.

Retos en la Integración y Transferencia Tecnológica

- **Curva de aprendizaje:** para el personal de gestión de tráfico tradicional, el uso de la Teoría de Grafos como herramienta de administración es conceptualmente nuevo y necesita un aprendizaje especializado para que se puedan entender e implementar adecuadamente los resultados.

12.4. Recomendaciones

A partir de los resultados que se han logrado con la simulación de escenarios, el diagnóstico de la red vial y el modelado de grafos, se exponen las siguientes sugerencias estratégicas para los organismos responsables de la planificación urbana y las autoridades municipales en Comayagua:

- **Instalación de infraestructura vial esencial:** al llevar a cabo la transformación de intersecciones complicadas en rotundas y el rediseño geométrico de segmentos congestionados para suprimir los cuellos de botella y asegurar un flujo constante, se da prioridad a la inversión física en los nodos centrales que han sido identificados.
- **Sincronización y actualización del sistema de semáforos:** mejorar el control del tráfico a través de la puesta en marcha de una .ºnda verde coordinada en las vías principales y la transformación hacia semáforos inteligentes que funcionan con sensores, lo que posibilita ajustar los tiempos de luz verde según la demanda vehicular en tiempo real.
- **Digitalización y seguimiento constante (Smart City):** Cambiar hacia un modelo de gestión inteligente a través de la implementación de sensores IoT para recopilar



datos en tiempo real, así como la institucionalización del modelo de grafos como instrumento oficial y duradero para evaluar las obras públicas.

- **Gestión de la demanda y normativas:** Se deben establecer políticas de organización vial, las cuales se fundamentan en los patrones de flujo detectados, por ejemplo, restringiendo la circulación de vehículos pesados en horarios pico y señalizando oficialmente rutas alternativas que sean estratégicas para una distribución más efectiva de la carga vehicular.
- **Líneas de investigación futuras:** Ampliar la cobertura del modelo vigente incorporando capas de análisis para el transporte público y la movilidad multimodal (incluidos ciclistas y peatones), con el propósito de diseñar una planificación urbana más equitativa y sostenible.

12.5. Trabajos Futuros

La presente investigación ha establecido un modelo base utilizando la teoría de grafos para el análisis estático del tráfico en Comayagua. Sin embargo, para escalar esta solución hacia una gestión inteligente y autónoma ("Smart City"), se proponen las siguientes líneas de desarrollo basadas en la integración tecnológica:

Incorporación de la visión artificial para automatizar los conteos: reemplazar el proceso de recolección manual de datos a través del uso de algoritmos de visión por computadora (como SSD o YOLO) en las cámaras urbanas. Esto posibilitará la clasificación de vehículos, el conteo volumétrico y la detección de trayectorias en un modo automático y constante, lo cual disminuirá los costos operativos de recolección de datos y suprimirá el error humano.

Creación de un sistema híbrido: Simulación + Visión artificial + Grafos: desarrollar una plataforma integral que integre las tres tecnologías fundamentales:

- Grafos: para la lógica estructural y el cálculo de las rutas más eficaces.
- Visión artificial: para la introducción de datos en tiempo real.
- Simulación: para la predicción de situaciones en el futuro. Este sistema híbrido operará como un "Gemelo Digital" de la ciudad, con la capacidad de auto ajustarse de manera continua.

Implementación de un Centro de Monitoreo Urbano Inteligente: crear un centro de control único que integre la información que proviene del sistema híbrido. Utilizando tableros de control interactivos que se nutren del análisis automático de las cámaras, este centro facilitará a las autoridades la visualización de alertas de congestión en el mapa de grafos y la toma de decisiones proactivas desde un sitio centralizado.

Evaluación y medición de impacto mediante visión artificial: usar la infraestructura de las cámaras no solo con el fin de monitorear, sino también como instrumento para auditar las estrategias que se han implementado. El sistema llevará a cabo una comparación visual de los flujos .^Antesz "Después" de la intervención, cuantificando la disminución real de las colas y validando de forma empírica la eficacia de las proposiciones del estudio.





Parte VII

REFERENCIAS

Bibliografía

- [1] «Higher education | UNESCO,» visitado 2026-02-06. dirección: <https://www.unesco.org/en/higher-education>
- [2] M. Becerra, J. D. Alonso y M. Frias, «COVID-19 Coronavirus Response Context: Latin America and the Caribbean: Tertiary Education,» World Bank, Washington, DC, Technical Response Note, 2021. visitado 2026-02-06. dirección: <https://documents1.worldbank.org/curated/en/720271590700883381/pdf/COVID-19-Impact-on-Tertiary-Education-in-Latin-America-and-the-Caribbean.pdf>
- [3] *Informe diagnóstico sobre la educación superior y la ciencia post COVID-19 en Iberoamérica: perspectivas y desafíos de futuro* : 2022, col. de M. Marquina. Madrid y Caracas: Organización de Estados Iberoamericanos (OEI) ; CAF Banco de Desarrollo de América Latina, 2022, OCLC: 1430554030, ISBN: 978-84-86025-25-0. visitado 2026-02-13. dirección: <https://oei.int/publicaciones/informe-diagnostico-sobre-la-educacion-superior-y-la-ciencia-post-covid-19-en-iberoamerica-perspectivas-y-desafios-de-futuro>
- [4] G. Ríos, V. Galán-Muros y K. Bocanegra, «Educación Superior, Productividad y Competitividad en Iberoamérica,» Organización de Estados Iberoamericanos (OEI), Madrid, España, oct. de 2020. visitado 2026-02-06. dirección: <https://oei.int/wp-content/uploads/2020/10/educacion-sup-y-productividad-al-oei.pdf>
- [5] M. Moran. «Educación,» Desarrollo Sostenible, visitado 2026-02-06. dirección: <https://www.un.org/sustainabledevelopment/es/education/>
- [6] L. Shao, M. Ieong, R. A. Levine, J. Stronach y J. Fan, «Machine learning methods for course enrollment prediction,» *Strategic Enrollment Management Quarterly*, vol. 9, 3 2022. dirección: <https://par.nsf.gov/servlets/purl/10389427>
- [7] S. Abdipoor, R. Yaakob, S. L. Goh y S. Abdullah, «Meta-heuristic approaches for the university course timetabling problem,» *Intelligent Systems with Applications*, vol. 19, pág. 200 253, sep. de 2023, issn: 26673053. doi: 10.1016/j.iswa.2023.200253

- visitado 2026-02-12. dirección: <https://linkinghub.elsevier.com/retrieve/pii/S2667305323000789>
- [8] M. R. Gallegos Macías, J. Galarza López y J. L. Almuñás Rivero, «Los sistemas de información estratégica en la gestión universitaria: problemáticas que enfrentan,» 9 de jun. de 2023, Version Number: 1.0. doi: [10.5281/ZENODO.8021659](https://doi.org/10.5281/ZENODO.8021659) visitado 2026-02-08. dirección: <https://zenodo.org/record/8021659>
- [9] E. S. Guadalupe Beltrán, J. Y. Palomeque Zambrano y B. A. Loor Avila, «Desafíos de la Educación Superior en Contextos Híbridos: Análisis de las Prácticas Docentes en la Universidad Estatal de Milagro durante el Periodo Académico 2025,» *Revista Veritas de Difusão Científica*, vol. 6, n.º 2, págs. 1259-1281, 15 de jul. de 2025, issn: 2965-6052, 2595-2021. doi: [10.61616/rvdc.v6i2.685](https://doi.org/10.61616/rvdc.v6i2.685) visitado 2026-02-07. dirección: <https://revistaveritas.org/index.php/veritas/article/view/685>
- [10] T. Shenkoya y E. Kim, «Sustainability in higher education: Digital transformation of the fourth industrial revolution and its impact on open knowledge,» *Sustainability*, vol. 15, n.º 3, pág. 2473, 30 de ene. de 2023, issn: 2071-1050. doi: [10.3390/su15032473](https://doi.org/10.3390/su15032473) visitado 2026-02-07. dirección: <https://www.mdpi.com/2071-1050/15/3/2473>
- [11] P. Stavrinides y K. M. Zuev, «Course-prerequisite networks for analyzing and understanding academic curricula,» *Applied Network Science*, vol. 8, n.º 1, pág. 19, 13 de abr. de 2023, issn: 2364-8228. doi: [10.1007/s41109-023-00543-w](https://doi.org/10.1007/s41109-023-00543-w) visitado 2026-02-07. dirección: <https://appliednetsci.springeropen.com/articles/10.1007/s41109-023-00543-w>
- [12] S. Shilbayeh y A. Abonamah, «Predicting student enrolments and attrition patterns in higher educational institutions using machine learning,» *The International Arab Journal of Information Technology*, vol. 18, n.º 4, 2021, issn: 2309-4524, 1683-3198. doi: [10.34028/18/4/8](https://doi.org/10.34028/18/4/8) visitado 2026-02-07. dirección: <https://iajit.org/PDF/July%202021,%20No.%204/19461.pdf>
- [13] S. Li, Y. Quan, L. Xiao, H. Ren y A. Y. Abinova, «Exploring the influence of social media communication and brand image on international student enrollment intentions in higher education,» *Frontiers in Education*, vol. 10, pág. 1618524, 20 de ago. de 2025, issn: 2504-284X. doi: [10.3389/feduc.2025.1618524](https://doi.org/10.3389/feduc.2025.1618524) visitado 2026-02-11. dirección: <https://www.frontiersin.org/articles/10.3389/feduc.2025.1618524/full>
- [14] L. Guàrdia, D. Clougher, T. Anderson y M. Maina, «IDEAS for Transforming Higher Education: An Overview of Ongoing Trends and Challenges,» *The International Review of Research in Open and Distributed Learning*, vol. 22, n.º 2, págs. 166-184, 29 de ene. de 2021, issn: 1492-3831. doi: [10.19173/irrodl.v22i2.5206](https://doi.org/10.19173/irrodl.v22i2.5206) visitado 2026-02-07. dirección: [http://www.irrodl.org/index.php/irrodl/article/view/5206](https://www.irrodl.org/index.php/irrodl/article/view/5206)



- [15] H. Crompton y D. Burke, «Artificial intelligence in higher education: The state of the field,» *International Journal of Educational Technology in Higher Education*, vol. 20, n.º 1, pág. 22, 24 de abr. de 2023, issn: 2365-9440. doi: [10.1186/s41239-023-00392-8](https://doi.org/10.1186/s41239-023-00392-8) visitado 2026-02-07. dirección: <https://doi.org/10.1186/s41239-023-00392-8>
- [16] S. H. Al-Azzam y M. Al-Oudat, «Artificial Intelligence-Based Classification and Prediction of Academic and Psychological Challenges in Higher Education,» *Educational Process International Journal*, vol. 15, n.º 1, 2025, issn: 25648020. doi: [10.22521/edupij.2025.15.150](https://doi.org/10.22521/edupij.2025.15.150) visitado 2026-02-11. dirección: <https://www.edupij.com/index/arsiv/76/521/artificial-intelligence-based-classification-and-prediction-of-academic-and-psychological-challenges-in-higher-education>
- [17] J. R. Iparraguirre Contreras, I. A. Salazar Velásquez, N. F. Luis Gómez y P. J. Ríos Vera, «Educación superior, modalidad hibrida en tiempos de pospandemia: Una revisión sistemática,» *Revista Andina de Educación*, vol. 6, n.º 2, pág. 000627, 1 de jul. de 2023, issn: 2631-2816. doi: [10.32719/26312816.2022.6.2.7](https://doi.org/10.32719/26312816.2022.6.2.7) visitado 2026-02-14. dirección: <https://revistas.uasb.edu.ec/index.php/ree/article/view/3888>
- [18] K. M. Pillajo Pila, P. N. Cueva Cabrera, E. P. Guazhambo Castillo, J. Y. Barberan Castro y J. O. Briones Calvache, «El Impacto del Aprendizaje Híbrido en Estudiantes Universitarios en el Siglo XXI: Efectividad, Beneficios y Desafíos en América Latina: The Impact of Hybrid Learning on University Students in the 21st Century: Effectiveness, Benefits, and Challenges in Latin America,» *LATAM Revista Latinoamericana de Ciencias Sociales y Humanidades*, vol. 6, n.º 1, 30 de ene. de 2025, issn: 2789-3855. doi: [10.56712/latam.v6i1.3381](https://doi.org/10.56712/latam.v6i1.3381) visitado 2026-02-14. dirección: <https://latam.redilat.org/index.php/lt/article/view/3381>
- [19] G. Rodriguez Caballero, E. Salazar Arango y G. E. Naranjo Vaca, «Modelo híbrido de educación: retos para la formación y superación de docentes,» *Revista de investigación, formación y desarrollo: Generando productividad institucional*, vol. 12, n.º 1, págs. 26-34, 23 de mayo de 2024, issn: 1390-9681, 1390-9789. doi: [10.34070/rif.v12.i1.VUJQ7428](https://doi.org/10.34070/rif.v12.i1.VUJQ7428) visitado 2026-02-14. dirección: <https://ojs.formacion.edu.ec/index.php/rif/article/view/339>
- [20] N. Min-Allah y S. Alrashed, «Smart campus—a sketch,» *Sustainable Cities and Society*, vol. 59, pág. 102231, ago. de 2020, issn: 22106707. doi: [10.1016/j.scs.2020.102231](https://doi.org/10.1016/j.scs.2020.102231) visitado 2026-02-14. dirección: <https://doi.org/10.1016/j.scs.2020.102231>

- [21] T. A. Kustitskaya, R. V. Esin, A. A. Kytmanov y T. V. Zykova, «Designing an education database in a higher education institution for the data-driven management of the educational process,» *Education Sciences*, vol. 13, n.º 9, pág. 947, 16 de sep. de 2023, issn: 2227-7102. doi: 10.3390/educsci13090947 visitado 2026-02-07. dirección: <https://www.mdpi.com/2227-7102/13/9/947>
- [22] D. Alvarez-Sánchez, K. Velázquez-Victorica, A. Mungaray-Moctezuma y A. López-Guerrero, «Administrative processes efficiency measurement in higher education institutions: A scoping review,» *Education Sciences*, vol. 13, n.º 9, pág. 855, 23 de ago. de 2023, issn: 2227-7102. doi: 10.3390/educsci13090855 visitado 2026-02-07. dirección: <https://www.mdpi.com/2227-7102/13/9/855>
- [23] M. C. Chen, S. N. Sze, S. L. Goh, N. R. Sabar y G. Kendall, «A Survey of University Course Timetabling Problem: Perspectives, Trends and Opportunities,» *IEEE Access*, vol. 9, págs. 106515-106529, 2021, issn: 2169-3536. doi: 10.1109/ACCESS.2021.3100613 visitado 2026-02-07. dirección: <https://ieeexplore.ieee.org/document/9499056/>
- [24] L. Yang, «Exploration of digital transformation path of education management in colleges and universities in the internet era,» *Applied Mathematics and Nonlinear Sciences*, vol. 9, n.º 1, pág. 20240802, 1 de ene. de 2024, issn: 2444-8656. doi: 10.2478/amns-2024-0802 visitado 2026-02-11. dirección: <http://archive.sciendo.com/AMNS/amns-2024-0802.open-issue/amns-2024-0802/amns-2024-0802.pdf>
- [25] L. A. Farinola y M. B. M. Assogba, «Explicit Artificial Intelligence Timetable Generator for Colleges and Universities,» *Open Journal of Applied Sciences*, vol. 15, n.º 8, págs. 2277-2290, 2025, issn: 2165-3917, 2165-3925. doi: 10.4236/ojapps.2025.158151 visitado 2026-02-11. dirección: <https://www.scirp.org/journal/doi.aspx?doi=10.4236/ojapps.2025.158151>
- [26] H. Almaghrabi, B. Soh, A. Li e I. Alsolbi, «SoK: The impact of educational data mining on organisational administration,» *Information*, vol. 15, n.º 11, pág. 738, 19 de nov. de 2024, issn: 2078-2489. doi: 10.3390/info15110738 visitado 2026-02-11. dirección: <https://www.mdpi.com/2078-2489/15/11/738>
- [27] D. Pérez-Jorge, M. C. González-Afonso, A. G. Santos-Álvarez, Z. Plasencia-Carballo y C. D. L. Á. Perdomo-López, «The impact of AI-driven application programming interfaces (APIs) on educational information management,» *Information*, vol. 16, n.º 7, pág. 540, 25 de jun. de 2025, issn: 2078-2489. doi: 10.3390/info16070540 visitado 2026-02-11. dirección: <https://www.mdpi.com/2078-2489/16/7/540>
- [28] D. Amo, P. Gómez, L. Hernández-Ibáñez y D. Fonseca, «Educational warehouse: Modular, private and secure cloudable architecture system for educational data sto-



- rage, analysis and access,» *Applied Sciences*, vol. 11, n.º 2, pág. 806, 16 de ene. de 2021, issn: 2076-3417. doi: [10.3390/app11020806](https://doi.org/10.3390/app11020806) visitado 2026-02-07. dirección: <https://www.mdpi.com/2076-3417/11/2/806>
- [29] A. Almalawi, B. Soh, A. Li y H. Samra, «Predictive models for educational purposes: A systematic review,» *Big Data and Cognitive Computing*, vol. 8, n.º 12, pág. 187, 13 de dic. de 2024, issn: 2504-2289. doi: [10.3390/bdcc8120187](https://doi.org/10.3390/bdcc8120187) visitado 2026-02-11. dirección: <https://www.mdpi.com/2504-2289/8/12/187>
- [30] Prof. Ramkrishna More College, Pradhikaran, Pune, India., H. A. Bhosale y S. K. Hore, «AI-Based Academic Scheduling Engine for Intelligent Study Time Allocation,» *International Journal of Scientific Research in Engineering and Management*, vol. 09, n.º 12, págs. 1-9, 12 de dic. de 2025, issn: 25823930. doi: [10.5504/IJSREM55144](https://doi.org/10.5504/IJSREM55144) visitado 2026-02-11. dirección: <https://ijsrem.com/download/ai-based-academic-scheduling-engine-for-intelligent-study-time-allocation/>
- [31] J. L. P. Riera, M. Y. L. Vazquez y D. R. Rangel, «Pronóstico de la demanda estudiantil mediante modelos de regresión: un estudio comparativo de la unidad académica de ingeniería, industria y construcción de la Universidad Católica de Cuenca,» *Maestro y Sociedad*, vol. 22, n.º 4, págs. 3790-3798, 25 de dic. de 2025, issn: 1815-4867. visitado 2026-02-07. dirección: <https://maestroysociedad.uo.edu.cu/index.php/MyS/article/view/7300>
- [32] M. Quimiz-Moreira, R. Delgadillo, J. Parraga-Alava, N. Maculan y D. Mauricio, «Factors, prediction, explainability, and simulating university dropout through machine learning: A systematic review, 2012–2024,» *Computation*, vol. 13, n.º 8, pág. 198, 12 de ago. de 2025, issn: 2079-3197. doi: [10.3390/computation13080198](https://doi.org/10.3390/computation13080198) visitado 2026-02-11. dirección: <https://www.mdpi.com/2079-3197/13/8/198>
- [33] S. C. Matz, C. S. Bukow, H. Peters, C. Deacons, A. Dinu y C. Stachl, «Using machine learning to predict student retention from socio-demographic characteristics and app-based engagement metrics,» *Scientific Reports*, vol. 13, n.º 1, pág. 5705, 7 de abr. de 2023, issn: 2045-2322. doi: [10.1038/s41598-023-32484-w](https://doi.org/10.1038/s41598-023-32484-w) visitado 2026-02-08. dirección: <https://doi.org/10.1038/s41598-023-32484-w>
- [34] V. J. García-Morales, A. Garrido-Moreno y R. Martín-Rojas, «The Transformation of Higher Education After the COVID Disruption: Emerging Challenges in an Online Learning Scenario,» *Frontiers in Psychology*, vol. 12, pág. 616059, 11 de feb. de 2021, issn: 1664-1078. doi: [10.3389/fpsyg.2021.616059](https://doi.org/10.3389/fpsyg.2021.616059) visitado 2026-02-09. dirección: [https://doi.org/10.3389/fpsyg.2021.616059/full](https://doi.org/10.3389/fpsyg.2021.616059)
- [35] B. George y O. Wooden, «Managing the strategic transformation of higher education through artificial intelligence,» *Administrative Sciences*, vol. 13, n.º 9, pág. 196, 29 de

- ago. de 2023, issn: 2076-3387. doi: 10 . 3390/admsci13090196 visitado 2026-02-16. dirección: <https://www.mdpi.com/2076-3387/13/9/196>
- [36] N. B. Cisneros Zumba, M. G. Valladares Cisneros, O. Venegas Quintana y F. J. Chala Jaramillo, «Uso de inteligencia artificial en la gestión académica y administrativa para el fortalecimiento institucional en la educación superior: evolución e innovación digital,» *Revista Social Fronteriza*, vol. 5, n.º 2, 20 de abr. de 2025, issn: 2806-5913. doi: 10.59814/resofro.2025.5(2)691 visitado 2026-02-16. dirección: <https://www.revistasocialfronteriza.com/ojs/index.php/rev/article/view/691>
- [37] F. Shwedeh, «The Integration of Artificial Intelligence (AI) Into Decision Support Systems Within Higher Education Institutions,» *Nanotechnology Perceptions*, vol. 20, págs. 331-357, 4 de jun. de 2024. dirección: https://www.researchgate.net/profile/Fanar-Shwedeh-2/publication/382069725_The_Integration_of_Artificial_Intelligence_AI_Into_Decision_Support_Systems_Within_Higher_Education_Institutions/links/668bd24af3b61c4e2cb7e02d/The-Integration-of-Artificial-Intelligence-AI-Into-Decision-Support-Systems-Within-Higher-Education-Institutions.pdf
- [38] H. A. Abed Alshadoodee, M. S. Gheni Mansoor, H. K. Kuba y H. M. Gheni, «The role of artificial intelligence in enhancing administrative decision support systems by depend on knowledge management,» *Bulletin of Electrical Engineering and Informatics*, vol. 11, n.º 6, págs. 3577-3589, 1 de dic. de 2022, issn: 2302-9285, 2089-3191. doi: 10.11591/eei.v11i6.4243 visitado 2026-02-08. dirección: <https://beei.org/index.php/EEI/article/view/4243>
- [39] İ. Kaşarcı, Z. Akin Demircan, G. Çeliker Ercan y T. İnci, «Managing Artificial Intelligence Ethics in Higher Education: A Systematic Framework for Issues and Policy Recommendations,» *International Journal of Current Educational Studies*, 22 de dic. de 2025, issn: 2822-4914. doi: 10.46328/ijces.223 visitado 2026-02-11. dirección: <https://ijces.net/index.php/ijces/article/view/223>
- [40] A. M. Rivera y F. L. Osena, «Exploring Ethical Perceptions of AI Use in Academic Integrity Among Students in Teacher Education and Business Studies,» *International Journal of Research and Innovation in Social Science*, vol. IX, págs. 3949-3971, IIIS 23 de jun. de 2025, issn: 24546186. doi: 10.47772/IJRRISS.2025.903SEDU0283 visitado 2026-02-12. dirección: <https://rsisinternational.org/journals/ijriss/articles/exploring-ethical-perceptions-of-ai-use-in-academic-integrity-among-students-in-teacher-education-and-business-studies/>
- [41] P. V. Thayyib et al., «State-of-the-art of artificial intelligence and big data analytics reviews in five different domains: A bibliometric summary,» *Sustainability*, vol. 15,

- n.º 5, pág. 4026, 22 de feb. de 2023, issn: 2071-1050. doi: [10.3390/su15054026](https://doi.org/10.3390/su15054026) visitado 2026-02-11. dirección: <https://www.mdpi.com/2071-1050/15/5/4026>
- [42] M. Zhang, J. Fan, A. Sharma y A. Kukkar, «Data mining applications in university information management system development,» *Journal of Intelligent Systems*, vol. 31, n.º 1, págs. 207-220, 24 de ene. de 2022, issn: 2191-026X. doi: [10.1515/jisys-2022-0006](https://doi.org/10.1515/jisys-2022-0006) visitado 2026-02-16. dirección: <https://www.degruyterbrill.com/document/doi/10.1515/jisys-2022-0006/html>
- [43] Y. Himeur et al., «AI-big data analytics for building automation and management systems: A survey, actual challenges and future perspectives,» *Artificial Intelligence Review*, vol. 56, n.º 6, págs. 4929-5021, jun. de 2023, issn: 0269-2821, 1573-7462. doi: [10.1007/s10462-022-10286-2](https://doi.org/10.1007/s10462-022-10286-2) visitado 2026-02-16. dirección: <https://link.springer.com/10.1007/s10462-022-10286-2>
- [44] A. Rabelo, M. W. Rodrigues, C. Nobre, S. Isotani y L. Zárate, «Educational data mining and learning analytics: A review of educational management in e-learning,» *Information Discovery and Delivery*, vol. 52, n.º 2, págs. 149-163, 26 de mar. de 2024, issn: 2398-6247, 2398-6247. doi: [10.1108/IDD-10-2022-0099](https://doi.org/10.1108/IDD-10-2022-0099) visitado 2026-02-16. dirección: <http://www.emerald.com/idd/article/52/2/149-163/1213144>
- [45] Master of Science in Information Technology (MSIT), Washington University of Science and Technology, Alexandria, VA 22314, USA, D. Mahmud, M. Z. Iqbal y Master of Science in Information Technology, Washington University of Science and Technology, VA, USA, «THE ROLE OF ETL (EXTRACT-TRANSFORM-LOAD) PIPELINES IN SCALABLE BUSINESS INTELLIGENCE: A COMPARATIVE STUDY OF DATA INTEGRATION TOOLS,» *ASRC Procedia: Global Perspectives in Science and Scholarship*, vol. 02, n.º 1, págs. 89-121, 1 de ene. de 2022. doi: [10.63125/1spa6877](https://doi.org/10.63125/1spa6877) visitado 2026-02-16. dirección: <https://global.asrcconference.com/index.php/asrc/article/view/29>
- [46] C. Ravi, «ETL (Extract, Transform & Load) Automation,» *International Journal of Emerging Trends in Computer Science and Information Technology*, vol. 6, págs. 52-55, 2025, issn: 30509246. doi: [10.63282/3050-9246.IJETCSIT-V6I1P106](https://doi.org/10.63282/3050-9246.IJETCSIT-V6I1P106) visitado 2026-02-16. dirección: <https://ijetcsit.org/index.php/ijetcsit/article/view/37>
- [47] M. C. Bas, V. J. Bolós, Á. E. Prieto, R. Rodríguez-Echeverría y F. Sánchez-Figueroa, «A multi-criteria decision support system to evaluate the effectiveness of training courses on citizens' employability,» *Applied Intelligence*, vol. 55, n.º 1, pág. 57, ene. de 2025, issn: 0924-669X, 1573-7497. doi: [10.1007/s10489-024-05967-0](https://doi.org/10.1007/s10489-024-05967-0) visitado 2026-02-12. dirección: <https://link.springer.com/10.1007/s10489-024-05967-0>

- [48] M. Awad y S. Fraihat, «Recursive feature elimination with cross-validation with decision tree: Feature selection method for machine learning-based intrusion detection systems,» *Journal of Sensor and Actuator Networks*, vol. 12, n.º 5, pág. 67, 18 de sep. de 2023, issn: 2224-2708. doi: [10.3390/jsan12050067](https://doi.org/10.3390/jsan12050067) visitado 2026-02-16. dirección: <https://www.mdpi.com/2224-2708/12/5/67>
- [49] J. Peng e Y. Li, «Frontiers of artificial intelligence for personalized learning in higher education: A systematic review of leading articles,» *Applied Sciences*, vol. 15, n.º 18, pág. 10 096, 16 de sep. de 2025, issn: 2076-3417. doi: [10.3390/app151810096](https://doi.org/10.3390/app151810096) visitado 2026-02-11. dirección: <https://www.mdpi.com/2076-3417/15/18/10096>
- [50] L.-b. Sweet, C. Müller, M. Anand y J. Zscheischler, «Cross-Validation Strategy Impacts the Performance and Interpretation of Machine Learning Models,» *Artificial Intelligence for the Earth Systems*, vol. 2, n.º 4, e230026, oct. de 2023, issn: 2769-7525. doi: [10.1175/AIES-D-23-0026.1](https://doi.org/10.1175/AIES-D-23-0026.1) visitado 2026-02-16. dirección: <https://journals.ametsoc.org/view/journals/aies/2/4/AIES-D-23-0026.1.xml>
- [51] D. El-Shahat, A. Tolba, M. Abouhawwash y M. Abdel-Basset, «Machine learning and deep learning models based grid search cross validation for short-term solar irradiance forecasting,» *Journal of Big Data*, vol. 11, n.º 1, pág. 134, 18 de sep. de 2024, issn: 2196-1115. doi: [10.1186/s40537-024-00991-w](https://doi.org/10.1186/s40537-024-00991-w) visitado 2026-02-16. dirección: <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-024-00991-w>
- [52] Z. El Mrabet, N. Sugunaraj, P. Ranganathan y S. Abhyankar, «Random forest regressor-based approach for detecting fault location and duration in power systems,» *Sensors*, vol. 22, n.º 2, pág. 458, 8 de ene. de 2022, issn: 1424-8220. doi: [10.3390/s22020458](https://doi.org/10.3390/s22020458) visitado 2026-02-16. dirección: <https://www.mdpi.com/1424-8220/22/2/458>
- [53] N. Hamill y R. Iqbal, «Regression-based small language models for DER trust metric extraction from structured and semi-structured data,» *Big Data and Cognitive Computing*, vol. 10, n.º 2, pág. 39, 24 de ene. de 2026, issn: 2504-2289. doi: [10.3390/bdcc10020039](https://doi.org/10.3390/bdcc10020039) visitado 2026-02-11. dirección: <https://www.mdpi.com/2504-2289/10/2/39>
- [54] H. Blockeel, L. Devos, B. Frénay, G. Nanfack y S. Nijssen, «Decision trees: from efficient prediction to responsible AI,» *Frontiers in Artificial Intelligence*, vol. 6, pág. 1 124 553, 26 de jul. de 2023, issn: 2624-8212. doi: [10.3389/frai.2023.1124553](https://doi.org/10.3389/frai.2023.1124553) visitado 2026-02-16. dirección: <https://www.frontiersin.org/articles/10.3389/frai.2023.1124553/full>
- [55] H. A. Salman, A. Kalakech y A. Steiti, «Random Forest Algorithm Overview,» *Babylonian Journal of Machine Learning*, vol. 2024, págs. 69-79, 8 de jun. de 2024, issn:

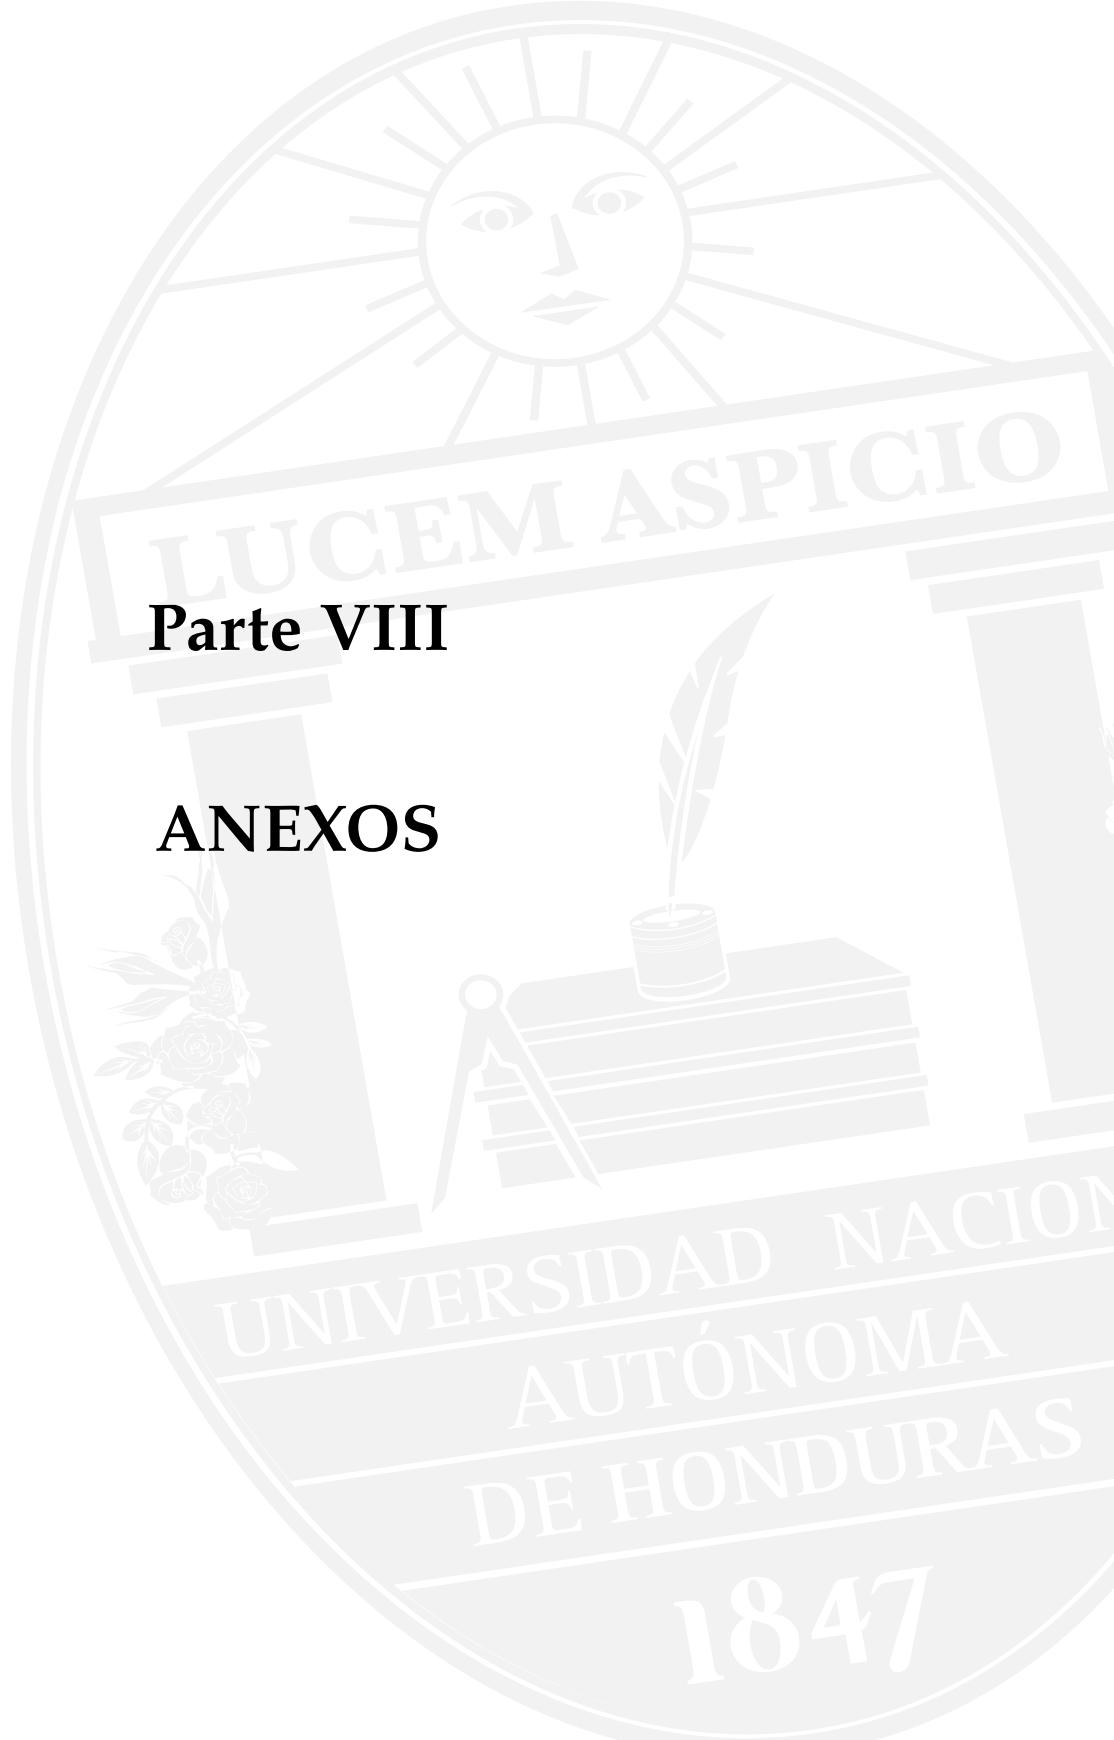
- 3006-5429. doi: [10.58496/BJML/2024/007](https://doi.org/10.58496/BJML/2024/007) visitado 2026-02-16. dirección: <https://journals.mesopotamian.press/index.php/BJML/article/view/417>
- [56] M. Gusnina, Wiharto y U. Salamah, «Student Performance Prediction in Sebelas Maret University Based on the Random Forest Algorithm,» *Ingénierie des systèmes d'information*, vol. 27, n.º 3, págs. 495-501, 30 de jun. de 2022, issn: 16331311, 21167125. doi: [10.18280/isi.270317](https://doi.org/10.18280/isi.270317) visitado 2026-02-11. dirección: <https://www.ieta.org/journals/isi/paper/10.18280/isi.270317>
- [57] S. D. A. Bujang et al., «Multiclass Prediction Model for Student Grade Prediction Using Machine Learning,» *IEEE Access*, vol. 9, págs. 95 608-95 621, 2021, issn: 2169-3536. doi: [10.1109/ACCESS.2021.3093563](https://doi.org/10.1109/ACCESS.2021.3093563) visitado 2026-02-11. dirección: <https://ieeexplore.ieee.org/document/9468629/>
- [58] D. Valkenborg, A.-J. Rousseau, M. Geubbelsmans y T. Burzykowski, «Support vector machines,» *American Journal of Orthodontics and Dentofacial Orthopedics*, vol. 164, n.º 5, págs. 754-757, nov. de 2023, issn: 08895406. doi: [10.1016/j.ajodo.2023.08.003](https://doi.org/10.1016/j.ajodo.2023.08.003) visitado 2026-02-16. dirección: <https://linkinghub.elsevier.com/retrieve/pii/S0889540623004298>
- [59] K. M. Sujon, R. Hassan, K. Choi y M. A. Samad, «Accuracy, precision, recall, f1-score, or MCC? empirical evidence from advanced statistics, ML, and XAI for evaluating business predictive models,» *Journal of Big Data*, vol. 12, n.º 1, pág. 268, 9 de dic. de 2025, issn: 2196-1115. doi: [10.1186/s40537-025-01313-4](https://doi.org/10.1186/s40537-025-01313-4) visitado 2026-02-16. dirección: <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-025-01313-4>
- [60] T. O. Hodson, «Root-mean-square error (RMSE) or mean absolute error (MAE): When to use them or not,» *Geoscientific Model Development*, vol. 15, n.º 14, págs. 5481-5487, 19 de jul. de 2022, issn: 1991-9603. doi: [10.5194/gmd-15-5481-2022](https://doi.org/10.5194/gmd-15-5481-2022) visitado 2026-02-16. dirección: <https://gmd.copernicus.org/articles/15/5481/2022/>
- [61] D. Wang, D. Lian, Y. Xing, S. Dong, X. Sun y J. Yu, «Analysis and Prediction of Influencing Factors of College Student Achievement Based on Machine Learning,» *Frontiers in Psychology*, vol. 13, pág. 881859, 22 de abr. de 2022, issn: 1664-1078. doi: [10.3389/fpsyg.2022.881859](https://doi.org/10.3389/fpsyg.2022.881859) visitado 2026-02-12. dirección: <https://www.frontiersin.org/articles/10.3389/fpsyg.2022.881859/full>
- [62] G. Blinowski, A. Ojdowska y A. Przybylek, «Monolithic vs. Microservice Architecture: A Performance and Scalability Evaluation,» *IEEE Access*, vol. 10, págs. 20 357-20 374, 2022, issn: 2169-3536. doi: [10.1109/ACCESS.2022.3152803](https://doi.org/10.1109/ACCESS.2022.3152803) visitado 2026-02-17. dirección: <https://ieeexplore.ieee.org/document/9717259/>

- [63] P. Gowda y A. N. Gowda, «Best Practices in REST API Design for Enhanced Scalability and Security,» *Journal of Artificial Intelligence, Machine Learning and Data Science*, vol. 2, n.º 1, págs. 827-830, 20 de feb. de 2024, issn: 25839888. doi: [10.51219/JAIMLD/priyanka-gowda/202](https://doi.org/10.51219/JAIMLD/priyanka-gowda/202) visitado 2026-02-17. dirección: <https://urfjournals.org/open-access/best-practices-in-rest-api-design-for-enhanced-scalability-and-security.pdf>
- [64] Mohammed Maaz, Md Akif Ahmed, Md Maqsood y Dr Shridevi Soma, «Development Of Service Deployment Models In Private Cloud,» *Journal of Scientific Research and Technology*, 11 de dic. de 2023, issn: 2583-8660. doi: [10.61808/jsrt74](https://doi.org/10.61808/jsrt74) visitado 2026-02-16. dirección: <https://jsrtjournal.com/index.php/JSRT/article/view/74>
- [65] K. Senjab, S. Abbas, N. Ahmed y A. U. R. Khan, «A survey of kubernetes scheduling algorithms,» *Journal of Cloud Computing*, vol. 12, n.º 1, pág. 87, 13 de jun. de 2023, issn: 2192-113X. doi: [10.1186/s13677-023-00471-1](https://doi.org/10.1186/s13677-023-00471-1) visitado 2026-02-08. dirección: <https://journalofcloudcomputing.springeropen.com/articles/10.1186/s13677-023-00471-1>
- [66] A. Nazyrova, M. Miłosz, G. Bekanova, A. Omarbekova, G. Aimicheva e Y. Kadyr, «The digital transformation of higher education in the context of an AI-driven future,» *Sustainability*, vol. 17, n.º 22, pág. 9927, 7 de nov. de 2025, issn: 2071-1050. doi: [10.3390/su17229927](https://doi.org/10.3390/su17229927) visitado 2026-02-11. dirección: <https://www.mdpi.com/2071-1050/17/22/9927>
- [67] P. I. Silva-da-Nóbrega, A. F. Chim-Miki y M. Castillo-Palacio, «A smart campus framework: Challenges and opportunities for education based on the sustainable development goals,» *Sustainability*, vol. 14, n.º 15, pág. 9640, 5 de ago. de 2022, issn: 2071-1050. doi: [10.3390/su14159640](https://doi.org/10.3390/su14159640) visitado 2026-02-19. dirección: <https://www.mdpi.com/2071-1050/14/15/9640>
- [68] X. Zhou y L. Schofield, «Developing a conceptual framework for Artificial Intelligence (AI) literacy in higher education,» *Journal of Learning Development in Higher Education*, n.º 31, 29 de sep. de 2024, issn: 1759-667X. doi: [10.47408/jldhe.vi31.1354](https://doi.org/10.47408/jldhe.vi31.1354) visitado 2026-02-19. dirección: <https://journal.aldinhe.ac.uk/index.php/jldhe/article/view/1354>
- [69] A. Alshanqiti, T. Alam, M. Benaida, A. Namoun y A. Taleb, «A rule-based approach toward automating the assessments of academic curriculum mapping,» *International Journal of Advanced Computer Science and Applications*, vol. 11, n.º 12, 2020, issn: 21565570, 2158107X. doi: [10.14569/IJACSA.2020.0111285](https://doi.org/10.14569/IJACSA.2020.0111285) visitado 2026-02-19.



- rección: <http://thesai.org/Publications/ViewPaper?Volume=11&Issue=12&Code=IJACSA&SerialNo=85>
- [70] A. Chang, *Data-Driven Enrollment Planning: Predictive Modeling in the First-Year Writing Program*, 2025. doi: [10.24507/icicelb.16.09.943](https://doi.org/10.24507/icicelb.16.09.943) visitado 2026-02-19. dirección: <https://doi.org/10.24507/icicelb.16.09.943>
- [71] A. Bashab et al., «Optimization techniques in university timetabling problem: Constraints, methodologies, benchmarks, and open issues,» *Computers, Materials & Continua*, vol. 74, n.º 3, págs. 6461-6484, 2023, ISSN: 1546-2226. doi: [10.32604/cmc.2023.034051](https://doi.org/10.32604/cmc.2023.034051) visitado 2026-02-19. dirección: <https://www.techscience.com/cmc/v74n3/50939>
- [72] A. Almtrf, «Integrating Explainable Ai (Xai) Into Decision Support Systems: A Framework for Enhancing Transparency and Trust in Managerial Decision-Making,» *International Journal of Managerial Studies and Research*, vol. 13, n.º 9, págs. 9-22, 2025, ISSN: 23490349. doi: [10.20431/2349-0349.1309002](https://doi.org/10.20431/2349-0349.1309002) visitado 2026-02-19. dirección: <https://www.arcjournals.org/pdfs/ijmsr/v13-i9/2.pdf>
- [73] A. Shaikhanova, O. Kuznetsov, K. Iklassova, A. Tokkuliyeva y L. Sugurova, «Interpretable predictive modeling for educational equity: A workload-aware decision support system for early identification of at-risk students,» *Big Data and Cognitive Computing*, vol. 9, n.º 11, pág. 297, 20 de nov. de 2025, ISSN: 2504-2289. doi: [10.3390/bdcc9110297](https://doi.org/10.3390/bdcc9110297) visitado 2026-02-19. dirección: <https://www.mdpi.com/2504-2289/9/11/297>
- [74] V. M. García Macías, R. W. Moreira Pérez, R. I. Ponce Martínez y M. Loor Domo, «Aprendizaje adaptativo a través de la Inteligencia Artificial en la Educación Superior,» *Revista Científica de Innovación Educativa y Sociedad Actual "ALCON"*, vol. 5, n.º 4, págs. 480-489, 8 de ago. de 2025, ISSN: 2960-8473. doi: [10.62305/alcon.v5i4.775](https://doi.org/10.62305/alcon.v5i4.775) visitado 2026-02-19. dirección: <https://soeici.org/index.php/alcon/article/view/775>
- [75] Universidad Nacional Autónoma de Honduras. «Normas académicas - Universidad Nacional Autónoma de Honduras,» visitado 2026-02-21. dirección: <https://www.unah.edu.hn/sobre-la-unah/normativa/normas-academicas/>
- [76] Congreso Nacional de la República de Honduras. «Ley de Transparencia y Acceso a la Información Pública y su Reglamento,» visitado 2026-02-21. dirección: <https://www.tsc.gob.hn/biblioteca/index.php/leyes/17-ley-de-transparencia-y-acceso-a-la-informacion-publica>

- [77] UNESCO. «Recomendación sobre la ética de la inteligencia artificial - UNESCO Biblioteca Digital,» visitado 2026-02-21. dirección: https://unesdoc.unesco.org/ark:/48223/pf0000381137_spa
- [78] R. Hernández Sampieri, C. Fernández Collado y M. d. P. Baptista Lucio, *Metodología de la investigación*, 6.^a ed. México: McGraw-Hill Interamericana, 2014, ISBN: 978-1-4562-2396-0.



Parte VIII

ANEXOS

13

Anexos

Anexo A Proceso de configuración de SUMO

En este anexo se presentan unas fotografías del proceso de configuración de SUMO. En la imagen se observa como se esta trabajando con la herramienta de edición de redes de SUMO (NETEDIT) para la creación de la red vial correspondiente al área de estudio.

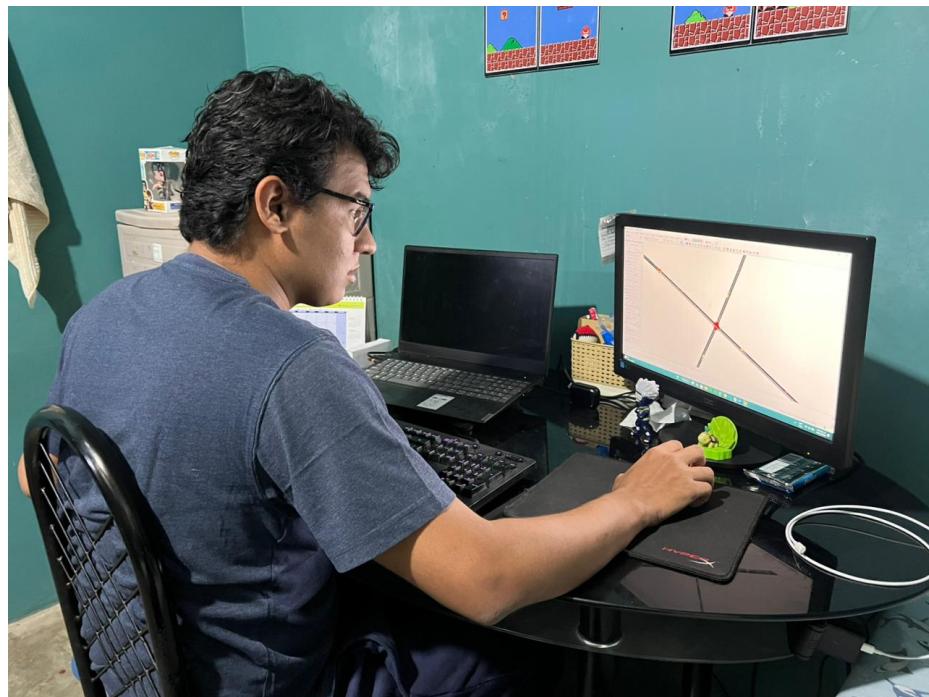


Figura 13.1: Interfaz de SUMO NETEDIT para la edición de redes viales

Anexo B Equipo de cómputo utilizado

En este anexo se muestra el equipo de cómputo utilizado para la realización de las simulaciones vehiculares y análisis de datos presentados en este trabajo.

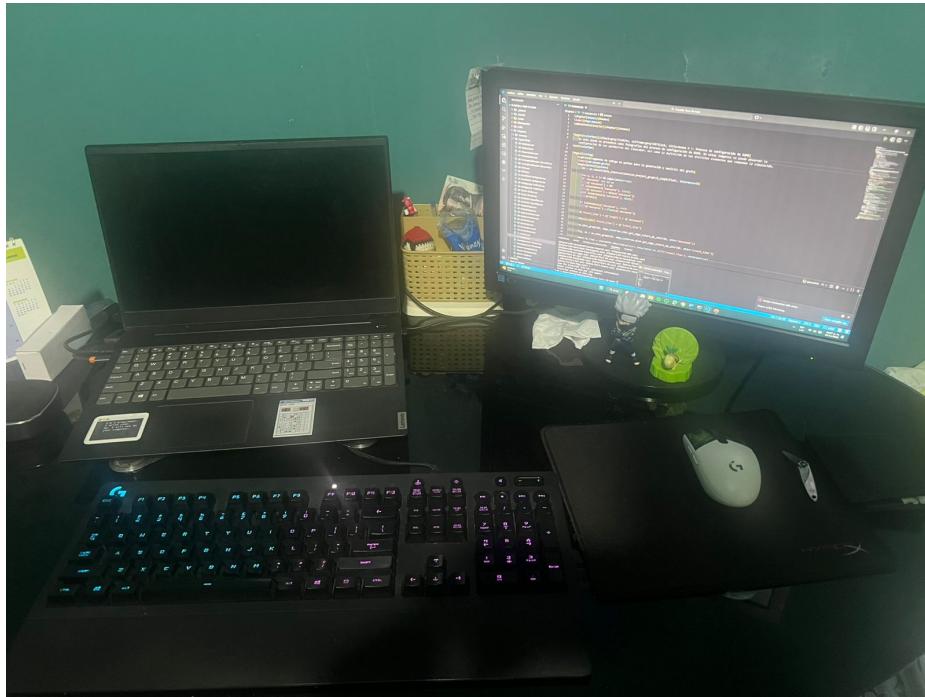


Figura 13.2: Equipo de cómputo utilizado para la realización de las simulaciones y análisis de datos

Anexo C Código en python para la generación del grafos

En este anexo se presenta un fragmento de código utilizado para la generación y análisis del grafo vial del área de estudio utilizando la librería OSMNX y NetworkX.

Código 1: Fragmento de código en python para la generación y análisis del grafo

```
1 G2 = ox.consolidate_intersections(ox.project_graph(G_simplified), tolerance=15)
2
3     for u, v, a in G2.edges(data=True):
4         if 'maxspeed' not in a:
5             a['maxspeed'] = 50
6         if isinstance(a['maxspeed'], list):
7             a['maxspeed'] = min(a['maxspeed'])
8         elif isinstance(a['maxspeed'], dict):
9             print(a)
10
11     if isinstance(a['maxspeed'], str):
12         a['maxspeed'] = float(a['maxspeed'])
13
14     a['travel_time'] = a['length'] / a['maxspeed']
15
16     G2[u][v][0]['travel_time'] = a['travel_time']
17
18     ox.plot_graph(G2, edge_color=ox.plot.get_edge_colors_by_attr(G2, attr='maxspeed'))
19
20     fig, ax = ox.plot_graph(G2, edge_color=ox.plot.get_edge_colors_by_attr(G2,
21     ↪ attr='travel_time'))
22
23     edges_by_time = sorted(G2.edges(data=True), key=lambda e: e[2]['travel_time'],
24     ↪ reverse=True)
25
26     [e[2].get('name', 'Unnamed edge') for e in edges_by_time[:10]]
27
28     nodes_centrality = nx.betweenness_centrality(G2, weight='length')
29
30     for node, centrality in nodes_centrality.items():
31         G2.nodes[node]['centrality'] = centrality
32
33     ox.plot_graph(G2, node_color=ox.plot.get_node_colors_by_attr(G2, attr='centrality'))
```

Anexo D Fragmento de código en python para la generación del gráficas

En este anexo se presentan el ejemplo de un código utilizado para el análisis de datos generados por la simulación vehicular en SUMO y la generación de las gráficas presentadas en el capítulo. El código completo se encuentra disponible en el cuaderno ejecutable: .

Código 2: Fragmento de código para el análisis de datos de SUMO y generación de gráficas

```
1 # Cargar y obtener los promedios de cada archivo para todas las columnas
2 datos_por_columna = {col: [] for col in cols}
3
4 for archivo, etiqueta_archivo in archivos:
5     df = pd.read_csv(archivo)
6     for col in cols:
7         promedio = df[col].mean()
8         datos_por_columna[col].append((promedio, etiqueta_archivo))
```